

Парсер-комбинаторы и Parser Expression Grammars

Автор: Екатерина Вербицкая

Санкт-Петербургский государственный университет
Математико-механический факультет

8 декабря 2015г.

Долг: зачем нужен RNLGR

Долг: зачем нужен RNLGR

Для обработки неоднозначных грамматик. Часто нельзя выбрать заранее, какая из альтернатив "верна".

Долг: зачем нужен RNLGR

Для обработки неоднозначных грамматик. Часто нельзя выбрать заранее, какая из альтернатив "верна".

$$S \rightarrow \text{if } b \text{ then } S \text{ else } S$$
$$S \rightarrow \text{if } b \text{ then } S$$
$$S \rightarrow a$$


Долг: зачем нужен RNLGR

Для обработки неоднозначных грамматик. Часто нельзя выбрать заранее, какая из альтернатив "верна".

$$S \rightarrow \text{if } b \text{ then } S \text{ else } S$$
$$S \rightarrow \text{if } b \text{ then } S$$
$$S \rightarrow a$$

2 дерева вывода для цепочки *if b then if b then a else a*

Лес разбора: объединяет 2 дерева



Парсер-комбинаторы: общая идея

- Написать примитивные парсеры (например, для обработки отдельных символов)
- Написать комбинаторы для составления из примитивных парсеров более сложных
 - ▶ Последовательности
 - ▶ Альтернативы
 - ▶ Повторение
 - ▶ Опциональный парсер
 - ▶ ...
- С использованием этого инструментария описать необходимый парсер

Парсер-комбинаторы: тип парсера

$$\textit{Parser} = \textit{String} \rightarrow \textit{Tree}$$

Парсер-комбинаторы: тип парсера

Parser = *String* \rightarrow *Tree*

Parser = *String* \rightarrow (*Tree*, *String*)

Парсер-комбинаторы: тип парсера

Parser = *String* \rightarrow *Tree*

Parser = *String* \rightarrow (*Tree*, *String*)

Parser = *String* \rightarrow [(*Tree*, *String*)]

Парсер-комбинаторы: тип парсера

Parser = *String* \rightarrow *Tree*

Parser = *String* \rightarrow (*Tree*, *String*)

Parser = *String* \rightarrow [(*Tree*, *String*)]

Parser a = *String* \rightarrow [(*a*, *String*)]

Примитивные парсеры

```
result :: a -> Parser a  
result v = \inp -> [(v,inp)]
```

```
zero :: Parser a  
zero = \inp -> []
```

```
item :: Parser Char  
item = \inp -> case inp of  
    [] -> []  
    (x:xs) -> [(x,xs)]
```

Парсер-комбинаторы

```
bind :: Parser a -> (a -> Parser b) -> Parser b
p 'bind' f = \inp -> concat [f v inp' | (v,inp') <- p inp]
```

```
p 'seq' q = p 'bind' \x ->
             q 'bind' \y ->
             result (x,y)
```

```
sat :: (Char -> Bool) -> Parser Char
sat p = item 'bind' \x ->
        if p x then result x else zero
```

```
plus :: Parser a -> Parser a -> Parser a
p 'plus' q = \inp -> (p inp ++ q inp)
```

Маленькие полезные парсеры

```
char :: Char -> Parser Char
```

```
char x = sat (\y -> x == y)
```

```
digit :: Parser Char
```

```
digit = sat (\x -> '0' <= x && x <= '9')
```

```
lower :: Parser Char
```

```
lower = sat (\x -> 'a' <= x && x <= 'z')
```

```
upper :: Parser Char
```

```
upper = sat (\x -> 'A' <= x && x <= 'Z')
```

Менее маленькие полезные парсеры

```
letter :: Parser Char
letter = lower 'plus' upper

alphanum :: Parser Char
alphanum = letter 'plus' digit

word :: Parser String
word = neWord 'plus' result ""
    where
        neWord = letter 'bind' \x ->
            word 'bind' \xs ->
                result (x:xs)

word "Yes!" = [("Yes","!"), ("Ye","s!"),
               ("Y","es!"), ("","Yes!")]
```

Монадические парсер-комбинаторы

```
class Monad m where
  result :: a -> m a
  bind :: m a -> (a -> m b) -> m b

instance Monad Parser where
  -- result :: a -> Parser a
  result v = \inp -> [(v,inp)]

  -- bind :: Parser a -> (a -> Parser b) -> Parser b
  p 'bind' f = \inp -> concat [f v out | (v,out) <- p inp]
```


Монадические парсер-комбинаторы

```
class Monad m => Monad0Plus m where
  zero :: m a
  (++) :: m a -> m a -> m a

instance Monad0Plus Parser where
  -- zero :: Parser a
  zero = \inp -> []

  -- (++) :: Parser a -> Parser a -> Parser a
  p ++ q = \inp -> (p inp ++ q inp)
```

Другая форма записи

```
p1 'bind' \x1 ->  
p2 'bind' \x2 ->  
...  
pn 'bind' \xn ->  
result (f x1 x2 ... xn)
```

```
[ f x1 x2 ... xn | x1 <- p1  
                  , x2 <- p2  
                  , ...  
                  , xn <- pn ]
```

```
string :: String -> Parser String  
string "" = [""]  
string (x:xs) = [x:xs | _ <- char x, _ <- string xs]
```

Монадические парсер-комбинаторы

```
sat :: (Char -> Bool) -> Parser Char
```

```
sat p = [x | x <- item, p x]
```

```
many :: Parser a -> Parser [a]
```

```
many p = [x:xs | x <- p, xs <- many p] ++ [[]]
```

```
ident :: Parser String
```

```
ident = [x:xs | x <- lower, xs <- many alphanum]
```

Примеры парсеров

```
many1 :: Parser a -> Parser [a]
many1 p = [x:xs | x <- p, xs <- many p]

nat :: Parser Int
nat = [eval xs | xs <- many1 digit]
  where
    eval xs = foldl1 op [ord x - ord '0' | x <- xs]
    m 'op' n = 10*m + n

int :: Parser Int
int = [-n | _ <- char '-', n <- nat] ++ nat

int :: Parser Int
int = [f n | f <- op, n <- nat]
  where
    op = [negate | _ <- char '-'] ++ [id]
```

Пример: список чисел

```
ints :: Parser [Int]
ints = [n:ns | _ <- char '['
        , n <- int
        , ns <- many [x | _ <- char ',', x <- int]
        , _ <- char ']']
```

```
sepby1 :: Parser a -> Parser b -> Parser [a]
p 'sepby1' sep = [x:xs | x <- p
                        , xs <- many [y | _ <- sep, y <- p]]
```

```
ints = [ns | _ <- char '['
           , ns <- int 'sepby1' char ',',
           , _ <- char ']']
```

Список чисел: еще короче

```
bracket :: Parser a -> Parser b -> Parser c -> Parser b
bracket open p close = [x | _ <- open, x <- p, _ <- close]

ints = bracket (char '[')
              (int 'sepby1' char ',')
              (char ']')
```

Пример: арифметические выражения

$$\begin{aligned} \text{expr} &::= \text{expr addop factor} \mid \text{factor} \\ \text{addop} &::= + \mid - \\ \text{factor} &::= \text{nat} \mid (\text{expr}) \end{aligned}$$

```
expr :: Parser Int
addop :: Parser (Int -> Int -> Int)
factor :: Parser Int
```

```
expr = [f x y | x <- expr
               , f <- addop
               , y <- factor] ++ factor
```

```
addop = [(+) | _ <- char '+'] ++ [(-) | _ <- char '-']
```

```
factor = nat ++ bracket (char '(') expr (char ')')
```

Избавляемся от левой рекурсии

```
expr = [foldl1 (\x (f,y) -> f x y) x fys
        | x <- factor
        , fys <- many [(f,y) | f <- addop, y <- factor]]

addop = [(+) | _ <- char '+'] ++ [(-) | _ <- char '-']

factor = nat ++ bracket (char '(') expr (char ')')
```


Преимущества монадических парсер-комбинаторов

- Простота
- Гибкость
- Выразительность
- Возможность откатываться (backtracking)
- Лексический анализ не нужно выделять в отдельный шаг
- Можно считать семантику во время синтаксического анализа

Недостатки монадических парсер-комбинаторов

- Если использовать неграмотно, можно получить непредсказуемое время работы и легко исчерпать всю доступную память
 - ▶ Наличие общих префиксов у нескольких правил. Решение: факторизация грамматики
 - ▶ Вычисление промежуточных результатов, где не было надо. Решение: использование ленивости (например, $p + + + q = \text{first}(p + + q)$)

Parser Expression Grammars

- PEG G — четверка (V, T, P, p_S) , где
 - ▶ V — конечное множество нетерминалов
 - ▶ T — алфавит (конечное множество терминалов)
 - ▶ P — функция из V в выражения (parser expression)
 - ▶ p_S — стартовое выражение
- Parser expression
 - ▶ Пустая строка ε
 - ▶ Терминал a
 - ▶ Нетерминал A
 - ▶ Последовательность $p_1 p_2$, где p_1, p_2 — parser expression
 - ▶ Упорядоченный выбор p_1 / p_2 , где p_1, p_2 — parser expression
 - ▶ 0-или-больше p^* , где p — parser expression
 - ▶ Предикат $!p$, где p — parser expression

$$G[p] \ xy \overset{\text{PEG}}{\rightsquigarrow} (y, x')$$

- Выражение p парсит строку xy , съедая x и оставляя y , возвращая x' как результат
- Если справа *fail*, значит, распарсить строку не удалось

Операционная семантика PEG: пустая строка

$$\overline{G[\varepsilon] \quad x \overset{\text{PEG}}{\rightsquigarrow} (x, \varepsilon)}$$

$$\overline{G[a] \quad ax \overset{\text{PEG}}{\rightsquigarrow} (x, a)}$$

$$\frac{}{G[a] \quad ax \stackrel{\text{PEG}}{\leadsto} (x, a)}$$

$$\frac{}{G[b] \quad ax \stackrel{\text{PEG}}{\leadsto} \text{fail}}, \quad b \neq a$$

$$\overline{G[a] \quad ax \stackrel{\text{PEG}}{\leadsto} (x, a)}$$

$$\overline{G[b] \quad ax \stackrel{\text{PEG}}{\leadsto} \text{fail}}, \quad b \neq a$$

$$\overline{G[a] \quad \varepsilon \stackrel{\text{PEG}}{\leadsto} \text{fail}}$$

$$\frac{G[P(A)] \quad xy \overset{\text{PEG}}{\rightsquigarrow} (y, x')}{G[A] \quad xy \overset{\text{PEG}}{\rightsquigarrow} (y, A[x'])}$$

$$\frac{G[P(A)] \quad xy \stackrel{\text{PEG}}{\rightsquigarrow} (y, x')}{G[A] \quad xy \stackrel{\text{PEG}}{\rightsquigarrow} (y, A[x'])}$$

$$\frac{G[P(A)] \quad x \stackrel{\text{PEG}}{\rightsquigarrow} \text{fail}}{G[A] \quad x \stackrel{\text{PEG}}{\rightsquigarrow} \text{fail}}$$

Операционная семантика PEG: последовательность

$$\frac{G[p_1] \ xyz \overset{\text{PEG}}{\rightsquigarrow} (yz, x') \quad G[p_2] \ yz \overset{\text{PEG}}{\rightsquigarrow} (z, y')}{G[p_1 p_2] \ xyz \overset{\text{PEG}}{\rightsquigarrow} (z, x'y')}$$

Операционная семантика PEG: последовательность

$$\frac{G[p_1] \ xyz \xrightarrow{\text{PEG}} (yz, x') \quad G[p_2] \ yz \xrightarrow{\text{PEG}} (z, y')}{G[p_1 p_2] \ xyz \xrightarrow{\text{PEG}} (z, x'y')}$$

$$\frac{G[p_1] \ xy \xrightarrow{\text{PEG}} (y, x') \quad G[p_2] \ y \xrightarrow{\text{PEG}} \text{fail}}{G[p_1 p_2] \ xy \xrightarrow{\text{PEG}} \text{fail}}$$

Операционная семантика PEG: последовательность

$$\frac{G[p_1] \ xyz \xrightarrow{\text{PEG}} (yz, x') \quad G[p_2] \ yz \xrightarrow{\text{PEG}} (z, y')}{G[p_1 p_2] \ xyz \xrightarrow{\text{PEG}} (z, x'y')}$$

$$\frac{G[p_1] \ xy \xrightarrow{\text{PEG}} (y, x') \quad G[p_2] \ y \xrightarrow{\text{PEG}} \text{fail}}{G[p_1 p_2] \ xy \xrightarrow{\text{PEG}} \text{fail}}$$

$$\frac{G[p_1] \ x \xrightarrow{\text{PEG}} \text{fail}}{G[p_1 p_2] \ x \xrightarrow{\text{PEG}} \text{fail}}$$

Операционная семантика PEG: выбор

$$\frac{G[p_1] \quad xy \overset{\text{PEG}}{\rightsquigarrow} (y, x')}{G[p_1 / p_2] \quad xy \overset{\text{PEG}}{\rightsquigarrow} (y, x')}$$

Операционная семантика PEG: выбор

$$\frac{G[p_1] \ xy \overset{\text{PEG}}{\rightsquigarrow} (y, x')}{G[p_1 / p_2] \ xy \overset{\text{PEG}}{\rightsquigarrow} (y, x')}$$

$$\frac{G[p_1] \ x \overset{\text{PEG}}{\rightsquigarrow} \text{fail} \quad G[p_2] \ x \overset{\text{PEG}}{\rightsquigarrow} \text{fail}}{G[p_1 / p_2] \ x \overset{\text{PEG}}{\rightsquigarrow} \text{fail}}$$

Операционная семантика PEG: выбор

$$\frac{G[p_1] \ xy \overset{\text{PEG}}{\rightsquigarrow} (y, x')}{G[p_1 / p_2] \ xy \overset{\text{PEG}}{\rightsquigarrow} (y, x')}$$

$$\frac{G[p_1] \ x \overset{\text{PEG}}{\rightsquigarrow} \text{fail} \quad G[p_2] \ x \overset{\text{PEG}}{\rightsquigarrow} \text{fail}}{G[p_1 / p_2] \ x \overset{\text{PEG}}{\rightsquigarrow} \text{fail}}$$

$$\frac{G[p_1] \ xy \overset{\text{PEG}}{\rightsquigarrow} \text{fail} \quad G[p_2] \ xy \overset{\text{PEG}}{\rightsquigarrow} (y, x')}{G[p_1 / p_2] \ xy \overset{\text{PEG}}{\rightsquigarrow} (y, x')}$$

$$\frac{G[p] \ x \overset{\text{PEG}}{\rightsquigarrow} \text{fail}}{G[!p] \ x \overset{\text{PEG}}{\rightsquigarrow} (x, \varepsilon)}$$

Операционная семантика PEG: предикат не

$$\frac{G[p] \ x \stackrel{\text{PEG}}{\leadsto} \text{fail}}{G[!p] \ x \stackrel{\text{PEG}}{\leadsto} (x, \varepsilon)}$$

$$\frac{G[p] \ xy \stackrel{\text{PEG}}{\leadsto} (y, x')}{G[!p] \ xy \stackrel{\text{PEG}}{\leadsto} \text{fail}}$$

Операционная семантика PEG: повторение

$$\frac{G[p] \ x \overset{\text{PEG}}{\rightsquigarrow} \mathbf{fail}}{G[p^*] \ x \overset{\text{PEG}}{\rightsquigarrow} (x, \varepsilon)}$$

Операционная семантика PEG: повторение

$$\frac{G[p] \ x \xrightarrow{\text{PEG}} \text{fail}}{G[p^*] \ x \xrightarrow{\text{PEG}} (x, \varepsilon)}$$

$$\frac{G[p] \ xyz \xrightarrow{\text{PEG}} (yz, x') \quad G[p^*] \ yz \xrightarrow{\text{PEG}} (z, y')}{G[p^*] \ xyz \xrightarrow{\text{PEG}} (z, x'y')}$$

Борьба с левой рекурсией: ограниченная левая рекурсия

- A^n имеет не более n леворекурсивных вызовов A , A^0 всегда завершается ошибкой

$$E^0 ::= \text{fail}$$

$$E^1 ::= E^0 + n/n = \perp + n/n = n$$

$$E^2 ::= E^1 + n/n = n + n/n$$

$$E^3 ::= E^2 + n/n = (n + n/n) + n/n$$

...

$$E^n ::= E^{n-1} + n/n$$

Пример: разбираем с разными границами строку $n + n$

$$E^0(n + n) = \text{fail}$$

$$E^1(n + n) = (\perp + n/n)(n + n) = (n, +n)$$

$$E^2(n + n) = (n + n/n)(n + n) = (n + n, \varepsilon)$$

$$E^3(n + n) = ((n + n/n) + n/n)(n + n) = (n, +n)$$

При разборе входа с помощью E^3 , во внутренней альтернативе $(n + n/n)$ первый вариант срабатывает (и поэтому второй вариант не будет рассматриваться вообще!). После этого пытаемся разобрать оставшийся ε с помощью оставшегося $+n$ и не можем. Остается только вторая альтернатива, поэтому матчится только один n .

- Ищем значение n для каждого леворекурсивного нетерминала
- Подбирается такая граница, чтобы префикс, обработанный правилом, имел максимальную длину
- Промежуточные значения сохраняются в табличку L
 - ▶ $L[(A, x) \rightarrow X](B, y) = L(B, y)$, если $B \neq A$ или $y \neq x$
 - ▶ $L[(A, x) \rightarrow X](A, x) = X$

Обработка леворекурсивного нетерминала

$$\frac{\begin{array}{l} (A, xyz) \notin \mathcal{L} \quad G[P(A)] \quad xyz \quad \mathcal{L}[(A, xyz) \mapsto \mathbf{fail}] \xrightarrow{\text{PEG}} (yz, x') \\ G[P(A)] \quad xyz \quad \mathcal{L}[(A, xyz) \mapsto (yz, x')] \xrightarrow{\text{INC}} (z, (xy)') \end{array}}{G[A] \quad xyz \quad \mathcal{L} \xrightarrow{\text{PEG}} (z, A[(xy)'])}$$

Обработка леворекурсивного нетерминала

$$\frac{(A, xyz) \notin \mathcal{L} \quad G[P(A)] \quad xyz \in \mathcal{L}[(A, xyz) \mapsto \mathbf{fail}] \xrightarrow{\text{PEG}} (yz, x') \quad G[P(A)] \quad xyz \in \mathcal{L}[(A, xyz) \mapsto (yz, x')] \xrightarrow{\text{INC}} (z, (xy)')}{G[A] \quad xyz \in \mathcal{L} \xrightarrow{\text{PEG}} (z, A[(xy)'])}$$

$$\frac{(A, x) \notin \mathcal{L} \quad G[P(A)] \quad x \in \mathcal{L}[(A, x) \mapsto \mathbf{fail}] \xrightarrow{\text{PEG}} \mathbf{fail}}{G[A] \quad x \in \mathcal{L} \xrightarrow{\text{PEG}} \mathbf{fail}}$$

Обработка леворекурсивного нетерминала

$$\frac{(A, xyz) \notin \mathcal{L} \quad G[P(A)] \quad xyz \quad \mathcal{L}[(A, xyz) \mapsto \mathbf{fail}] \xrightarrow{\text{PEG}} (yz, x') \quad G[P(A)] \quad xyz \quad \mathcal{L}[(A, xyz) \mapsto (yz, x')] \xrightarrow{\text{INC}} (z, (xy)')}{G[A] \quad xyz \quad \mathcal{L} \xrightarrow{\text{PEG}} (z, A[(xy)'])}$$

$$\frac{(A, x) \notin \mathcal{L} \quad G[P(A)] \quad x \quad \mathcal{L}[(A, x) \mapsto \mathbf{fail}] \xrightarrow{\text{PEG}} \mathbf{fail}}{G[A] \quad x \quad \mathcal{L} \xrightarrow{\text{PEG}} \mathbf{fail}}$$

$$\frac{\mathcal{L}(A, xy) = \mathbf{fail}}{G[A] \quad xy \quad \mathcal{L} \xrightarrow{\text{PEG}} \mathbf{fail}}$$

Обработка леворекурсивного нетерминала

$$\frac{(A, xyz) \notin \mathcal{L} \quad G[P(A)] \quad xyz \quad \mathcal{L}[(A, xyz) \mapsto \mathbf{fail}] \stackrel{\text{PEG}}{\rightsquigarrow} (yz, x') \quad G[P(A)] \quad xyz \quad \mathcal{L}[(A, xyz) \mapsto (yz, x')] \stackrel{\text{INC}}{\rightsquigarrow} (z, (xy)')}{G[A] \quad xyz \quad \mathcal{L} \stackrel{\text{PEG}}{\rightsquigarrow} (z, A[(xy)'])}$$

$$\frac{(A, x) \notin \mathcal{L} \quad G[P(A)] \quad x \quad \mathcal{L}[(A, x) \mapsto \mathbf{fail}] \stackrel{\text{PEG}}{\rightsquigarrow} \mathbf{fail}}{G[A] \quad x \quad \mathcal{L} \stackrel{\text{PEG}}{\rightsquigarrow} \mathbf{fail}}$$

$$\frac{\mathcal{L}(A, xy) = \mathbf{fail}}{G[A] \quad xy \quad \mathcal{L} \stackrel{\text{PEG}}{\rightsquigarrow} \mathbf{fail}}$$

$$\frac{\mathcal{L}(A, xy) = (y, x')}{G[A] \quad xy \quad \mathcal{L} \stackrel{\text{PEG}}{\rightsquigarrow} (y, A[x'])}$$

$$\frac{G[P(A)] \ xyzw \ \mathcal{L}[(A, xyzw) \mapsto (yzw, x')] \stackrel{\text{PEG}}{\rightsquigarrow} (zw, (xy)') \quad G[P(A)] \ xyzw \ \mathcal{L}[(A, xyzw) \mapsto (zw, (xy)')] \stackrel{\text{INC}}{\rightsquigarrow} (w, (xyz)')}{G[P(A)] \ xyzw \ \mathcal{L}[(A, xyzw) \mapsto (yzw, x')] \stackrel{\text{INC}}{\rightsquigarrow} (w, (xyz)')}, \text{ where } y \neq \varepsilon$$

$$\frac{G[P(A)] \ x y z w \ \mathcal{L}[(A, x y z w) \mapsto (y z w, x')] \stackrel{\text{PEG}}{\rightsquigarrow} (z w, (x y)') \quad G[P(A)] \ x y z w \ \mathcal{L}[(A, x y z w) \mapsto (z w, (x y)')] \stackrel{\text{INC}}{\rightsquigarrow} (w, (x y z)')}{G[P(A)] \ x y z w \ \mathcal{L}[(A, x y z w) \mapsto (y z w, x')] \stackrel{\text{INC}}{\rightsquigarrow} (w, (x y z)')}, \text{ where } y \neq \varepsilon$$

$$\frac{G[P(A)] \ x \ \mathcal{L} \stackrel{\text{PEG}}{\rightsquigarrow} \text{fail}}{G[P(A)] \ x \ \mathcal{L} \stackrel{\text{INC}}{\rightsquigarrow} \mathcal{L}(A, x)}$$

$$\frac{G[P(A)] \ x y z w \ \mathcal{L}[(A, x y z w) \mapsto (y z w, x')] \stackrel{\text{PEG}}{\rightsquigarrow} (z w, (x y)') \quad G[P(A)] \ x y z w \ \mathcal{L}[(A, x y z w) \mapsto (z w, (x y)')] \stackrel{\text{INC}}{\rightsquigarrow} (w, (x y z)')}{G[P(A)] \ x y z w \ \mathcal{L}[(A, x y z w) \mapsto (y z w, x')] \stackrel{\text{INC}}{\rightsquigarrow} (w, (x y z)')}, \text{ where } y \neq \varepsilon$$

$$\frac{G[P(A)] \ x \ \mathcal{L} \stackrel{\text{PEG}}{\rightsquigarrow} \text{fail}}{G[P(A)] \ x \ \mathcal{L} \stackrel{\text{INC}}{\rightsquigarrow} \mathcal{L}(A, x)}$$

$$\frac{G[P(A)] \ x y z \ \mathcal{L}[(A, x y z) \mapsto (z, (x y)')] \stackrel{\text{PEG}}{\rightsquigarrow} (y z, x')}{G[P(A)] \ x y z \ \mathcal{L}[(A, x y z) \mapsto (z, (x y)')] \stackrel{\text{INC}}{\rightsquigarrow} (z, (x y)')}$$

- Monadic parser combinators:
<http://www.cs.nott.ac.uk/~pszgmh/monparsing.pdf>
- Left recursion in Parsing Expression Grammars:
<http://arxiv.org/pdf/1207.0443.pdf>
- Парсер-комбинаторная библиотека на F#:
<https://github.com/pragmatrix/ScanRat>