Синтаксический анализ регулярных множеств

Автор: Екатерина Вербицкая

Семинар научно-исследовательских лабораторий JetBrains

21 ноября 2015г.

Динамически формируемые выражения

- *Динамически формируемые выражения* генерируются из строковых литералов во время исполнения программы
  - Также могут называться *динамическим* или *встроенным кодом*
- Программа, формирующая такие выражения — *генератор* или *основная программа*
- *Точка интереса* — строка основной программы, в которой осуществляется чтение значения формируемого выражения
- *Множество значений (динамического) выражения* — множество всех выражений, которые могут породиться в процессе выполнения основной программы в данной точке интереса

Динамически формируемые выражения: примеры

- Встроенный SQL

```
SqlComm nd myComm nd = new SqlComm nd(
    "SELECT * FROM t ble WHERE Column = @P r m2",
    myConnection);
myComm nd.P r meters.Add(myP r m2);
```

- Динамический SQL

```
IF @X = @Y
    SET @TBL = ' #t ble1 '
ELSE
    SET @TBL = ' t ble2 '
SET @S = 'SELECT x FROM' + @TBL + 'WHERE ISNULL(n,0) > 1'
EXECUTE (@S)
```

Проблемы

- Встроенный код — код на некотором языке программирования, поэтому, как следствие, необходимы:
  - Поддержка в IDE (подсветка кода, сообщение об ошибках, рефакторинги)
  - Трансляция (миграция с устаревших технологий на новые платформы)
  - Обнаружение уязвимостей

Статический анализ встроенного кода

- Производится без выполнения основной программы
- Проверяет выполнение некоторых свойств для *каждого* возможного выражения

- В общем случае задача статического анализа встроенных языков неразрешима
- При *регулярной аппроксимации* множества значений выражения некоторые задачи становятся разрешимыми
  - *Регулярная аппроксимация* — аппроксимация (сверху) регулярным языком множества значений выражения

Существующие решения

- PHP String Analyzer, Java String Analyzer, Alvor
  - Статические анализаторы PHP, Java и SQL, встроенных в Java
- Kyung-Goo Doh et al.
  - Проверяет синтаксическую корректность встроенного кода
- PHPStorm
  - IDE для PHP с поддержкой HTML, CSS, JavaScript
- IntelliLang
  - PHPStorm и IDEA plugin, поддержка многих языков
- STRANGER
  - Обнаружение уязвимости в коде на PHP

- Недостатки
  - Ограниченная функциональность
  - Сложно расширить новой функциональностью или поддержать новые языки
  - Не создают структурного представления динамического кода

Статический анализ встроенных языков: схема

- Определение точек интереса
- Построение аппроксимации
- Лексический анализ
- **Синтаксический анализ**
  - Относительно эталонной грамматики
- Семантический анализ

Статический анализ встроенных языков: схема

Код: выделена точка интереса

```
string res = "";
for(i = 0; i < l; i++)
    res = "()" + res;
use(res);
```

Порождаемые значения

```
{"", "()", "()()", ..., "()"^l}
```

Регулярная аппроксимация

```
("()")*
```

Аппроксимация

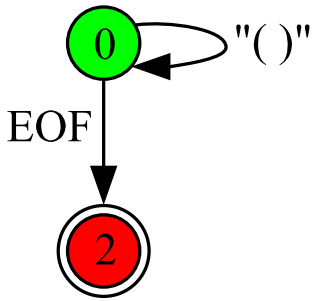

Статический анализ встроенных языков: схема

Аппроксимация

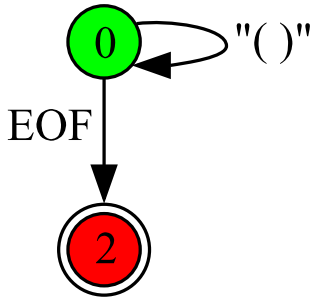

После лексического анализа

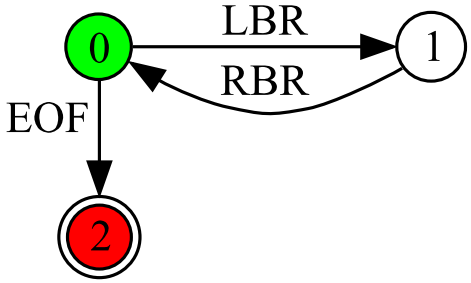

Грамматика

$$
\begin{array}{rcl}
\mathit{start} & ::= & s \\
s & ::= & \texttt{LBR}\ s\ \texttt{RBR}\ s \\
s & ::= & \epsilon
\end{array}
$$

Лес разбора

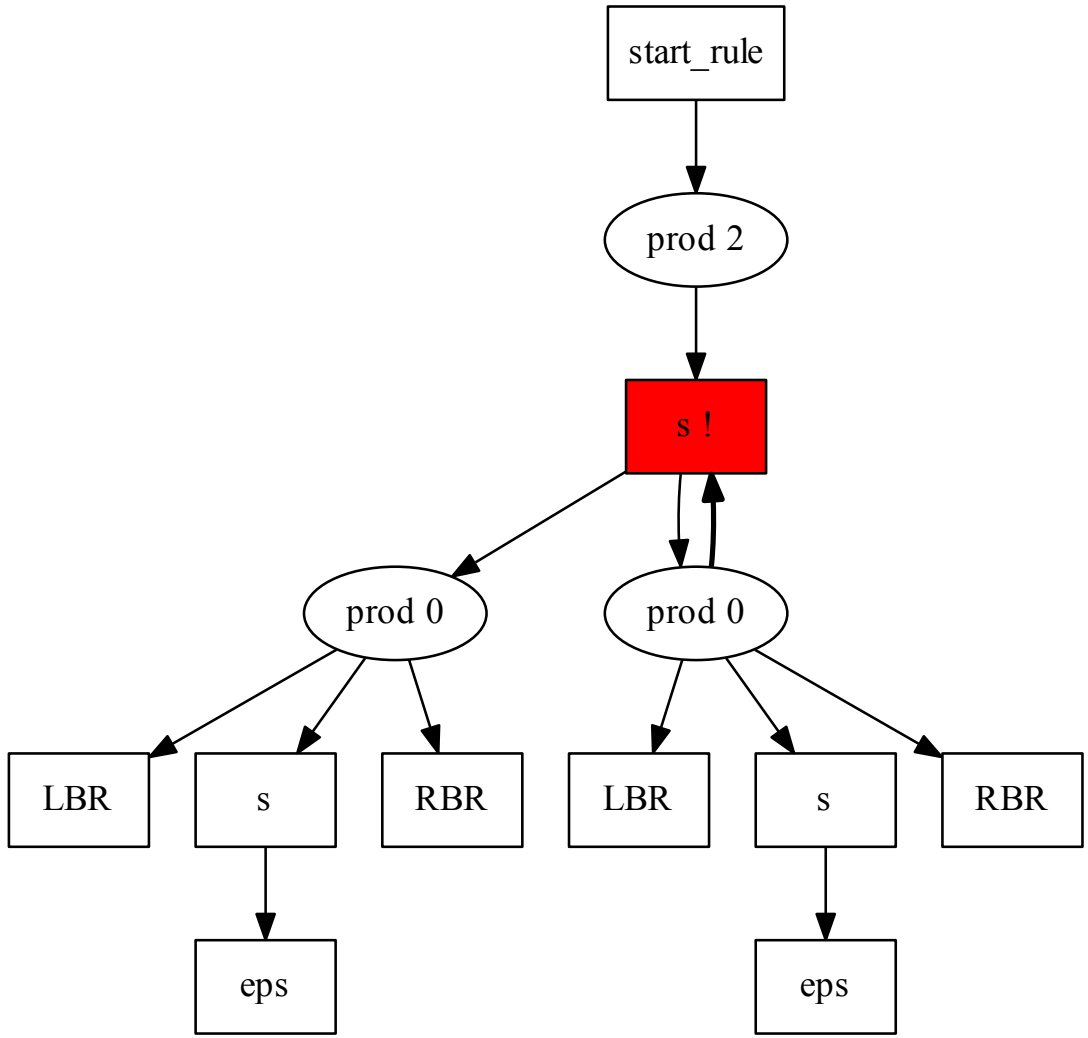

Постановка задачи

Цель: разработать алгоритм, подходящий для синтаксического анализа встроенного кода

- *Синтаксический анализ* — сопоставление каждого выражения из апроксимирующего языка с некоторой эталонной грамматикой и построение деревьев разбора

Постановка задачи

Задачи:

- Разработать алгоритм для синтаксического анализа регулярного языка, который строит конечный лес разбора
- Лес разбора должен содержать дерево разбора для каждой корректной строки из регулярного языка
- Диагностики ошибок не предусматривается: некорректные выражения игнорируются
- Алгоритм не должен зависеть от языков основной программы и встроенного кода

Алгоритм

- **Входные данные**
  - Эталонная КС грамматика G
  - Регулярный язык в виде графа ДКА без ϵ-переходов над алфавитом терминалов грамматики G
- **Результат**
  - Лес разбора всех корректных выражений, принимаемых входным автоматом

Right-Nulled Generalized LR алгоритм

- RNGLR обрабатывает произвольные KC грамматики
- Табличный синтаксический анализ
- В случае LR-конфликтов, продолжает обработку всех возможных вариантов
  - Shift/Reduce конфликт
  - Reduce/Reduce конфликт
- Использует специальные структуры данных, ограничивающие потребление памяти и гарантирующие полиномиальное время работы

Структуры данных: Graph-Structured Stack

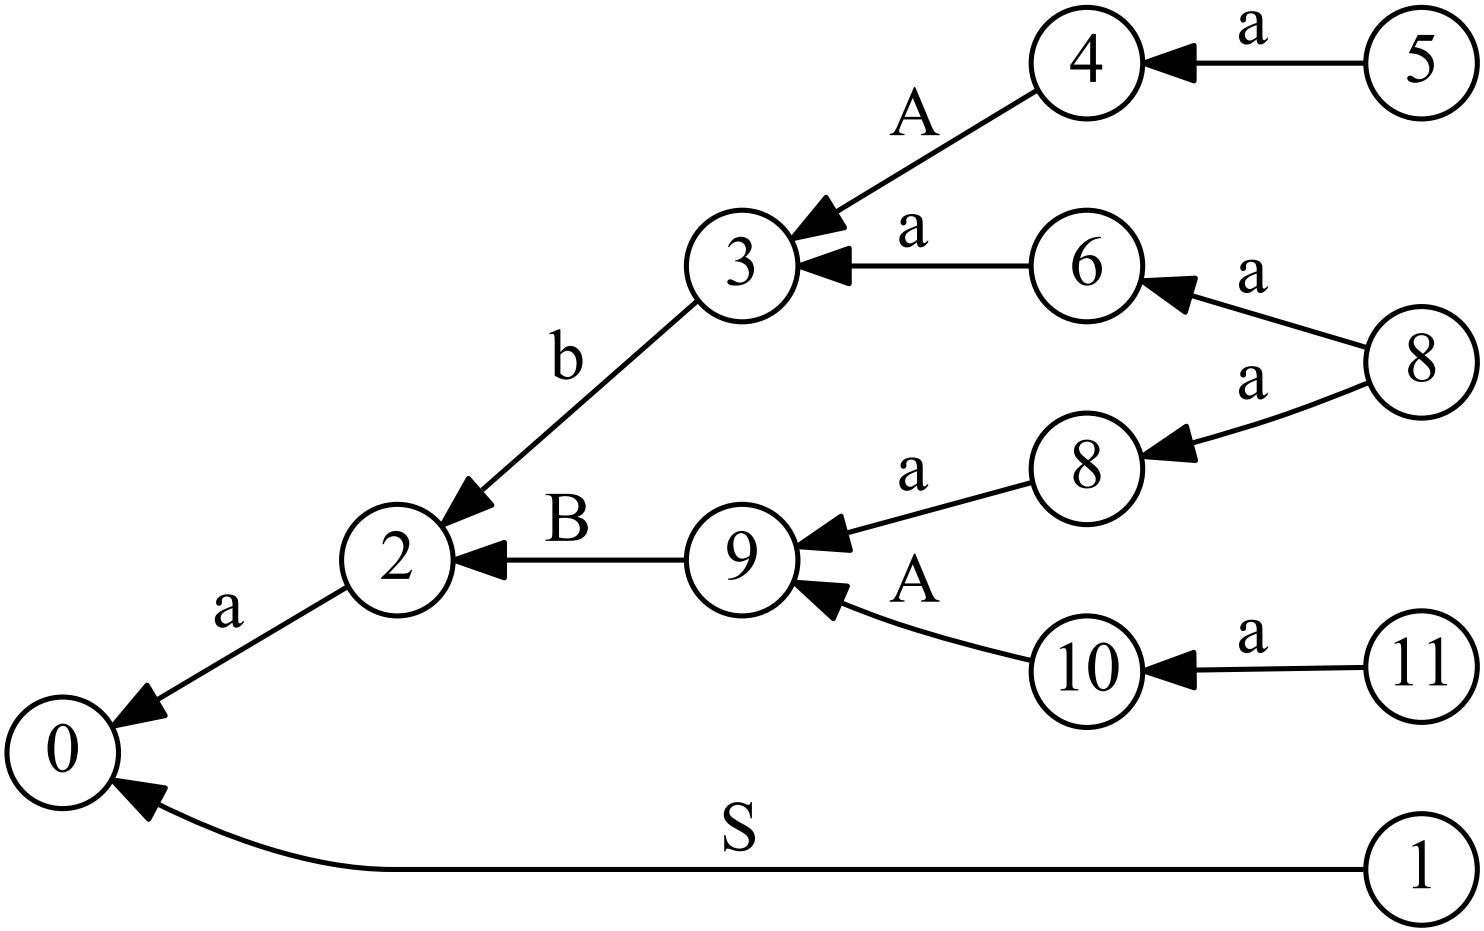

Операции в RNGLR-алгоритме: shift (сдвиг)

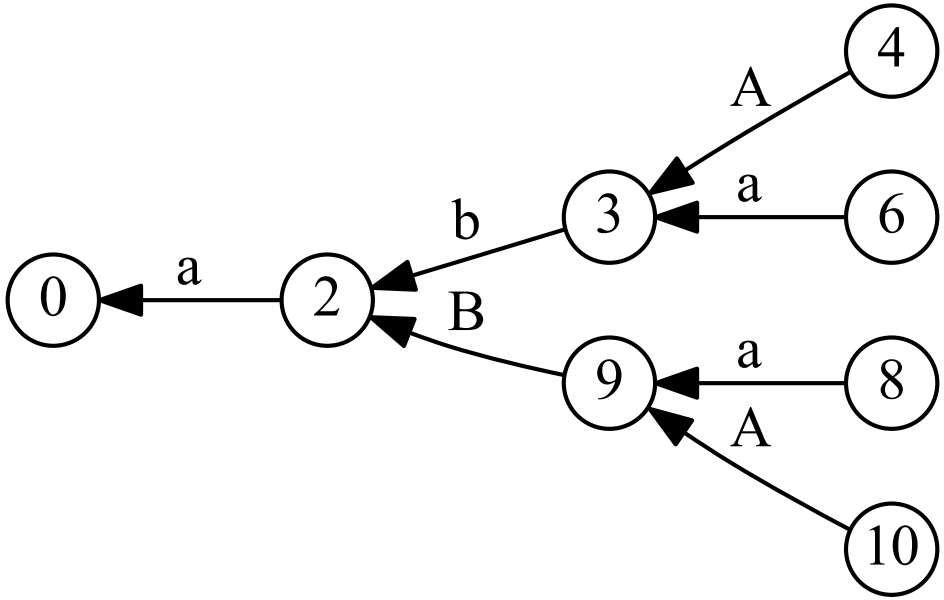

Операции в RNGLR-алгоритме: shift (сдвиг)

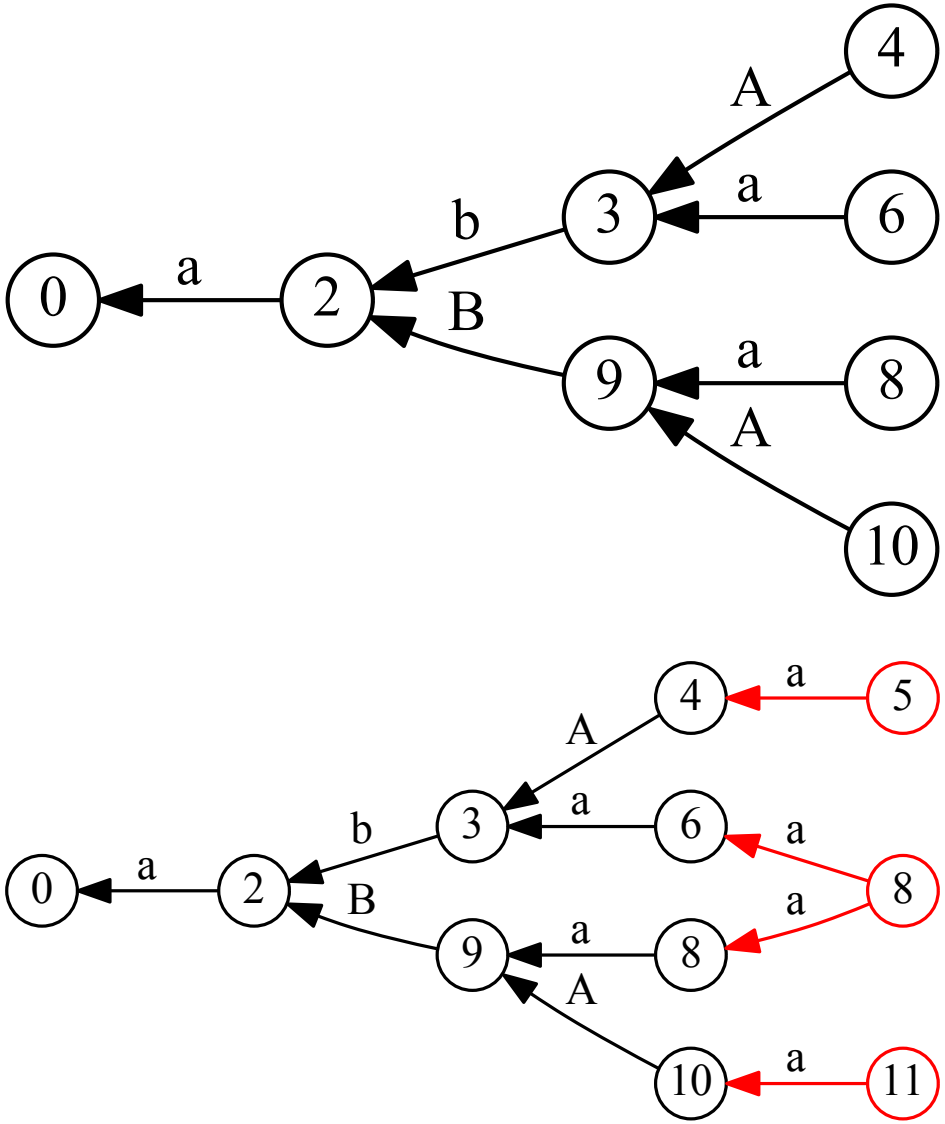

Операции в RNGLR-алгоритме: reduce (редукция или свертка)

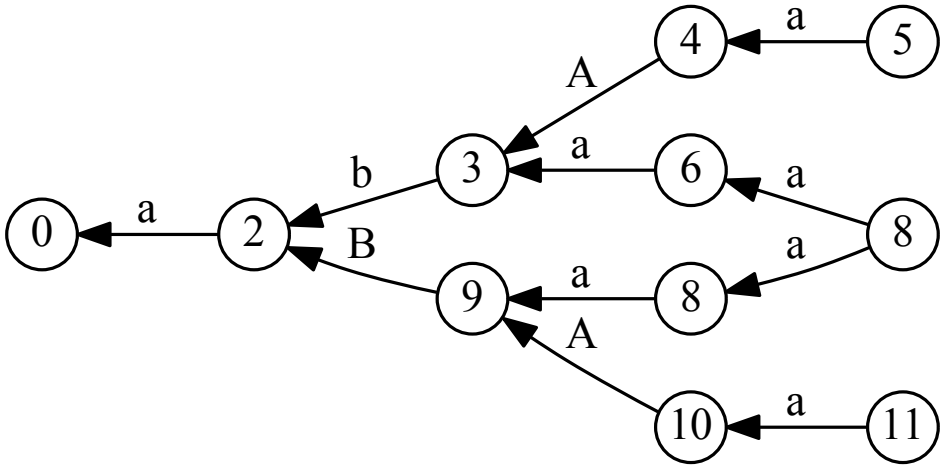

Операции в RNGLR-алгоритме: reduce (редукция или свертка)

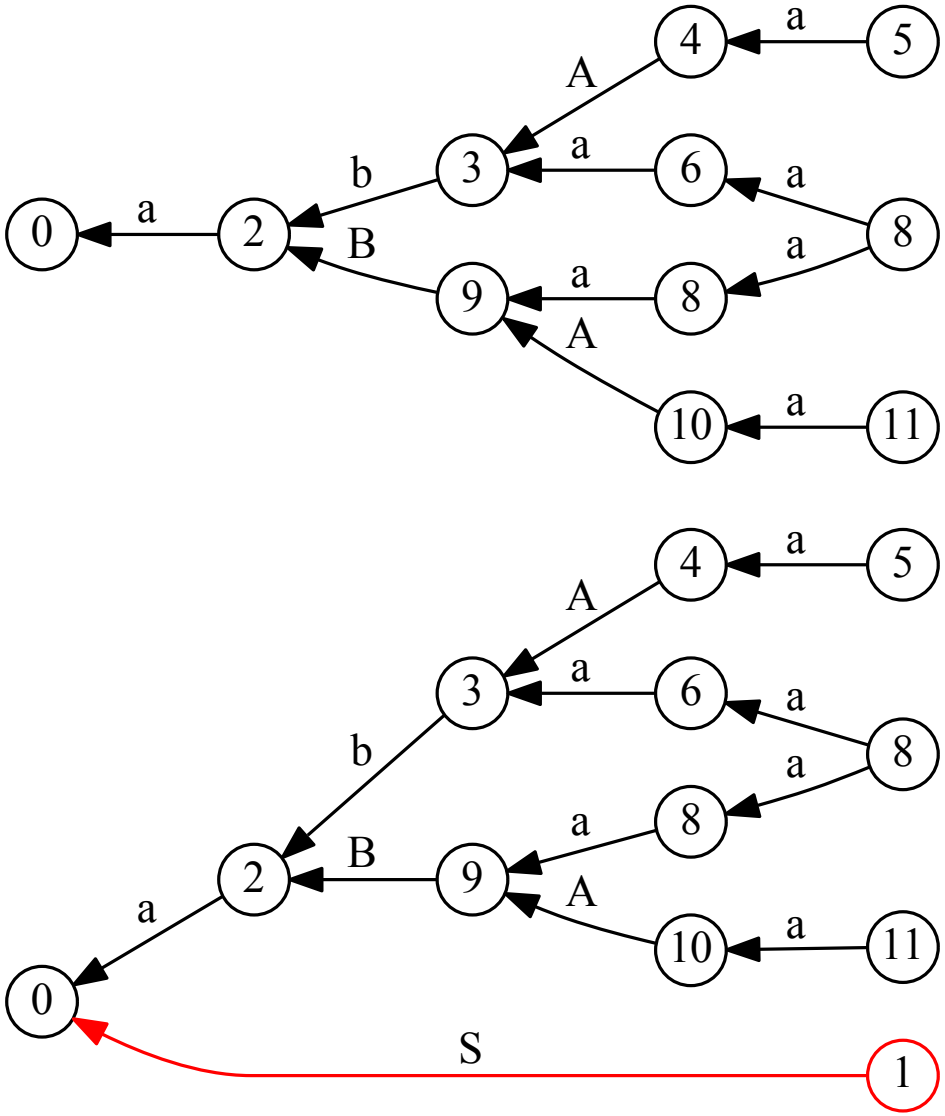

RNGLR

- Входной поток читается последовательно
  - Обработать все редукции
  - Сдвинуть следующий символ со входа
- При добавлении новой вершины в GSS вычисляется сдвиг
- При добавлении нового ребра — редукции

Алгоритм

- GSS строится последовательно во время обхода графа входного автомата, похожим образом, что в RNGLR
- Новый тип “конфликта”: Shift/Shift

- Множество LR-состояний ассоциируется с каждой вершиной входного графа
- Порядок, в котором обходятся вершины входного графа, определяется очередью. Каждый раз, когда ребро добавляется в GSS, его начальная вершина добавляется в очередь

- Обнаружения ошибок не производится, некорректные строки игнорируются

Обработка циклов: начальный стек

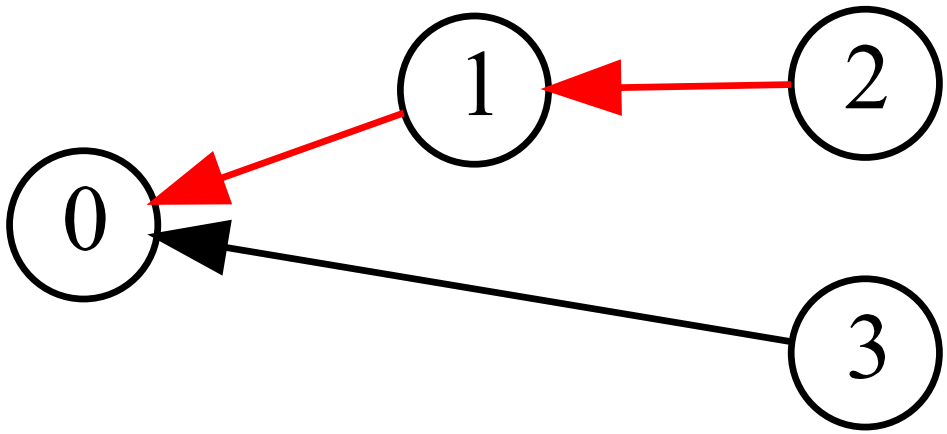

Обработка циклов: добавили несколько ребер

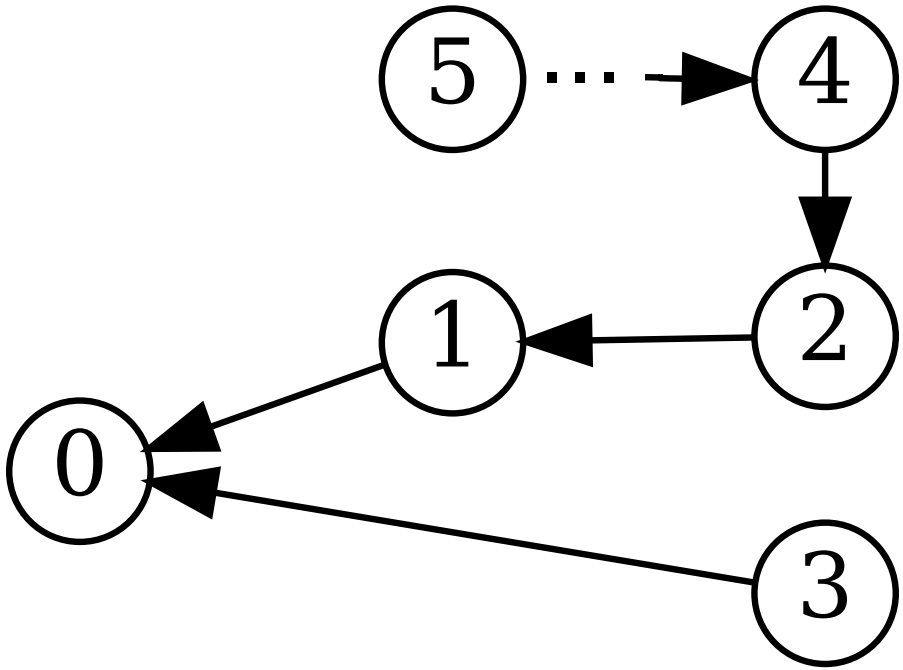

Обработка циклов: образовался цикл

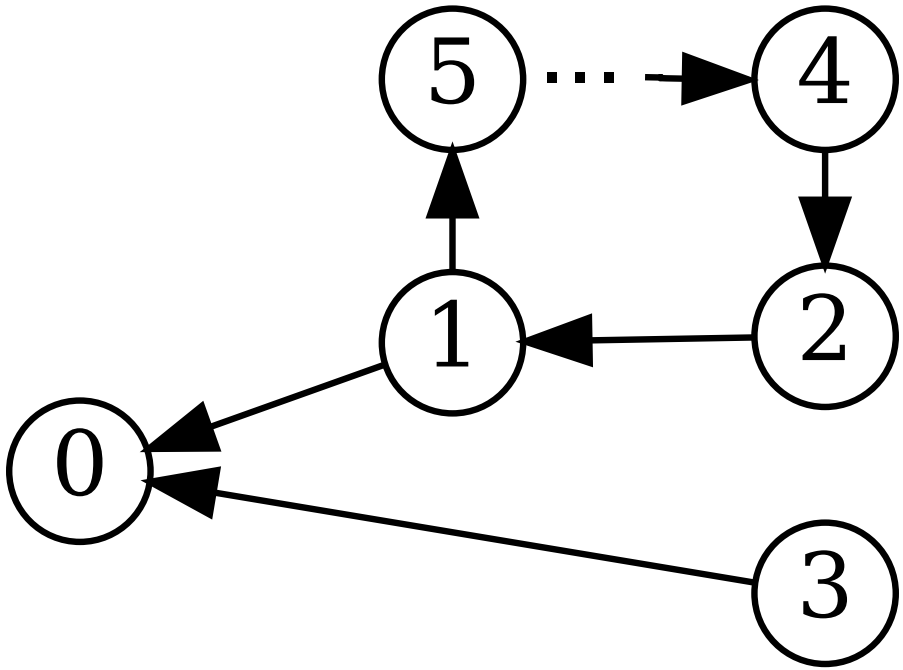

Обработка циклов: новая редукция

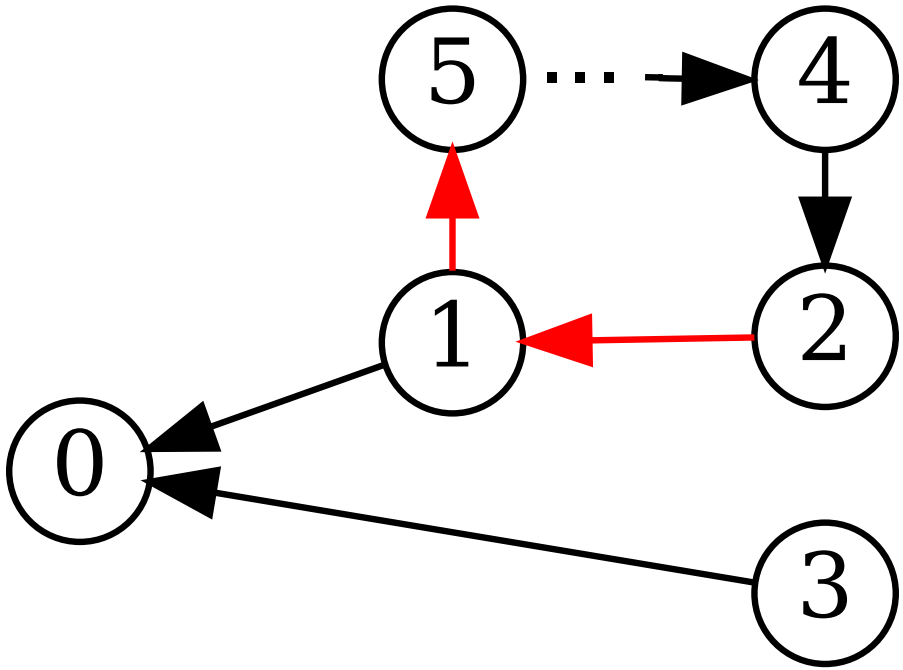

Обработка циклов: добавили новую редукцию

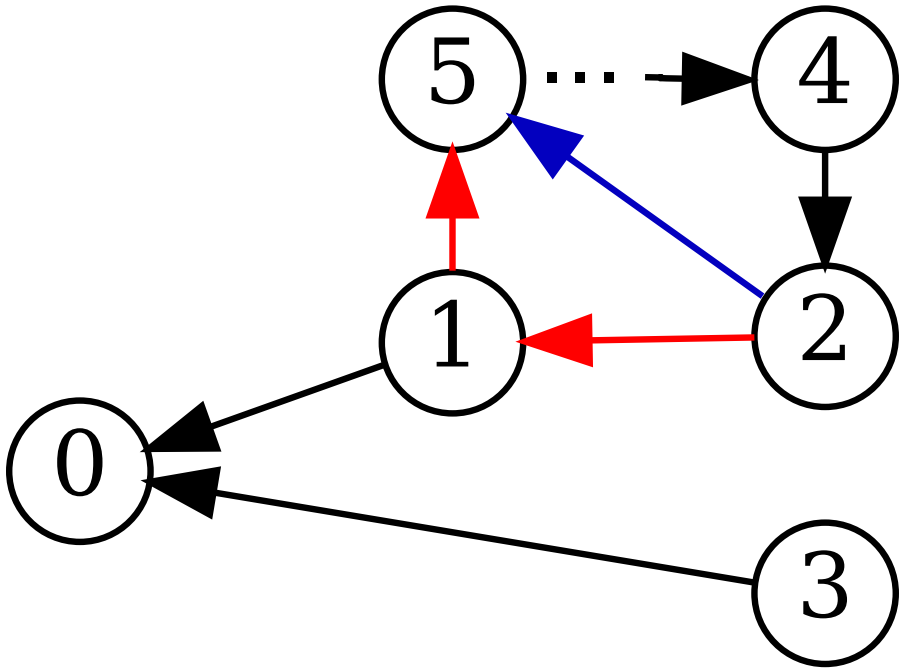

Построение леса разбора

- Shared Packed Parse Forest — граф, в котором объединено множество деревьев вывода
- Строится так же, как в RNGLR-алгоритме

- С каждым ребром GSS ассоциируется фрагмент дерева вывода
- При обработке shift, создается дерево из одной вершины, соответствующей терминалу
- При обработке reduce, создается дерево, детьми корня которого становятся деревья, ассоциированные с ребрами путей
  - Фрагменты деревьев переиспользуются, не копируясь
- Корень результирующего леса разбора ассоциирован с ребром GSS, соответствующим свертке к стартовому нетерминалу
  - Все недостижимые вершины удаляются из графа-леса

Корректность алгоритма

Корректное дерево — дерево вывода строки, накопленной вдоль некоторого пути во входном графе

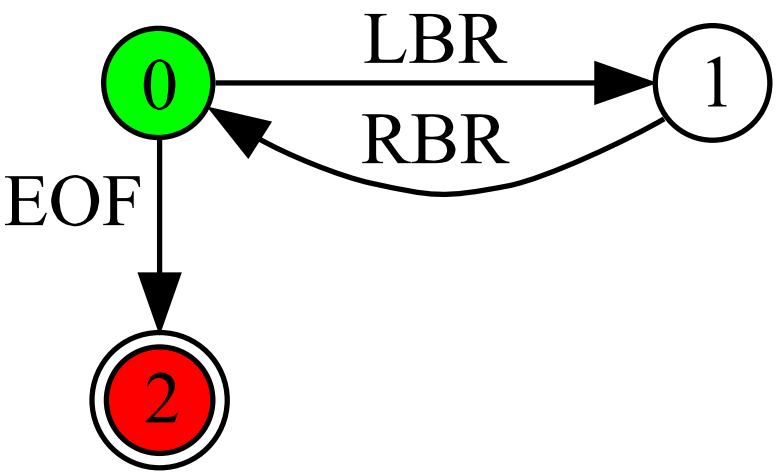

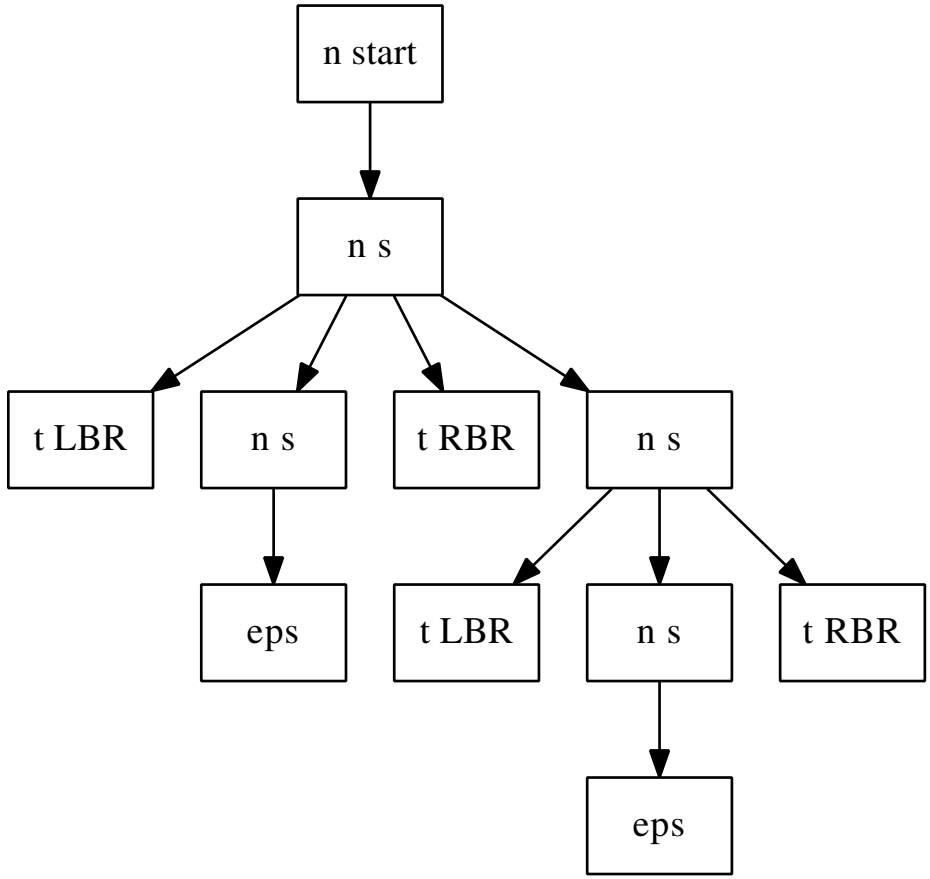

Алгоритм: корректность

Свойство (Завершаемость)

Алгоритм завершается при любом входе

Свойство (Корректность)

Каждое дерево, генерируемое из SPPF, корректно

Свойство (Корректность)

Для каждой строки из входного регулярного множества, корректной относительно эталонной грамматики, из SPPF можно извлечь корректное дерево

Реализация

- Алгоритм реализован как часть проекта YaccConstructor на языке программирования F#
- Генератор таблиц RNGLR и описание структур данных GSS и SPPF переиспользованы

Тестирование

- Данные взяли из промышленного проекта по миграции с MS-SQL на Oracle Server
- Всего 2,7 млн. строк кода, 2430 запросов, 2188 успешно обработаны
- С 45 до 1 сократилось количество необработанных запросов

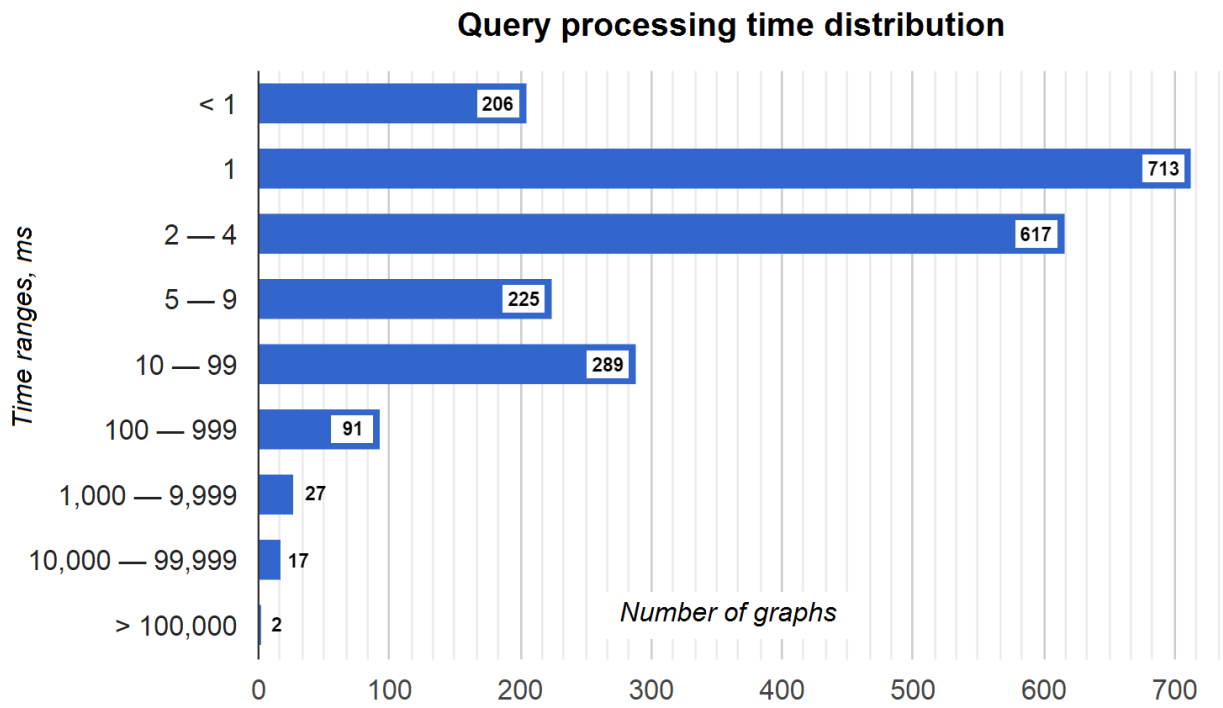

Заключение

- Разработан алгоритм синтаксического анализа регулярной аппроксимации динамически формируемых выражений, который строит конечное представление леса разбора
- Доказаны завершаемость и корректность алгоритма
- Алгоритм реализован как часть проекта YaccConstructor
  - `https://github.com/YaccConstructor/YaccConstructor`
- Продемонстрирована применимость алгоритма для решения сложных задач

Настоящее и будущее

- Обнаружение ошибок и сообщение о них
- Теоретическая оценка сложности
- Вычисление семантики над полученным лесом разбора
- Интеграция в плагин к ReSharper