Третья международная научно-практическая конференция: Инструменты и методы анализа программ, TMPA-2015
12–14 ноября, Санкт-Петербург

Лексический анализ динамически формируемых строковых выражений

Автор: Полубелова Марина

Санкт-Петербургский государственный университет

12 ноября 2015г.

Примеры

- Встроенный SQL в C#

```
private void Go (int cond){
string columnName = cond > 3 ? "X":(cond < 0 ? "Y":"Z");
string queryString =
                "SELECT name" + columnName + " FROM table";
Program.ExecuteImmediate(queryString);
}
```

- Динамически генерируемый HTML в PHP-программах

```
<?php
    $name = 'your name';
    echo '<table>
        <tr><th>Name</th></tr>
        <tr><td>'.$name.'</td></tr>
        </table>';
?>
```

Мотивация

Использование динамически формируемых строковых выражений:

- уменьшает надежность
  - нет статического поиска ошибок
- увеличивает уязвимость
  - SQL инъекции
  - межсайтовый скриптинг

Статический анализ программ

- Лексический анализ
- Синтаксический анализ
- Семантический анализ

Обзор существующих инструментов

- Проверка выражения на соответствие описанию некоторой эталонной грамматики
  - Java String Analyzer
  - PHP String Analyzer
  - Alvor
- Статический анализ программы на уязвимость
  - Pixy
  - Stranger
  - SAFELI

Генераторы лексических анализаторов

Автоматизированный способ создания лексических и синтаксических анализаторов:

- Lex
- Yacc и др.

Проект YaccConstructor

- YaccConstructor — модульный инструмент, предназначенный для проведения лексического анализа и синтаксического разбора
- YaccConstructor — платформа для поддержки встроенных языков

- Не поддерживаются циклы и строковые операции

Постановка задачи

Цель: разработать автоматизированный подход создания лексического анализатора для динамически формируемого кода

- разработать алгоритм лексического анализа выражений, формируемых с помощью строковых операций и циклов
- реализовать генератор лексических анализаторов
- сохранить привязку лексических единиц к исходному коду

Аппроксимация

- ```
  private void Go (int cond){
  string columnName = cond > 3 ? "X":(cond < 0 ? "Y":"Z");
  string queryString =
                  "SELECT name" + columnName + " FROM table";
  Program.ExecuteImmediate(queryString);
  }
  ```
- Множество значений:
  { "SELECT nameX FROM table"; "SELECT nameY FROM table";
  "SELECT nameZ FROM table"}
- Результат аппроксимации:

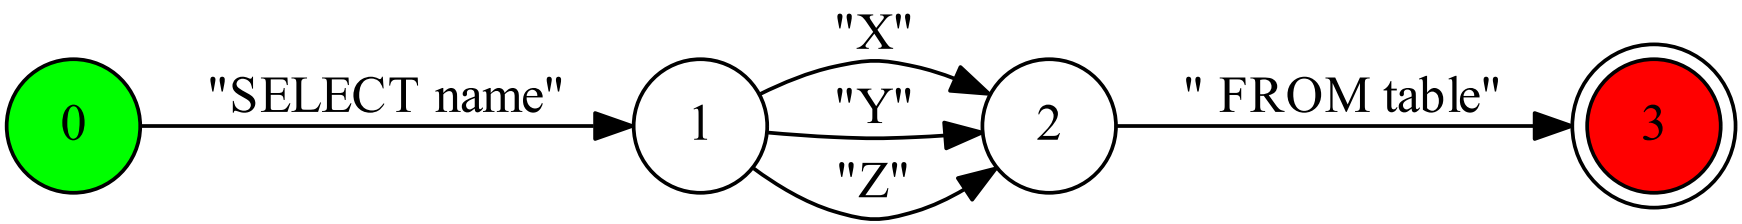
  ```

Лексический анализ строковых выражений

- На вход анализатору подается конечный автомат, полученный в результате аппроксимации множества значений строкового выражения
- На выходе получаем либо конечный автомат над токенами, либо список лексических ошибок. Токен содержит в себе:
  - идентификатор токена
  - конечный автомат, описывающий все возможные последовательности символов для данного токена

Задача лексического анализа: получение конечного автомата над алфавитом токенов эталонной грамматики из конечного автомата над алфавитом символов обрабатываемого языка

Пример

```
private void Go (int cond){
string columnName = cond > 3 ? "X":(cond < 0 ? "Y":"Z");
string queryString =
                "SELECT name" + columnName + " FROM table";
Program.ExecuteImmediate(queryString);
}
```

- Результат аппроксимации:

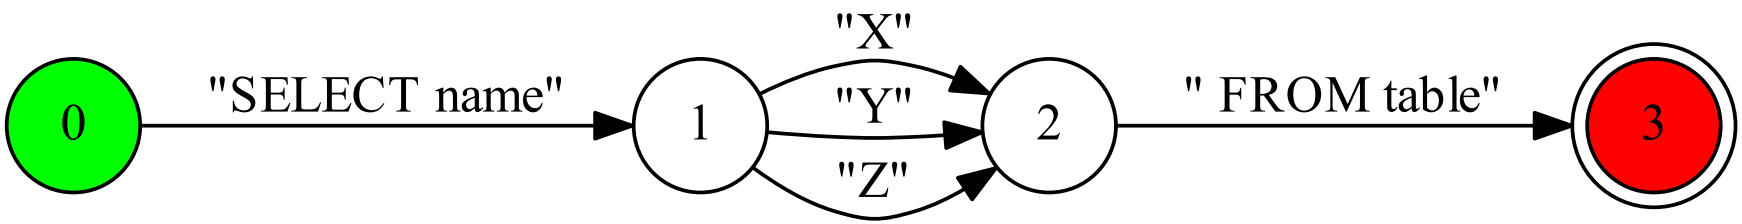

- Результат лексического анализа:

Пример

- Результат лексического анализа:

- Конечный автомат первого токена `IDENT`:

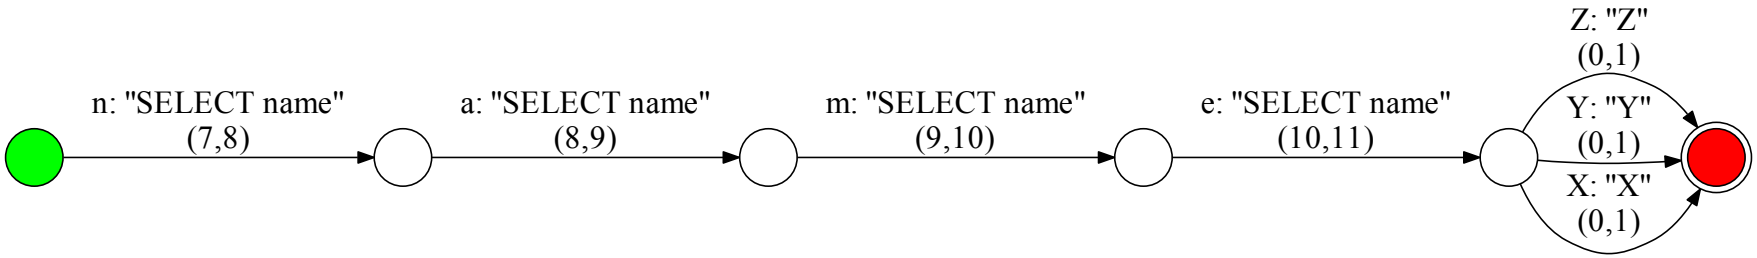

- Конечный автомат второго токена `IDENT`:

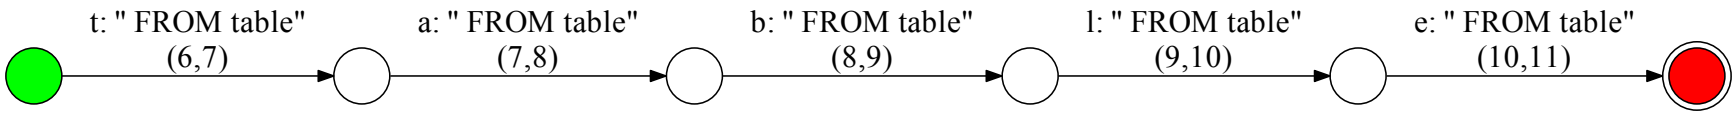

Конечный преобразователь

- **Конечный преобразователь** — это конечный автомат, который может выводить конечное число символов для каждого входного символа
- **Композиция** конечных преобразователей — это два последовательно взаимодействующих конечных преобразователя: выход первого конечного преобразователя является входом для второго конечного преобразователя

Генератор лексических анализаторов

Вход:

- Лексическая спецификация языка

```
let digit = ['0'-'9']
let whitespace = [' ' '\t' '\r' '\n']
let num = ['-']? digit+ ('.'digit+)? (['e' 'E'] digit+)?
```

FsLex

```
rule token = parse
| whitespace  token lb
| num  { NUMBER(lexeme lb) }
| '-'  { MINUS(lexeme lb) }
| '/'  { DIV(lexeme lb) }
| '+'  { PLUS(lexeme lb) }
| "**" { POW(lexeme lb) }
| '*'  { MULT(lexeme lb) }
```

YaccConstructor

```
rule token = parse
| whitespace { None }
| num  { Some(NUMBER(gr)) }
| '-'  { Some(MINUS(gr)) }
| '/'  { Some(DIV(gr)) }
| '+'  { Some(PLUS(gr)) }
| "**" { Some(POW(gr)) }
| '*'  { Some(MULT(gr)) }
```

- Описание токенов

Выход: Описание конечного преобразователя и вспомогательные функции

Алгоритм лексического анализа

- **Этап 0**.
  Вход: конечный автомат, полученный в результате построения аппроксимации
  Выход: конечный преобразователь, построенный из входного конечного автомата

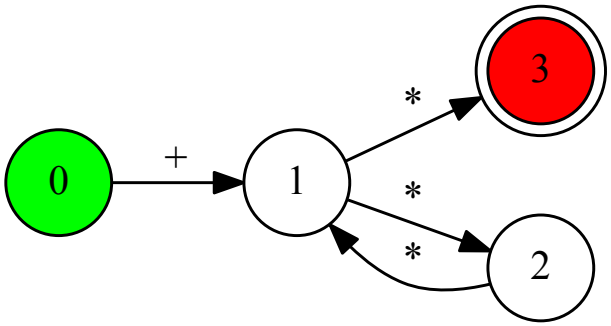

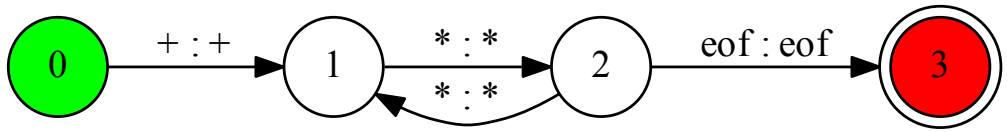

Алгоритм лексического анализа

- **Этап 1.**
  Вход:
  - конечный преобразователь, полученный на Этапе 0
  - конечный преобразователь, полученный из описания, построенного генератором лексических анализаторов

  Выход: конечный преобразователь над алфавитом токенов и набор лексических ошибок

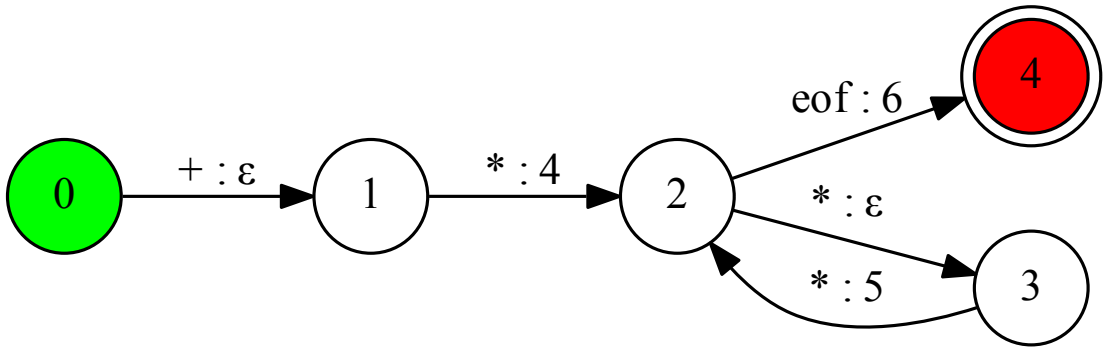

Алгоритм лексического анализа

- **Этап 2**. Интерпретация конечного преобразователя
  Вход: конечный преобразователь, полученный на Этапе 1
  Выход: конечный автомат над алфавитом токенов эталонной грамматики

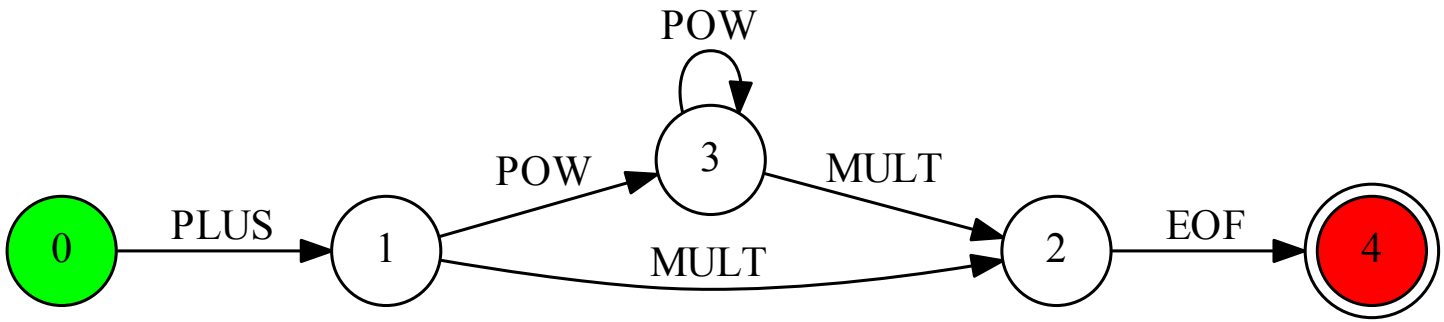

Архитектура инструмента

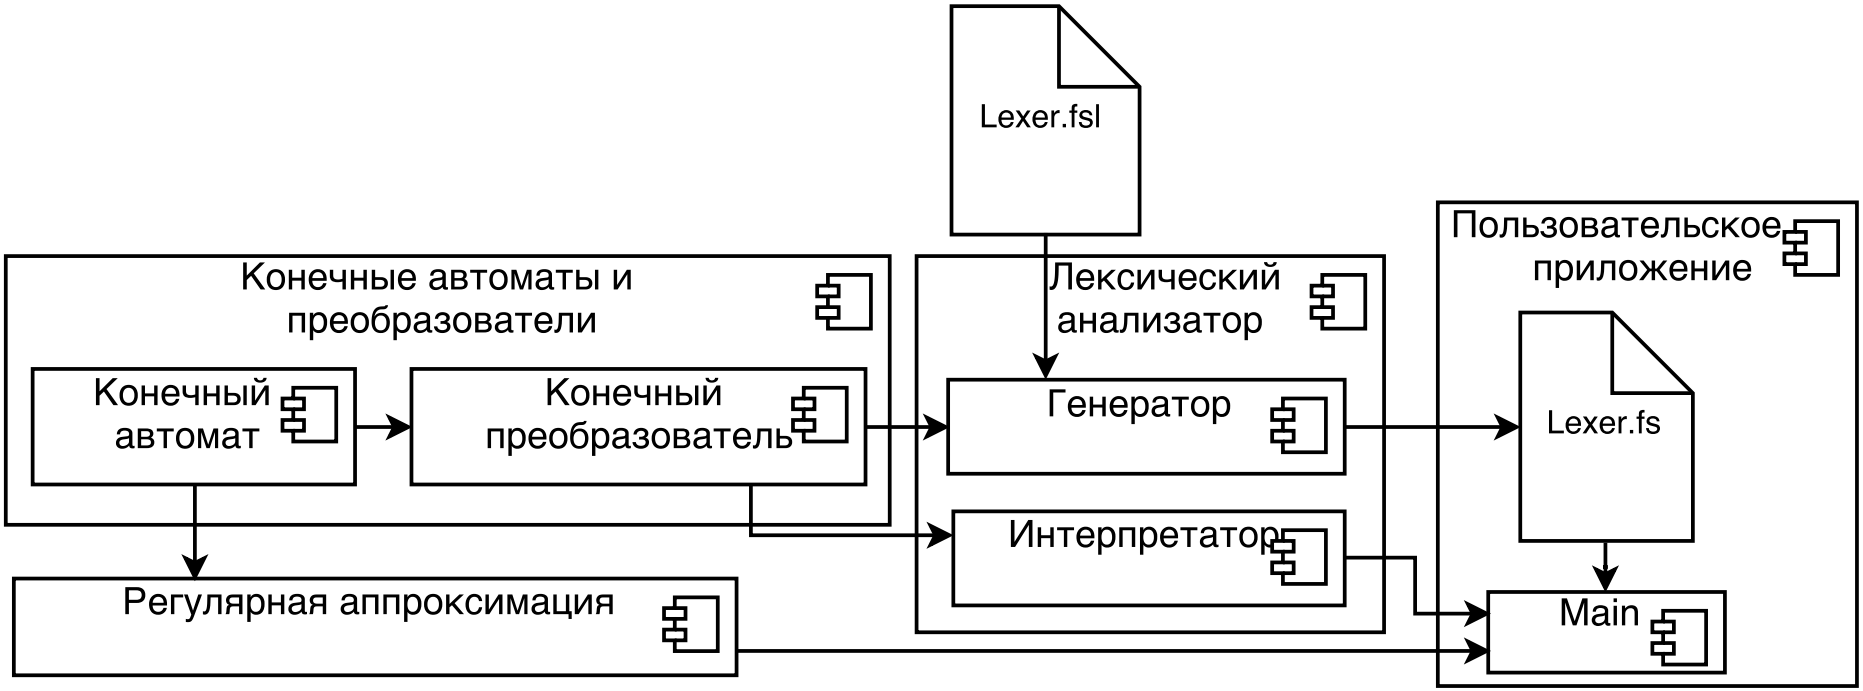

Пример 1

- ```
  private void Go (int number){
  string query =
            "SELECT nameX FROM tableY WHERE x < ";
  while(query.Length < number){ query += "+ 1 ";}
  Program.ExecuteImmediate(query);
  }
  ```
- Результат аппроксимации:

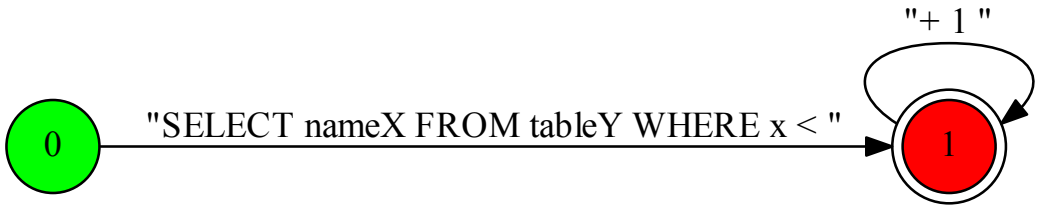

- Результат лексического анализа:

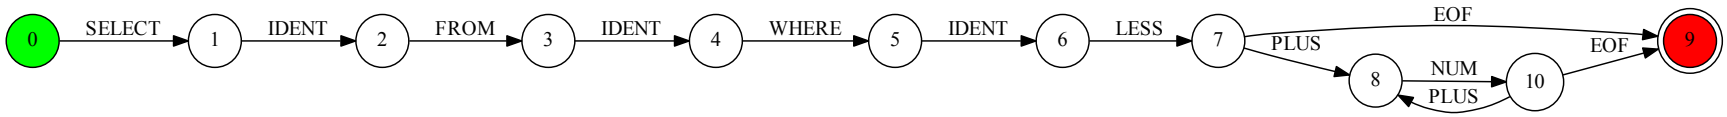
  ```

Пример 2

- ```
  string query = "SELECT name";
  for(int i = 0; i < 10; i++){ query += "X";}
  query += " FROM tableY";
  Program.ExecuteImmediate(query);
  ```
- Результат лексического анализа:

- Конечный автомат первого токена IDENT:

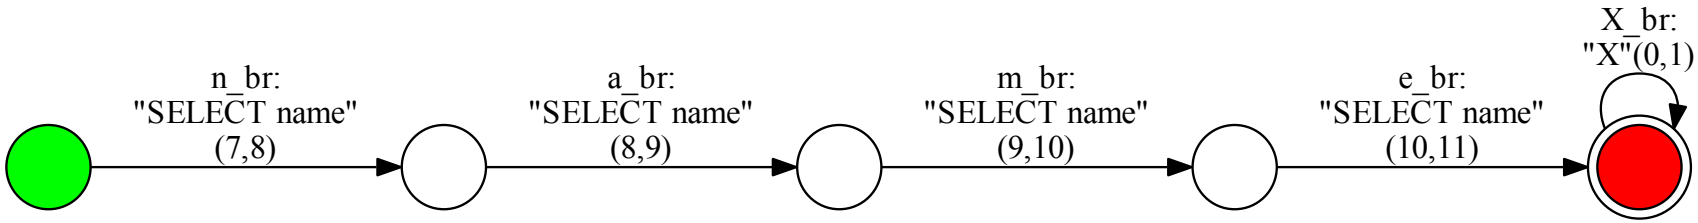
  ```

Результаты

В рамках данной работы были получены следующие результаты:

- Разработан алгоритм лексического анализа выражений, формируемых с помощью строковых операций и циклов
- Реализован генератор лексических анализаторов на основе предложенного алгоритма

Область применения

- Реинжиниринг программного обеспечения
  - Анализ и трансформация систем, использующие строковые выражения
- Поддержка строковых выражений в IDE
  - Статический поиск ошибок
  - Подсветка синтаксиса
  - Рефакторинг

Контактная информация

- Полубелова Марина: polubelovam@gmail.com
- Григорьев Семён: Semen.Grigorev@jetbrains.com

- Исходный код YaccConstructor: https://github.com/YaccConstructor