Поддержка расширенных контекстно-свободных грамматик в алгоритме синтаксического анализа Generalised LL

Автор: Горохов Артем Владимирович, 471 гр.
Научный руководитель: к.ф.-м.н., доцент Григорьев С.В.
Рецензент: программист СУИ НИУ ИТМО Авдюхин Д.А.

Санкт-Петербургский Государственный Университет

9 июня 2017

Биоинформатика

- Множество задач, связанных с обработкой и пониманием биологических данных
- Геном — длинная последовательность нуклеотидов
- На деле строка над алфавитом {A, C, G, T}

Получение данных

- Из биологического материала читаются короткие строчки
- Эти кусочки склеиваются в более длинные строки
- Множество строчек — сборка
- Данных очень много, поэтому строится конечный автомат, пути в котором содержат полученные строки

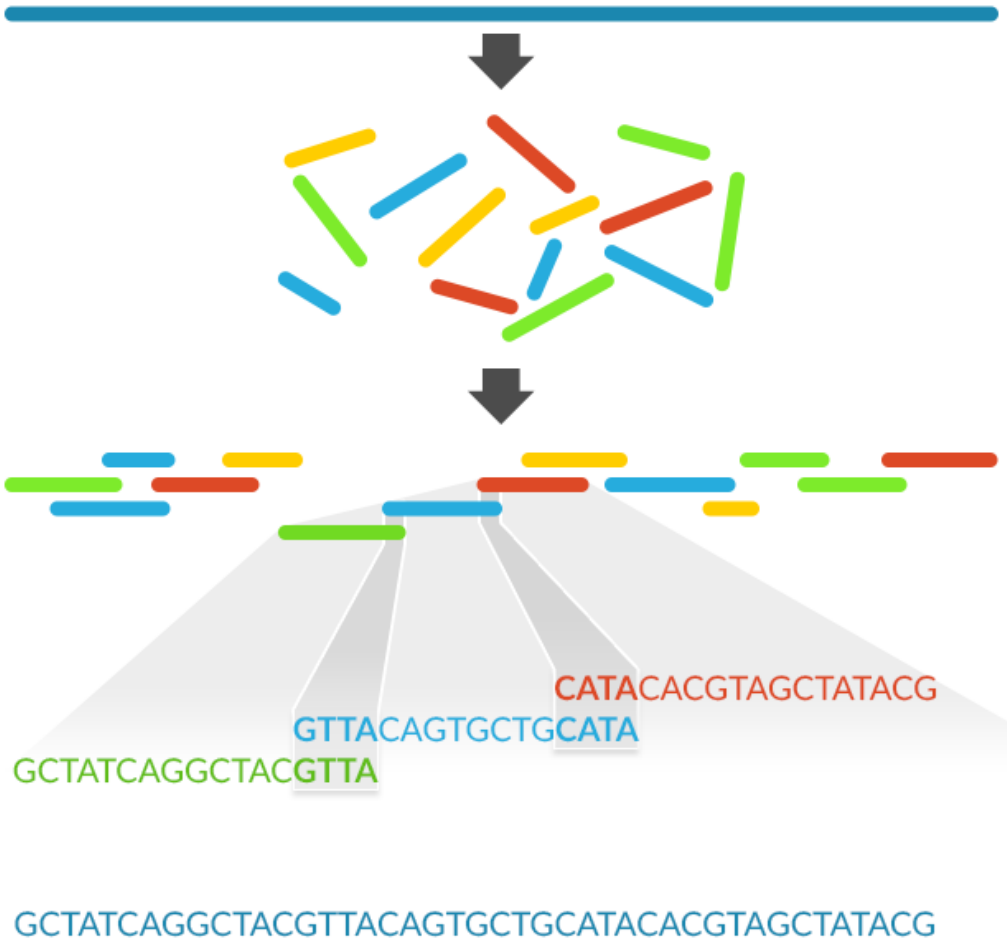

Метагеномная сборка

- В сборке геномы различных организмов
- Нужно уметь определять содержащиеся в сборке огранизмы

Как ищем

- Такие последовательности как тРНК, 16s-рРНК позволяют провести классификацию организма
- Данные последовательности имеют общую вторичную структуру, которая может быть описана КС-грамматикой

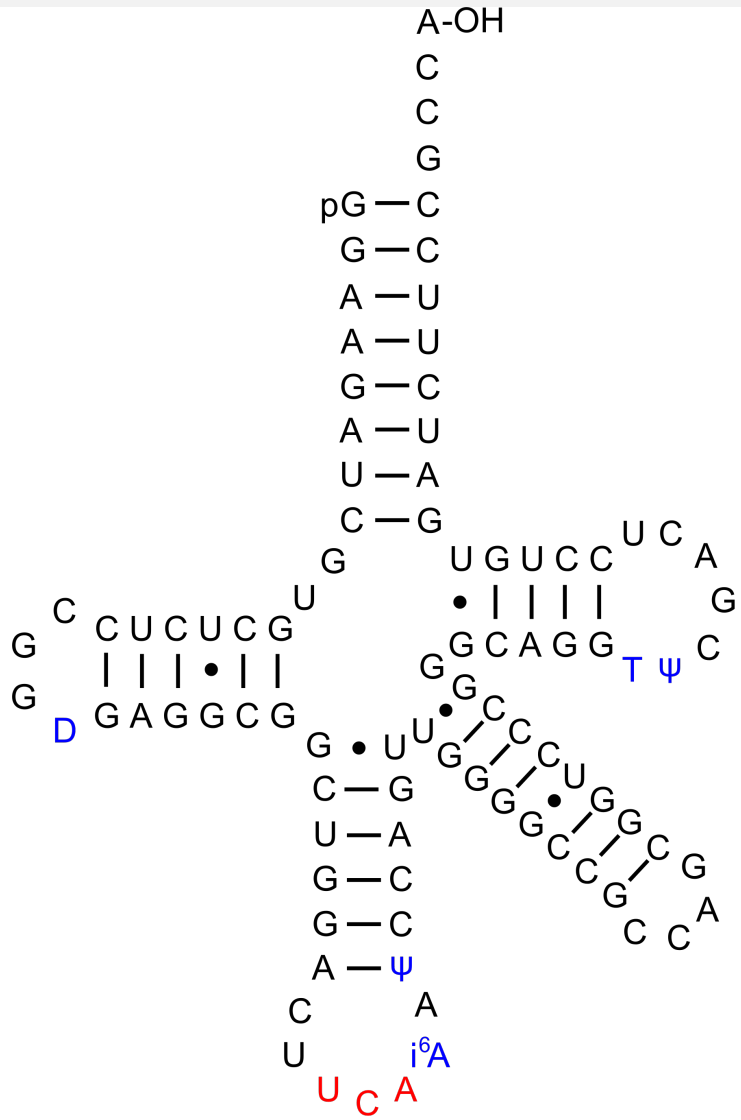

Рис.: Структура тРНК

Существующее решение

- В магистерской прошлого года реализован алгоритм синтаксического анализа регулярных множеств
  - Основан на алгоритме Generalised LL
  - Умеет решать задачу поиска цепочек в конечном автомате, удовлетворяющих KC-грамматике
  - Реализован в рамках проекта кафедры системного программирования YaccConstructor

Расширенные контекстно-свободные грамматики

В правых частях продукций регулярные выражения

$$
\begin{aligned}
S &= a\ M^* \\
M &= a?\ (B\ K)^+ \\
&\mid u\ B \\
B &= c \mid \varepsilon
\end{aligned}
$$

Обзор

- Теоретические работы о синтаксическом анализе ECFG
  - L. Breveglieri, S. Crespi Reghizzi, A. Morzenti (2014). ELR parsing
  - K. Hemerik.(2009) ECFG and RRPG Parsing
- Описываются лишь LL(k), LR(k) подходы
- Работать с LL проще чем с LR
- Нет инструментов допускающих произвольные ECFG
- **Generalised LL**
  - Допускает произвольные CFG (включая неоднозначные)
  - Не может использовать ECFG без преобразований

Цель и задачи

Цель работы: разработать и реализовать модификацию алгоритма GLL, работающую с расширенными контекстно-свободными грамматиками, и проверить, как полученный алгоритм влияет на производительность поиска структур, заданных с помощью контекстно-свободной грамматики в метагеномных сборках. Для её достижения были поставлены следующие задачи:

- Выбрать или разработать подходящее представление ECFG
- Спроектировать структуру данных для представления леса разбора по ECFG
- Разработать алгоритм на основе Generalised LL, строящий лес разбора по ECFG
- Разработать механизм анализа регулярных множеств в алгоритме
- Реализовать алгоритм в рамках проекта YaccConstructor
- Провести экспериментальное сравнение реализованного алгоритма с существующим в проекте YaccConstructor при анализе метагеномной сборки

Автоматы и ECFG

Грамматика G_0

$$S = a^* S\ b? \mid c$$

$\Longrightarrow$

RA для грамматики G_0

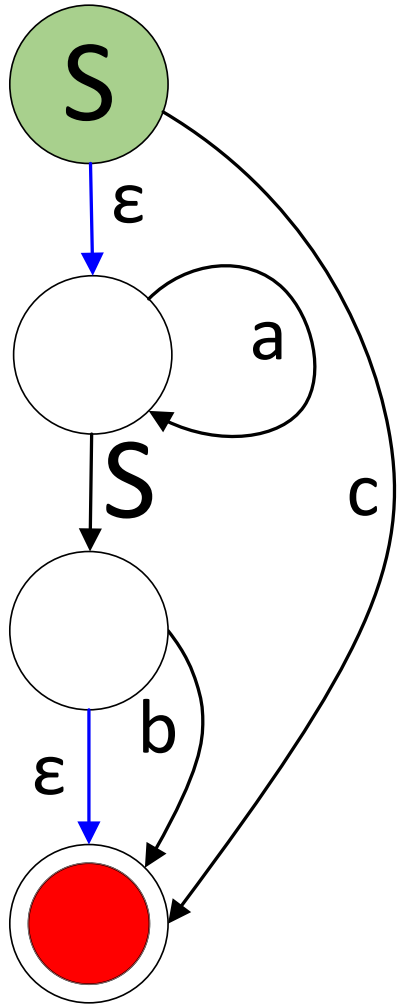

Минимизация рекурсивных автоматов

Грамматика G_1

$$S = K\ K\ K\ K\ K\ K \mid K\ a\ K\ K\ K\ K$$
$$K = S\ K \mid a\ K \mid a$$

Автомат для G_1

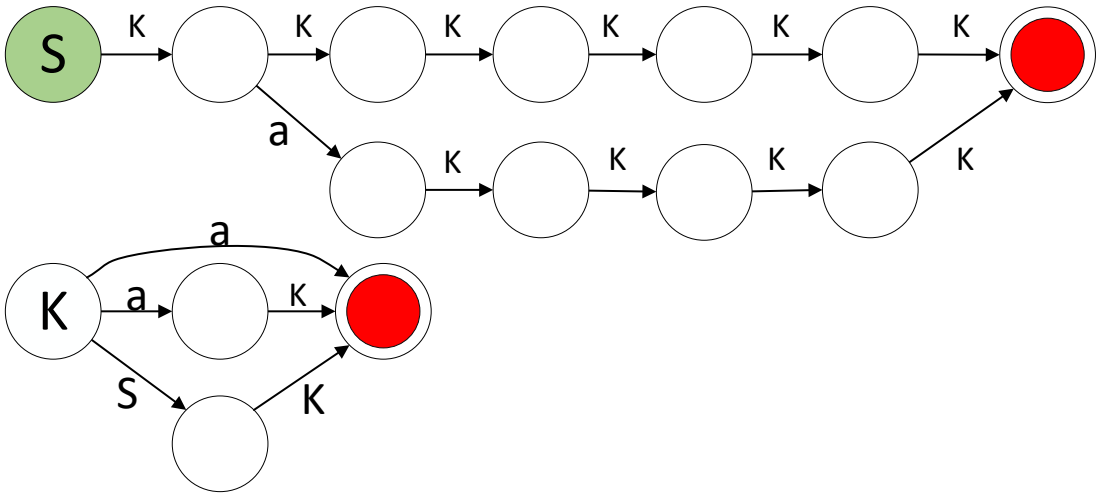

Минимизированный автомат для G_1

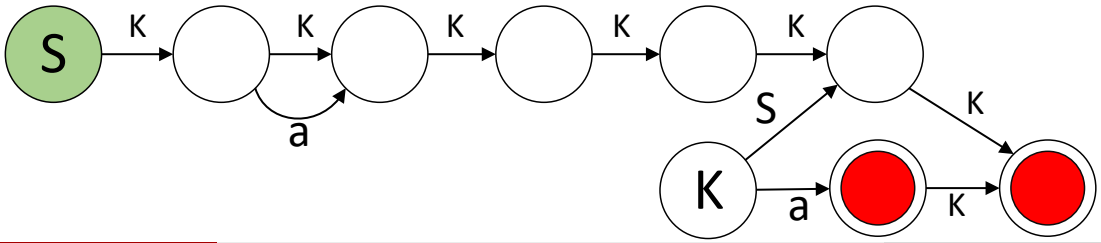

Деревья вывода для рекурсивных автоматов

Вход:

aacb

Автомат:

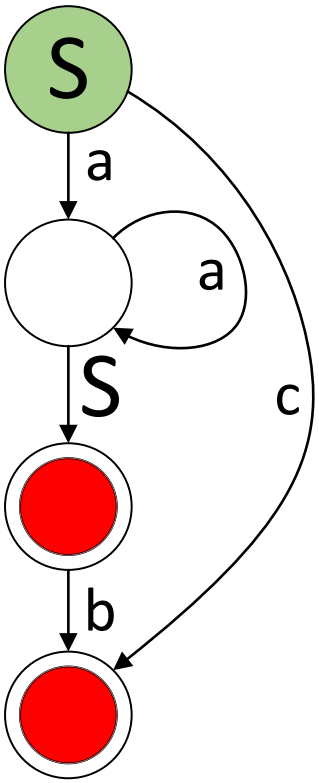

Деревья вывода:

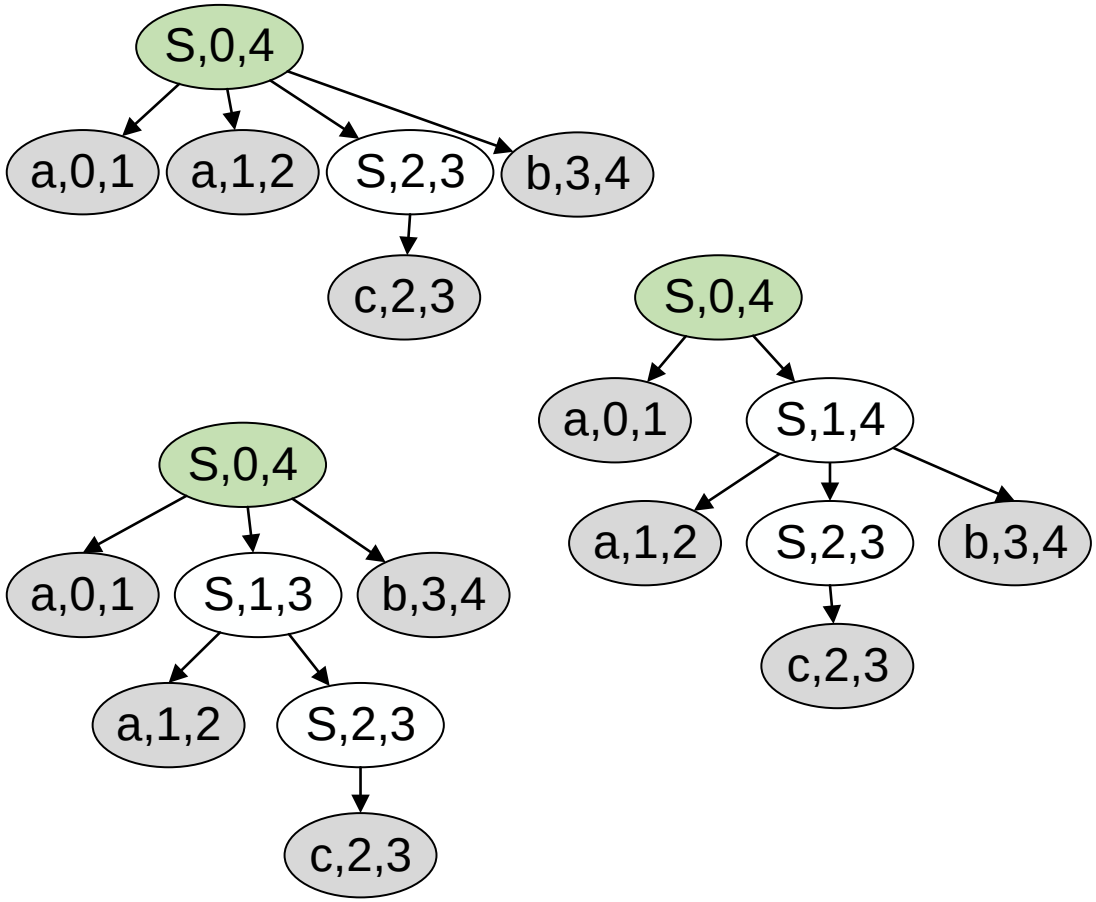

Разработанный алгоритм

- Основан на Generalised LL
  - Определено сжатое представление леса разбора(SPPF) для рекурсивных автоматов
  - Поддержаны рекурсивные автоматы вместо грамматик
- Поддержан механизм анализа регулярных множеств
- Реализован в рамках проекта кафедры системного программирования YaccConstructor

Эксперименты

Грамматика G_1

$$S = K(\ K\ K\ K\ K\ K \mid a\ K\ K\ K\ K)$$
$$K = S\ K \mid a\ K \mid a$$

Результаты для входа a^{450}

	Время	Память,Мб
Гамматика	10мин.13с.	11818
RA	5мин.51с.	8026
Ratio	43%	33 %

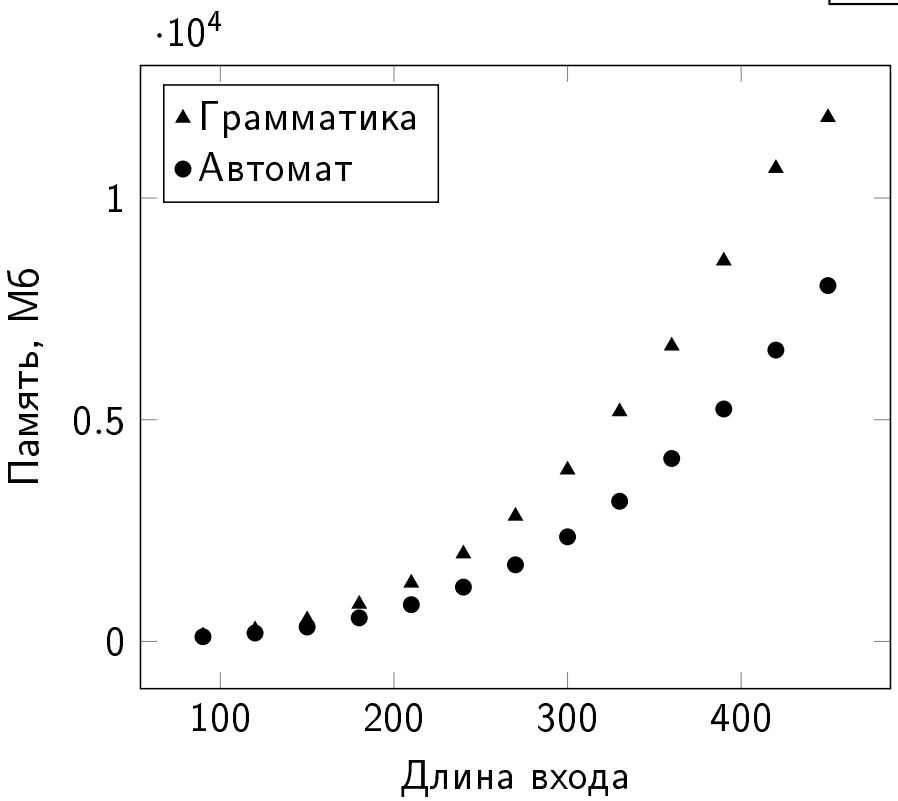

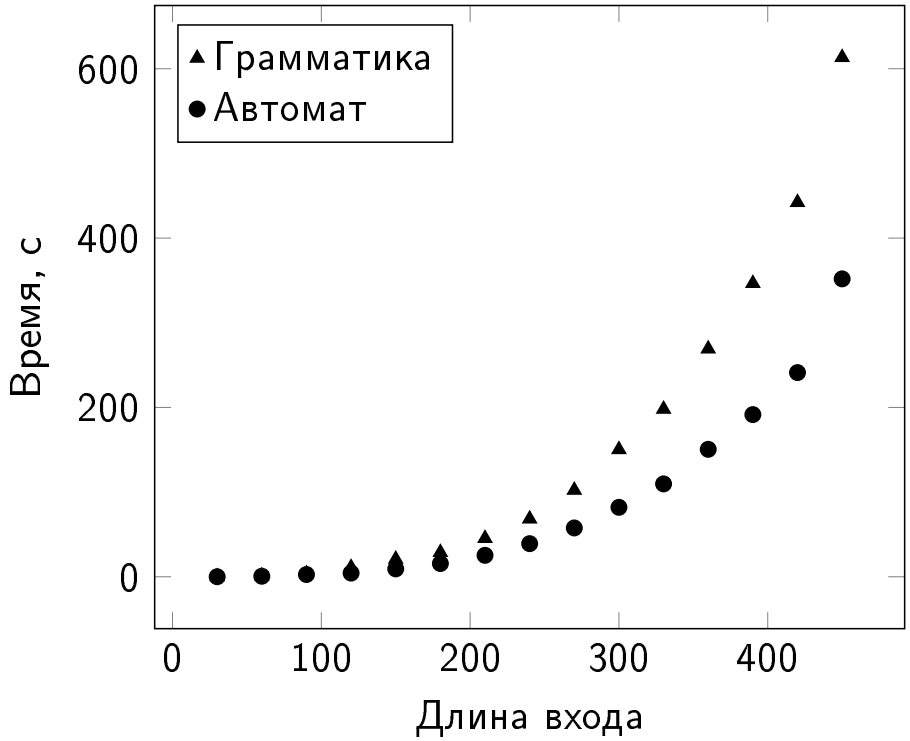

Поиск в метагеномных сборках

- Были проведены эксперименты на метагеномной сборке
- 10 компонент с 400-100 состояний и переходов и 1118 компонент с менее чем 100 состояний и переходов

	Память	Время
Существующее решение	27 Гб	02.26 мин
Предложенное в данной работе	10 Гб	01.25 мин
Ratio	63 %	45 %

Результаты

- В качестве подходящего представления ECFG предложены рекурсивные автоматы
- Определён SPPF для ECFG
- Разработан алгоритм на основе GLL, строящий SPPF по ECFG
- Разработан механизм анализа регулярных множеств в алгоритме
- Алгоритм реализован в рамках проекта YaccConstructor
- Эксперименты показали двухкратный прирост производительности по сравнению с существующим решением
- Выступление на международной конференции “Tools and Methods of Program Analysis”(Москва, 2017г.)