Синтаксический анализ графов и задача генерации строк с ограничениями

Рустам Азимов, Семён Григорьев
Лаборатория языковых инструментов JetBrains,
Санкт-Петербургский государственный университет,
Россия, 199034, Санкт-Петербург, Университетская наб. 7/9/
rustam.azimov19021995@gmail.com, Semen.Grigorev@jetbrains.com

Аннотация

Одной из задач, изучаемых в теории формальных языков, является задача генерации строк, удовлетворяющих заданной системе правил. С другой стороны, существует задача синтаксического анализа графов, то есть задача поиска путей в графе, метки на ребрах которых образуют строку, принадлежащую заданному формальному языку. В данной работе будет показана связь между этими двумя задачами.

Ключевые слова: синтаксический анализ графов, генерация строк, формальные языки, конъюнктивные грамматики.

В таких областях, как графовые базы данных [5, 8], биоинформатика [1], возникают задачи поиска путей в графах, удовлетворяющих определенным ограничениям. В качестве таких ограничений естественно выбрать формальный язык L [2] и искать пути в графе, соответствующие строкам из языка L. Задачи поиска путей в графе, которые используют такие ограничения с формальными языками, называются задачами *синтаксического анализа графов*. Данная задача также возникает при статическом анализе динамически формируемого кода, например динамических SQL-запросов или генераторов Web-страниц. В данном случае графом является представление регулярной аппроксимации множества возможных значений динамически формируемых строк.

Кроме того, существует задача генерации строк, суть которой в построении строк, принадлежащих некоторому формальному языку. В работе [9] приведены формулировки задачи генерации строк с дополнительными ограничениями.

Некоторые вариации задач синтаксического анализа графов могут быть сведены к задаче генерации строк. Так, например, в большинстве задач синтаксического анализа графов недостаточно просто определить существование пути, соответствующего строке некоторого формального языка L, но также требуется предъявить такой путь. Так как все пути в графе соответствуют строкам из некоторого регулярного языка R, то в данной задаче

требуется найти путь, соответствующий строке из языка $L \cap R$. Эта задача может быть решена с помощью генератора строк рассматриваемого пересечения языков. В рамках данной работы была поставлена задача исследования связей между задачей генерации строк [9] и некоторыми типами задач синтаксического анализа графов [3, 4], использующие контекстно-свободные и конъюнктивные [6] языки.

Язык, который порождается графом G и выделенными в нем вершинами m, n, обозначим $L(G, m, n)$. А язык, порождаемый грамматикой C, со стартовым нетерминалом a обозначим $L(C, a)$.

В контексте задач синтаксического анализа графов бывает необходимо отвечать на различного рода вопросы, связанные с искомыми в графе путями. Тип вопросов, на которые отвечает задача принято называть *семантикой запроса*.

Использование *relational* семантики запроса означает, что для нетерминала a и графа G необходимо построить множество $\{(m, n) | L(C, a) \cap L(G, m, n) \neq \emptyset\}$. В случае использования КС-языка было выявлено отсутствие необходимости в применении генератора строк для поиска ответа на запрос с *relational* семантикой, так как в работе [4] используется аннотированная грамматика, которая порождает язык $L(C, a) \cap L(G, m, n)$ и ее построение автоматически решает поставленную задачу.

Использование *all-path* семантики запроса означает, что для нетерминала a, графа G и его вершин m, n, необходимо предъявить все пути из вершины m в вершину n, такие что метки на ребрах этих путей образуют строку из языка $L(C, a)$. В случае использования КС-языка также было выявлено отсутствие необходимости в применении генератора строк для данной семантики, так как в работе [4] аннотированную грамматику и предлагают в качестве ответа на запрос. Но также была выявлена возможность использования генератора строк для получения конкретных строк пользователем из полученной аннотированной грамматики.

Использование *single-path* семантики запроса означает, что для нетерминала a, графа G и его вершин m, n, необходимо предъявить какой-нибудь путь (если он существует) из вершины m в вершину n, такой что метки на ребрах этого пути образуют строку из языка $L(C, a)$. Для КС-языков в работе [4] строится аннотированная грамматика, и если она порождает непустой язык, то в ней ищется строка минимальной длины, которая и будет соответствовать искомому пути в графе G. Таким образом, было выявлено, что алгоритм решения задачи синтаксического анализа графов с использованием *single-path* семантики запроса, предложенный в работе [4], и является примером использования генерации строки из КС-языка $L(C, a) \cap L(G, m, n)$.

Также была рассмотрена задача синтаксического анализа графов с использованием конъюнктивной грамматики. Из неразрешимости задачи определения пустоты конъюнктивных языков была получена неразрешимость задачи синтаксического анализа графов с использованием конъюнктивных языков и *relational* семантики запроса, о чем также упоминается в работе [3]. Кроме того, было выявлено, что при использовании конъюнктивных грамматик нельзя гарантировать нахождения хотя бы одной строки

из конъюнктивного языка $L(C, a) \cap L(G, m, n)$. Предположим, что найдется хотя бы одна строка, удовлетворяющая рассматриваемым ограничениям. Тогда при использовании *all-path* семантики запроса, применяя алгоритм генерации строки, происходил бы просто перебор всех возможных строк и проверка на принадлежность этих строк к языку $L(C, a) \cap L(G, m, n)$, что не соответствует практическому смыслу задачи. А для задачи синтаксического анализа графов с использованием *single-path* семантики запроса есть возможность сгенерировать некоторую строку непустого языка $L(C, a) \cap L(G, m, n)$. Стоит отметить, что использование конъюнктивных языков в задачах синтаксического анализа графов мало изучено. Полученные результаты могут быть использованы в дальнейших исследованиях данной области. Одной из тем таких исследований, например, является применимость булевых [7] грамматик в синтаксическом анализе графов.

Список литературы

[1] J. W. Anderson, Á. Novák, Z. Sükösd, M. Golden, P. Arunapuram, I. Edvardsson, and J. Hein. Quantifying variances in comparative rna secondary structure prediction. *BMC bioinformatics*, 14(1):149, 2013.

[2] C. Barrett, R. Jacob, and M. Marathe. Formal-language-constrained path problems. *SIAM Journal on Computing*, 30(3):809–837, 2000.

[3] J. Hellings. Conjunctive context-free path queries. 2014.

[4] J. Hellings. Querying for paths in graphs using context-free path queries. *arXiv preprint arXiv:1502.02242*, 2015.

[5] A. O. Mendelzon and P. T. Wood. Finding regular simple paths in graph databases. *SIAM Journal on Computing*, 24(6):1235–1258, 1995.

[6] A. Okhotin. Conjunctive grammars. *Journal of Automata, Languages and Combinatorics*, 6(4):519–535, 2001.

[7] A. Okhotin. Boolean grammars. *Information and Computation*, 194(1):19–48, 2004.

[8] X. Zhang, Z. Feng, X. Wang, G. Rao, and W. Wu. Context-free path queries on rdf graphs. In *International Semantic Web Conference*, pages 632–648. Springer, 2016.

[9] Охотин. О сложности задачи генерации строк. *Дискретная математика*, 15(4):84–99, 2003.