# Приложения теории формальных языков и синтаксического анализа

Семён Григорьев

3 марта 2020 г.

1	Обі	цие сведения теории графов	13
	1.1	Основные определения	13
	1.2	Задачи поиска путей	16
	1.3	APSP и транзитивное замыкание графа	17
	1.4	APSP и произведение матриц	19
	1.5	Умножение матриц с субкубической сложностью	20
	1.6	Вопросы и задачи	22
2	Общие сведения теории формальных языков		
	2.1	Контекстно-свободные грамматики и языки	24
	2.2	Дерево вывода	27
	2.3	Пустота КС-языка	28
	2.4	Нормальная форма Хомского	29
		2.4.1 Конъюнктивные и булевы грамматики	33
	2.5	Вопросы и задачи	40
3	Задача о поиске путей с ограничениями в терминах формальных языков		
	3.1	Постановка задачи	43
	3.2	О разрешимости задачи	45
	3.3	Области применения	46
	3.4	Вопросы и задачи	47

4	$\mathbf{C}\mathbf{Y}$	К для вычисления КС запросов	49
	4.1	Алгоритм СҮК	49
	4.2	Алгоритм для графов на основе СҮК	53
	4.3	Вопросы и задачи	63
5	Алі	горитм на матричных операциях	65
	5.1	Описание	65
		5.1.1 Матричный алгоритм для конъюнктивных грамматик	68
	5.2	Особенности реализации матричного алгоритма	70
	5.3	Обзор	72
	5.4	Вопросы и задачи	72
6	Чер	рез тензорное произведение	73
	6.1	Рекурсивные автоматы и сети	73
	6.2	Тензорное произведение	74
	6.3	Алгоритм	77
	6.4	Примеры	79
	6.5	Замечания о реализации	105
	6.6	Вопросы и задачи	105
7	Сж	атое представление леса разбора	107
	7.1	Лес разбора как представление контекстно-свободной грамматик	и 107
	7.2	Вопросы и задачи	119
8	Алі	горитм на основе восходящего анализа	121
	8.1	Восходящий синтаксический анализ	121
	8.2	GLR и его применение для КС запросов	128
		8.2.1 Классический GLR алгоритм	128
		8.2.2 Модификации GLR	132
	8.3	Вопросы и залачи	133

9	Алг	оритм на основе нисходящего анализа	135
	9.1	Нисходящий синтаксический анализ	. 135
		9.1.1 Рекурсивный спуск	. 135
		9.1.2 LL(k)-алгоритм синтаксического анализа	. 136
	9.2	GLL и его применение для КС запросов	. 141
	9.3	Вопросы и задачи	. 150
10	Kon	лбинаторы для KC апросов	151
	10.1	Парсер комбинаторы	. 151
	10.2	Комбинаторы для КС запросов	. 151
	10.3	Вопросы и задачи	. 151
11	Про	оизводные для КС запросов	153
	11.1	Производные	. 153
	11.2	Принадлежность языку	. 154
	11.3	Построение производных	. 154
	11.4	Задача достижимости	. 155
	11.5	Парсинг на производных	. 158
	11.6	Адоптация для КС запросов	. 158
	11.7	Вопросы и задачи	. 158
12	От	CFPQ к вычислению Datalog-запросов	159
		12.0.1 Datalog	. 159
		12.0.2 Datalog для работы с графами	. 160
		12.0.3 Алгоритм Эрли	. 161
	12.1	Вопросы и залачи	. 163

# Список авторов

### • Семён Григорьев

Санкт-Петербургский государственный университет, Университетская набережная, 7/9, Санкт-Петербург, 199034, Россия s.v.grigoriev@spbu.ru

JetBrains Research, Приморский проспект 68-70, здание 1, Санкт-Петербург, 197374, Россия semyon.grigorev@jetbrains.com

### • Екатерина Вербицкая

JetBrains Research, Приморский проспект 68-70, здание 1, Санкт-Петербург, 197374, Россия ekaterina.verbitskaya@jetbrains.com

### • Дмитрий Кутленков

Санкт-Петербургский государственный университет, Университетская набережная, 7/9, Санкт-Петербург, 199034, Россия kutlenkov.dmitri@gmail.com

# Введение

Теория формальных языков находит применение не только для ставших уже классическими задач синтаксического анализа кода (языков программирования, искусственных языков) и естественных языков, но и в других областях, таких как статический анализ кода, графовые базы данных, биоинформатика, машинное обучение.

Напримемер, в машинном обучении использование формальных граммтик позволяет передать искусственной нейронной сети, предназначенной для генерации цепочек с определёнными свойствами (генеративной нейронной сети), знания о синтаксической структуре этих цепочек, что позволяет существенно упростить процесс обучения и повысить качество результата [43]. Вместе с этим, развиваются подходы, позволяющие нейронным сетям наоборот извлекать синтаксическую структуру (строить дерево вывода) для входных цепочек [38, 39].

В биоинформатике формальные граммтики нашли широкое применение для описания особенностей вторичной структуры геномных и белковых последовательностей [24, 4, 88]. Соответствующие алгоритмы синтаксического анализа используются при создании инструментов обработки данных.

Таким образом, теория формальных языков выступает в качестве основы для многих прикладных областей, а алгоритмы синтаксического анлиза применимы не только для обработки естественных языков или языков программирования. Нас же в данной работе будет интересовать применение теории формальных языков и алгоритмов синтаксического анализа для анализа графовым базам данных и для статического анализу кода.

Одна из классических задач, связанных с анализом графов — это поиск путей в графе. Возможны различные формулировки этой задачи. В некоторых случайх необходимо выяснить, существует ли путь с определёнными свойствами между двумя выбранными вершинами. В других же ситуациях необходимо найти все пути в графе, удовлетворяющие некоторым свойствам или ограничениям. Например, указать, что искомый путь должен быть простым, кратчайшим, гамильтоновым и так далее.

Один из способов задавать ограничения на пути в графе основан на использовании формальных языков. Базоваое определение языка говорит нам, что язык — это множество слов над некоторым алфавитом. Если рассмотреть граф, рёбра которого помечены символами из алфавита, то путь в таком графе будет задавать слово: достаточно соединить последовательно символы, лежащие на рёбрах пути. Множество же таких путей будет задавать множество слов или язык. Таким образом, если мы хотим найти некоторое множество путей в графе, то в качестве ограничения можно описать язык, который должно задавать это множество. Иными словами, задача поиска путей может быть сформулирована следующим образом: необходимо найти такие пути в графе, что слова, получаемые конкатенацей меток их рёбер, принадлежат заданному языку. Такой класс задач будем называть задачами поиска путей с ограничениям в теринах формальных языков.

Подобный класс задач часто возникает в областях, связанных с анализом граф-структурированных данных и активно исследуется [10, 5, 35, 79, 9, 10]. Исследуются как классы языков, применяемых для задания ограничений, так и различные постановки задачи.

Граф-структурированный данные встречаются не только в графовых базах данных, но и при статическом анализе кода: по программе можно построить различные графы отображающие её свойства. Скажем, граф вызовов, граф потока данны и так далее. Оказывается, что поиск путей в специального вида графах с сипользованием ограничений в терминах формальных языков позволяет исследовать некоторые свойства программы. Например проводить межпроцедурный анализ указателей или анализ алиасов [87, 83, 85], строить срезы программ [61], проводить анализ типов [58].

В данной работе пердставлен ряд алгоритмов для поиска путей с ограничениями в терминах формальных языков. Основной акцент булет сделан на контекстно-свободных языках, однако будут затронуты и другие классы: регулярные и конъюнктивные языки. Будет показано, что теория формальных языков и алгоритмы синатксического анализа применимы не только для анализа языков программирования или естественных языков, а также для анализа графовых баз данных и статического анализа кода, что приводит к возникновению новых задач и переосмыслению старых.

Структура данной работы такова. Сперва, в главе 1 мы рассмотрим основные понятия из теории графов, необходимые в данной работе. Затем, в главе 2 мы введём основные понятия из теории формальных языков. Далее, в главе 3 рассмотрим различные варианты постановки задачи поиска путей с ограничениями в терминах формальнх языков, обсудим базовые свойства задач, её разрешимость в различных постановках и т.д.. И в тоге зафикси-

руем постановку, которую будем изучать далее. После этого, в главах 4–11 мы будем подробно рассматривать различные алгоритмы решения этой задачи, попутно вводя специфичные для рассматриваемого алгоритма структуры данных. Большинство алгоритмов будут основаны на классических алгоритмах синтаксического анализа, таких как СҮК или LR. Все гравы, начиная с 1, снабжены списком вопросов и задач для самостоятельного решения и закрепления материала.

# Глава 1

# Общие сведения теории графов

В данном разделе мы дадим определения базовым понятиям из теории графов, рассмотрим несколько классических задач из области анализа графов и алгоритмы их решения. Всё это понадобится нам при последующей работе.

### 1.1 Основные определения

**Определение 1.1.1.**  $\Gamma pa\phi \mathcal{G} = \langle V, E, L \rangle$ , где V — конечное множество вершин, E — конечное множество рёбер, т.ч.  $E \subseteq V \times L \times V$ , L — конечное множество меток рёбер.


В дальнейшем нам будут нужны конечные ориентированные помеченные графы. Мы будем использовать термин  $\it cpa\phi$  подразумевая именно конечный ориентированный помеченный граф, если только не оговорено противное.

Также мы будем считать, что все вершины занумерованы подряд с нуля. То есть можно считать, что V — это отрезок неотрицательный целых чисел.

**Пример 1.1.1** (Пример графа и его графического представления). Пусть дан граф

$$\mathcal{G}_1 = \langle \{0, 1, 2, 3\}, \{(0, a, 1), (1, a, 2), (2, a, 0), (2, b, 3), (3, b, 2)\}, \{a, b\} \rangle.$$

Графическое представление графа  $\mathcal{G}_1$ :

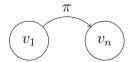


Определение 1.1.2. Ребро ориентированного помеченного графа  $\mathcal{G} = \langle V, E, L \rangle$  это упорядоченная тройка  $e = (v_i, l, v_j) \in V \times L \times V$ .

**Пример 1.1.2.** (0, a, 1) и (3, b, 2) — это рёбра графа  $\mathcal{G}_1$ . При этом, (3, b, 2) (2, b, 3) — это разные рёбра, что видно из рисунка.

Определение 1.1.3. Путём  $\pi$  в графе  $\mathcal G$  будем называть последовательность рёбер такую, что для любых двух последовательных рёбер  $e_1=(u_1,l_1,v_1)$  и  $e_2=(u_2,l_2,v_2)$  в этой последовательности, конечная вершина первого ребра является начальной вершиной второго, то есть  $v_1=u_2$ . Будем обозначать путь из вершины  $v_0$  в вершину  $v_n$  как

$$v_0\pi v_n = e_0, e_1, \dots, e_{n-1} = (v_0, l_0, v_1), (v_1, l_1, v_2), \dots, (v_{n-1}, l_n, v_n).$$



**Пример 1.1.3.**  $(0, a, 1)(1, a, 2) = 0\pi_1 2$  — путь из вершины 0 в вершину 2 в графе  $\mathcal{G}_1$ . При этом,  $(0, a, 1)(1, a, 2)(2, b, 3)(3, b, 2) = 0\pi_2 2$  — это тоже путь из вершины 0 в вершину 2 в графе  $\mathcal{G}_1$ , но он не равен  $0\pi_1 2$ .

Нам потребуется также отношение, отражающее факт существования пути между двумя вершинами.

**Определение 1.1.4.** Отношение достижимости в графе:  $(v_i, v_j) \in P \iff \exists v_i \pi v_i$ .

Отметим, что рефлексивность этого отношения часто зависит от контекста. В некоторых задачах по-умолчанию  $(v_i, v_i) \notin P$ , а чтобы это было верно, требуется явное наличие ребра-петли.

Один из способов задать граф — это задать его матрицу смежности.


**Определение 1.1.5.** *Матрица смежсности* графа  $\mathcal{G} = \langle V, E, L \rangle$  — это квадратная матрица M размера  $n \times n$ , где |V| = n и ячейки которой содержат множества. При этом  $l \in M[i,j] \iff \exists e = (i,l,j) \in E$ .

Заметим, что наше определение матрицы смежности отличается от классического, в котором матрица отражает лишь факт наличия хотя бы одного ребра и, соответственно, является булевой. То есть  $M[i,j]=1\iff \exists e=(i,\_,j)\in E.$ 

15

Также можно встретить матрицы смежности в ячейках которых всё же хранится некоторая информация, однако, в единственном экземпляре. То есть запрещены параллельные рёбра. Такой подход часто можно встретить в задачах о кратчайших путях: в этом случае в ячейке хранится расстояние между двумя вершинами. При этом, так как в качестве весов часто рассматривают произвольные (в том числе отрицательные) числа, то в задачах о кратчайших путях отдельно вводят значение "бесконечность" для обозначения ситуации, когда между двумя вершинами нет пути или его длина ещё не известна.

Пример 1.1.4. Неориентированный граф:



И его матрица смежности:


$$\begin{pmatrix} 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 \end{pmatrix}$$

Пример 1.1.5. Ориентированный граф:

И его матрица смежности:

$$\begin{pmatrix}
1 & 1 & 0 & 0 \\
0 & 1 & 1 & 0 \\
1 & 0 & 1 & 1 \\
0 & 0 & 1 & 1
\end{pmatrix}$$


Пример 1.1.6. Помеченный граф:



И его матрица смежности:

$$\begin{pmatrix}
\varnothing & \{a\} & \varnothing & \varnothing \\
\varnothing & \varnothing & \{a\} & \varnothing \\
\{a\} & \varnothing & \varnothing & \{a,b\} \\
\varnothing & \varnothing & \{b\} & \varnothing
\end{pmatrix}$$

Пример 1.1.7. Взвешенный граф для задачи о кратчайших путях:



И его матрица смежности (для задачи о кратчайших путях):

$$\begin{pmatrix} 0 & -1.4 & \infty & \infty \\ \infty & 0 & 2.2 & \infty \\ 0.5 & \infty & 0 & 1.85 \\ \infty & \infty & -0.76 & 0 \end{pmatrix}$$

Мы ввели лишь общие понятия. Специальные понятия, необходимые для изложения конкретного материала, будут даны в соответствующих главах.

### 1.2 Задачи поиска путей

Одна из классических задач анализа графов — это задача поиска путей между вершинами с различными ограничениями.

При этом, возможны различные постановки задачи. С одной стороны, по тому, что именно мы хотим получить в качестве результата:

• Наличие пути, удовлетворяющего ограничениям, в графе.

- Наличие пути, удовлетворяющего ограничениям, между некоторыми вершинами: задача достижимости. Достижима ли вершина  $v_1$  из вершины  $v_2$  по пути, удовлетворяющему ограничениям. Такая постановка требует лишь проверить существование, но не обязательно предоставлять путь.
- Поиск одного пути, удовлетворяющего ограничениям. Уже надо предъявлять путь.
- Поиск всех путей. Надо предоставить все пути.

С другой стороны, задачи различаются ещё и по тому, как фиксируем вершины:

- из одной вершины до всех
- между всеми парами вершин
- межу фиксированной парой вершин
- между двумя множествами вершин

Итого, можем сгенерировать прямое произведение различных постановок.

Ограничение, имеющее важное прикладное значение, — минимальность длины. Иными словами, важная прикладная задача — поиск кратиайших путей в графе (англ. APSP — all-pairs shortest paths)

Часто добавляют ограничения, что путь должен быть простым и другие.

### 1.3 APSP и транзитивное замыкание графа

Заметим, что отношение достижимости (1.1.4) является транзитивным. Действительно, если существует путь из  $v_i$  в  $v_j$  и путь из  $v_j$  в  $v_k$ , то существует путь из  $v_i$  в  $v_k$ .

**Определение 1.3.1.** *Транзитивным замыканием графа* называется транзитивное замыкание отношения достижимости по всему графу.

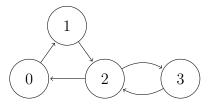
Как несложно заметить, транзитивное замыкание графа — это тоже граф. Более того, если решить задачу поиска кратчайших путей между всеми парами вершин, то мы построим транзитивное замыкание. Поэтому сразу рассмотрим алгоритм Флойда-Уоршелла [26, 62, 81], который является общим

### Listing 1 Алгоритм Флойда-Уоршелла


```
1: function FLOYDWARSHALL(\mathcal{G})
2: M \leftarrow матрица смежности \mathcal{G}
3: n \leftarrow |V(\mathcal{G})|
4: for k = 0; k < n; k++ do
5: for i = 0; i < n; i++ do
6: for j = 0; j < n; j++ do
7: M[i,j] \leftarrow \min(M[i,j], M[i,k] + M[k,j])
8: return M
```

алгоритмом поиска кратчайших путей (умеет обрабатывать рёбра с отрицательными весами, чего не может, например, алгоритм Дейкстры). Его сложность:  $O(n^3)$ , где n — количество вершин в графе. При этом, данный алгоритм легко упростить до алгоритма построения транзитивного замыкания.

Пример 1.3.1. Пусть дан следующий граф:



Построим его транзитивное замыкание:



Remark. На самом деле, петли у вершины 3 может и не быть, т.к. это зависит от определения.

Remark. Приведем список интересных работ по APSP для ориентированных графов с вещественными весами (здесь n — количество вершин в графе):

- 19
- М.L. Fredman (1976)  $O(n^3(\log\log n/\log n)^{\frac{1}{3}})$  использование дерева решений [27]
- W. Dobosiewicz (1990)  $O(n^3/\sqrt{\log n})$  использование операций на Word Random Access Machine [23]
- Т. Такаока (1992)  $O(n^3 \sqrt{\log \log n / \log n})$  использование таблицы поиска [71]
- Y. Han  $(2004) O(n^3 (\log \log n / \log n)^{\frac{5}{7}})$  [30]
- T. Takoaka  $(2004) O(n^3(\log\log n)^2/\log n)$  [72]
- T. Takoaka (2005)  $O(n^3 \log \log n / \log n)$  [73]
- U. Zwick  $(2004) O(n^3 \sqrt{\log \log n} / \log n)$  [89]
- Т.М. Chan (2006)  $O(n^3/\log n)$  многомерный принцип "разделяй и властвуй" [19]
- и др.

### 1.4 APSP и произведение матриц

Алгоритм Флойда-Уоршелла можно переформулировать в терминах перемножения матриц. Для этого введём обозначение.

**Определение 1.4.1.** Пусть даны матрицы A и B размера  $n \times n$ . Определим операцию  $\star$ , которую называют Min-plus  $matrix\ multiplication$ :

$$A\star B=C$$
 — матрица размера  $n\times n$ , т.ч.  $C[i,j]=\min_{k=1\dots n}\{A[i,k]+B[k,j]\}$ 

Также, обозначим за D[i,j](k) минимальную длину пути из вершины i в j, содержащий максимум k рёбер. Таким образом, D(1) = M, где M — это матрица смежности, а решением APSP является D(n-1), т.к. чтобы соединить n вершин требуется не больше n-1 рёбер.

$$D(1) = M$$

$$D(2) = D(1) * M = M^{2}$$

$$D(3) = D(2) * M = M^{3}$$

$$...$$

$$D(n-1) = D(n-2) * M = M^{n-1}$$

Итак, мы можем решить APSP за O(nK(n)), где K(n) — сложность алгоритма умножения матриц. Сразу заметим, что, например, D(3) считать не обязательно, т.к. можем посчитать D(4) как  $D(2) \star D(2)$ . Поэтому:

$$D(1) = M$$

$$D(2) = M^2 = M \star M$$

$$D(4) = M^4 = M^2 \star M^2$$

$$D(8) = M^8 = M^4 \star M^4$$

$$\dots$$

$$D(2^{\log(n-1)}) = M^{2^{\log(n-1)}} = M^{2^{\log(n-1)}-1} \star M^{2^{\log(n-1)}-1}$$

$$D(n-1) = D(2^{\log(n-1)})$$

Теперь вместо n итераций нам нужно  $\log n$ . В итоге, сложность —  $O(\log nK(n))$ . Данный алгоритм называется  $repeated\ squaring^1$ .

# 1.5 Умножение матриц с субкубической сложностью

В предыдущем подразделе мы свели проблему APSP к проблеме min-plus matrix multiplication, поэтому взглянем на эффективные алгоритмы матричного умножения.

Сложность наивного произведения двух матриц составляет  $O(n^3)$ , это приемлемо только для малых матриц, для больших же лучше использовать алгоритмы с субкубической сложностью. Отметим, что мы называем сложность субкубической, если она равна  $O(n^{3-\varepsilon})$ , где  $\varepsilon > 0$ , иначе говоря, меньшей, чем  $O(n^3)$ .

Первый субкубический алгоритм опубликовал Ф. Штрассен в 1969 году, его сложность —  $O(n^{\log_2 7}) \approx O(n^{2.81})$  [69]. Основная идея — рекурсивное разбиение на блоки  $2 \times 2$  и вычисление их произведения с помощью только 7 умножений, а не 8. Впоследствии алгоритмы усовершенствовались до  $\approx O(n^{2.5})$  [56, 13, 63, 21]. В настоящее время наиболее асимптотически быстрым является алгоритм Копперсмита — Винограда со сложностью  $O(n^{2.376})$  [22].

Несмотря на то, что у приведенных алгоритмов неплохая алгоритмическая сложность, мы всё же не можем использовать их для вычисления min-plus matrix multiplication, так как в субкубических алгоритмах требуется, чтобы

<sup>&</sup>lt;sup>1</sup>Пример решения APSP с помощью repeated squaring: http://users.cecs.anu.edu.au/~Alistair.Rendell/Teaching/apac\_comp3600/module4/all\_pairs\_shortest\_paths.xhtml

элементы образовывали кольцо. Покажем, что  $\mathbb{R} \cup \{+\infty\}$  с операциями min и + являются полукольцом, а не кольцом:

- 1. min(a, b) = min(b, a)
- 2. min(min(a,b)), c) = min(a, min(b,c))
- 3.  $min(a, +\infty) = min(+\infty, a) = a$ , т.е.  $+\infty$  нейтральный элемент относительно операции min
- 4. (a+b)+c=a+(b+c)
- 5. min(a, b) + c = min(a + c, b + c)
- 6. a + min(b, c) = min(a + b, a + c)
- 7.  $a + \infty = \infty + a = \infty$
- 8. Но для произвольного элемента  $a: \nexists d$ , т.ч.  $min(a,d) = min(d,a) = +\infty$ , т.е. для любого элемента нет обратного относительно операции min

Таким образом, вопрос о субкубических алгоритмах решения APSP всё ещё открыт [20]. Кроме того, более простая задача APSP с булевыми матрицами также не решена за субкубическую сложность. Приведем обоснование этого факта.

Определение 1.5.1. Матрица называется булевой, если она состоит из 0 и 1.

Булевы матрицы с поэлементными операциями дизъюнкции и конъюнкции являются полукольцом. Покажем это: пусть  $A,\ B$  и C — булевы матрицы, тогда:

- 1.  $A \lor B = B \lor A$
- 2.  $(A \lor B) \lor C = A \lor (B \lor C)$
- 3.  $A \lor N = N \lor A = A$ , где N матрица, полностью состоящая из 0
- 4.  $(A \wedge B) \wedge C = A \wedge (B \wedge C)$
- 5.  $(A \lor B) \land C = (A \land C) \lor (B \land C)$
- 6.  $A \wedge (B \vee C) = (A \wedge B) \vee (A \wedge C)$
- 7.  $A \wedge N = N \wedge A = N$

Булевы матрицы тоже не являются кольцом, т.к. не имеют обратный элемент относительно операции дизъюнкции (т.е. для произвольной булевой матрицы A:  $\not\equiv D$ , т.ч. D — булева матрица и  $A \lor D = D \lor A = N$ ). Следовательно, субкубические алгоритмы не подходят для перемножения булевых матриц, т.к. в них используются обратные элементы (например, для разности). В частности, они не применимы к классической матрице смежности, которая ведёт себя как булева матрица.

# 1.6 Вопросы и задачи

- 1. Реализуйте абстракцию полукльца, позволяющую конструировать полукольца с произвольными операциями.
- 2. Реализуйте алгоритм произведения матриц над произвольным полукольцом. Используйте результат решения предыдущей задачи.
- 3. Используя результаты предыдущих задач, реализуйте алгоритм построения транзитивного замыкания через произведение матриц.
- 4. Используя результаты предыдущих задач, реализуйте алгоритм решения задачи APSP для ориентированного через произведение матриц.
- 5. Используя существующую библиотеку линейной алгебры для CPU, решите задачу построения транзитивного замыкания графа.
- 6. Используя существующую библиотеку линейной алгебры для CPU, решите задачу APSP для ориентированного графа.
- 7. Используя существующую библиотеку линейной алгебры для GPGPU, решите задачу построения транзитивного замыкания графа.
- 8. Используя существующую библиотеку линейной алгебры для GPGPU, решите задачу APSP для ориентированного графа.
- 9. Сравните произволительность решений предыдущих задач

# Глава 2

# Общие сведения теории формальных языков

В данной главе мы рассмотрим основные понятия из теории формальных языков, которые пригодятся нам в дальнейшем изложении.

**Определение 2.0.1.** *Алфавит* — это конечное множество. Элементы этого множества будем называть *символами*.

Пример 2.0.1. Примеры алфавитов

- Латинский алфавит  $\Sigma = \{a, b, c, \dots, z\}$
- Кириллический алфавит  $\Sigma = \{a, 6, B, ..., я\}$
- Алфавит чисел в шестнадцатеричной записи  $\Sigma = \{0,1,2,3,4,5,6,7,8,9,A,B,C,D,E,F\}$

Традиционное обозначение для алфавита —  $\Sigma$ . Также мы будем использовать различные прописные буквы латинского алфавита. Для обозначения символов алфавита будем использовать строчные буквы латинского алфавита:  $a, b, \ldots, x, y, z$ .

Будем считать, что над алфавитом  $\Sigma$  всегда определена операция конкатенации  $(\cdot): \Sigma^* \times \Sigma^* \to \Sigma^*$ . При записи выражений символ точки (обозначение операции конкатенации) часто будем опускать:  $a \cdot b = ab$ .

Определение 2.0.2. Слово над алфавитом  $\Sigma$  — это конечная конкатенация символов алфавита  $\Sigma$ :  $\omega = a_0 \cdot a_1 \cdot \ldots \cdot a_m$ , где  $\omega$  — слово, а для любого  $i \ a_i \in \Sigma$ .

Определение 2.0.3. Слово над алфавитом  $\Sigma$  — это результат конечной конкатенации символов алфавита  $\Sigma$ :  $\omega = a_0 \cdot a_1 \cdot \ldots \cdot a_m$ , где  $\omega$  — слово, а для любого i  $a_i \in \Sigma$ . Будем называть m+1 длиной слова и обозначать как  $|\omega|$ . **Определение 2.0.4.**  $\mathit{Язык}$  над алфавитом  $\Sigma$  — это множество слов над алфавитом  $\Sigma$ .

### Пример 2.0.2. Примеры языков

- Язык целых чисел в двоичной записи  $\{0, 1, -1, 10, 11, -10, -11, \dots\}$
- Язык всех правильных скобочных последовательностей  $\{(),(()),()(),(())(),\dots\}$

Любой язык над алфавитом  $\Sigma$  является подмножеством  $\Sigma^*$  — множества всех слов над алфавитом  $\Sigma$ 

Заметим, что язык не обязан быть конечным множеством, в то время как алфавит всегда конечен и изучаем мы конечные слова.

Способы задания языков

- Перечислить все элементы. Такой способ работает только для конечных языков. Перечислить бесконечное множество не получится.
- Задать генератор процедуру, которая возвращает очередное слово языка.
- Задать распознователь процедуру, которая по данному слову может определить, принадлежит оно заданному языку или нет.

### 2.1 Контекстно-свободные грамматики и языки

Из всего многообразия нас будут интересовать прежде всего контекстно-свободные грамматики.

**Определение 2.1.1.** *Контекстно-свободная грамматика* — это четвёрка вида  $\langle \Sigma, N, P, S \rangle$ , где

- $\Sigma$  это терминальный алфавит;
- N это нетерминальный алфавит;
- P это множество правил или продукций, таких что каждая продукция имеет вид  $N_i \to \alpha$ , где  $N_i \in N$  и  $\alpha \in \{\Sigma \cup N\}^* \cup \varepsilon$ ;
- S стартовый нетерминал. Отметим, что  $\Sigma \cap N = \emptyset$ .

**Пример 2.1.1.** Грамматика, задающая язык целых чисел в двоичной записи без лидирующих нулей:  $G = \langle \{0,1,-\}, \{S,N,A\}, P,S \rangle$ , где P определено следующим образом:

$$\begin{array}{ccc} S & \rightarrow & 0 \mid N \mid -N \\ N & \rightarrow & 1A \\ A & \rightarrow & 0A \mid 1A \mid \varepsilon \end{array}$$

При спецификации грамматики часто опускают множество терминалов и нетерминалов, оставляя только множество правил. При этом нетерминалы часто обозначаются прописными латинскими буквами, терминалы — строчными, а стартовый нетерминал обозначается буквой S. Мы будем следовать этим обозначениям, если не указано иное.

Определение 2.1.2. Отношение непосредственной выводимости. Мы говорим, что последовательность терминалов и нетерминалов  $\gamma \alpha \delta$  непосредственно выводится из  $\gamma \beta \delta$  при помощи правила  $\alpha \to \beta$  ( $\gamma \alpha \delta \Rightarrow \gamma \beta \delta$ ), если

- $\alpha \to \beta \in P$
- $\gamma, \delta \in \{\Sigma \cup N\}^* \cup \varepsilon$

**Определение 2.1.3.** *Отношение выводимости* является рефлексивно-транзитивным замыканием отношения непосредственной выводимости

- $\alpha \stackrel{*}{\Rightarrow} \beta$  означает  $\exists \gamma_0, \dots \gamma_k : \alpha \Rightarrow \gamma_0 \Rightarrow \gamma_1 \Rightarrow \dots \Rightarrow \gamma_{k-1} \Rightarrow \gamma_k \Rightarrow \beta$
- Транзитивность:  $\forall \alpha, \beta, \gamma \in \{\Sigma \cup N\}^* \cup \varepsilon : \alpha \stackrel{*}{\Rightarrow} \beta, \beta \stackrel{*}{\Rightarrow} \gamma \Rightarrow \alpha \stackrel{*}{\Rightarrow} \gamma$
- Рефлексивность:  $\forall \alpha \in \{\Sigma \cup N\}^* \cup \varepsilon : \alpha \stackrel{*}{\Rightarrow} \alpha$
- $\alpha \stackrel{*}{\Rightarrow} \beta \alpha$  выводится из  $\beta$
- $\alpha \stackrel{k}{\Rightarrow} \beta \alpha$  выводится из  $\beta$  за k шагов
- $\alpha \stackrel{+}{\Rightarrow} \beta$  при выводе использовалось хотя бы одно правило грамматики

**Пример 2.1.2.** Пример вывода цепочки -1101 в грамматике:

$$\begin{array}{ccc} S & \rightarrow & 0 \mid N \mid -N \\ N & \rightarrow & 1A \\ A & \rightarrow & 0A \mid 1A \mid \varepsilon \end{array}$$

$$S \Rightarrow -N \Rightarrow -1A \Rightarrow -11A \stackrel{*}{\Rightarrow} -1101A \Rightarrow -1101$$

**Определение 2.1.4.** *Рефлексивно-транзитивное замыкание отношения* — это наименьшее рефлексивное и транзитивное отношение, содержащее исходное.

Определение 2.1.5. Вывод слова в грамматике. Слово  $\omega \in \Sigma^*$  выводимо в грамматике  $\langle \Sigma, N, P, S \rangle$ , если существует некоторый вывод этого слова из начального нетерминала  $S \stackrel{*}{\Rightarrow} \omega$ .

**Определение 2.1.6.** *Левосторонний вывод*. На каждом шаге вывода заменяется самый левый нетерминал.

Пример 2.1.3. Пример левостороннего вывода цепочки в грамматике

$$\begin{array}{ccc} S & \rightarrow & AA \mid s \\ A & \rightarrow & AA \mid Bb \mid a \\ B & \rightarrow & c \mid d \end{array}$$

$$S \Rightarrow AA \Rightarrow BbA \Rightarrow cbA \Rightarrow cbAA \Rightarrow cbaA \Rightarrow cbaa$$

Аналогично можно определить правосторонний вывод.

**Определение 2.1.7.** Язык, задаваемый грамматикой — множество строк, выводимых в грамматике  $L(G) = \{\omega \in \Sigma^* \mid S \stackrel{*}{\Rightarrow} \omega\}.$ 

**Определение 2.1.8.** Грамматики  $G_1$  и  $G_2$  называются эквивалентными, если они задают один и тот же язык:  $L(G_1) = L(G_2)$ 

**Пример 2.1.4.** Пример эквивалентных грамматик для языка целых чисел в двоичной системе счисления.

**Определение 2.1.9.** *Неоднозначная грамматика* — грамматика, в которой существует 2 и более левосторонних (правосторонних) выводов для одного слова.

27

**Пример 2.1.5.** Неоднозначная грамматика для правильных скобочных последовательностей

$$S \to (S) \mid SS \mid \varepsilon$$

**Определение 2.1.10.** Однозначная грамматика — грамматика, в которой существует не более одного левостороннего (правостороннего) вывода для каждого слова.

**Пример 2.1.6.** Однозначная грамматика для правильных скобочных последовательностей

$$S \to (S)S \mid \varepsilon$$

**Определение 2.1.11.** *Существенно неоднозначные языки* — языки, для которых невозможно построить однозначную грамматику.

Пример 2.1.7. Пример существенно неоднозначного языка

$$\{a^n b^n c^m \mid n, m \in \mathbb{Z}\} \cup \{a^n b^m c^m \mid n, m \in \mathbb{Z}\}$$

### 2.2 Дерево вывода


В некоторых случаях не достаточно знать порядок применения правил. Необходимо структурное представление вывода цепочки в грамматике. Таким представлением является дерево вывода.

**Определение 2.2.1.** Деревом вывода цепочки  $\omega$  в грамматике  $G = \langle \Sigma, N, S, P \rangle$  называется дерево, удовлетворяющее следующим свойствам.

- 1. Помеченное: метка каждого внутреннего узла нетерминал, метка каждого листа терминал или  $\varepsilon$ .
- 2. Корневое: корень помечен стартовым нетерминалом.
- 3. Упорядоченное.
- 4. В дереве есть узел с меткой  $N_i$  и сыновьями  $M_j \dots M_k$  тогда и только тогда, когда в грамматике есть правило вида  $N_i \to M_j \dots M_k$ .
- 5. Крона образует цепочку.

**Пример 2.2.1.** Построим дерево вывода цепочки *ababab* в грамматике

$$G = \langle \{a, b\}, \{S\}, S, \{S \rightarrow a \ S \ b \ S, S \rightarrow \varepsilon\} \rangle$$



**Теорема 2.2.1.** Пусть  $G = \langle \Sigma, N, P, S \rangle$  — КС-грамматика. Вывод  $S \stackrel{*}{\Rightarrow} \alpha$ , где  $\alpha \in (N \cup \Sigma)^*, \alpha \neq \varepsilon$  существует  $\Leftrightarrow$  существует дерево вывода в грамматике G с кроной  $\alpha$ .

### 2.3 Пустота КС-языка

**Теорема 2.3.1.** Существует алгоритм, определяющий, является ли язык, порождаемый КС грамматикой, пустым.

Доказательство. Следующая лемма утверждает, что если в КС языке есть выводимое слово, то существует другое выводимое слово с деревом вывода не глубже количества нетерминалов грамматики. Для доказательства теоремы достаточно привести алгоритм, последовательно строящий все деревья глубины не больше количества нетерминалов грамматики, и проверяющий, являются ли такие деревья деревьями вывода. Если в результате работы алгоритма не удалось построить ни одного дерева, то грамматика порождает пустой язык.

**Лемма 2.3.2.** Если в данной грамматике выводится некоторая цепочка, то существует цепочка, дерево вывода которой не содержит ветвей длиннее m, где m — количество нетерминалов грамматики.

Доказательство. Рассмотрим дерево вывода цепочки  $\omega$ . Если в нем есть 2 узла, соответствующих одному нетерминалу A, обозначим их  $n_1$  и  $n_2$ .

Предположим,  $n_1$  расположен ближе к корню дерева, чем  $n_2$ .

 $S \stackrel{*}{\Rightarrow} \alpha A_{n_1} \beta \stackrel{*}{\Rightarrow} \alpha \omega_1 \beta; S \stackrel{*}{\Rightarrow} \alpha \gamma A_{n_2} \delta \beta \stackrel{*}{\Rightarrow} \alpha \gamma \omega_2 \delta \beta$ , при этом  $\omega_2$  является подцепочкой  $\omega_1$ .

Заменим в изначальном дереве узел  $n_1$  на  $n_2$ . Полученное дерево является деревом вывода  $\alpha\omega_2\delta$ .

Повторяем процесс замены одинаковых нетерминалов до тех пор, пока в дереве не останутся только уникальные нетерминалы.

В полученном дереве не может быть ветвей длины большей, чем т.

По построению оно является деревом вывода.

### 2.4 Нормальная форма Хомского

Определение 2.4.1. Контекстно-свободная грамматика  $\langle \Sigma, N, P, S \rangle$  находится в *Нормальной Форме Хомского*, если она содержит только правила следующего вида:

- $A \to BC$ , где  $A, B, C \in N$ , S не содержится в правой части правила
- $A \to a$ , где  $A \in N, a \in \Sigma$
- $S \to \varepsilon$

**Теорема 2.4.1.** Любую КС грамматику можно преобразовать в НФХ.

Доказательство. Алгоритм преобразования в НФХ состоит из следующих шагов:

- Замена неодиночных терминалов
- Удаление длинных правил
- Удаление  $\varepsilon$ -правил
- Удаление цепных правил
- Удаление бесполезных нетерминалов

То, что каждый из этих шагов преобразует грамматику к эквивалентной, при этом является алгоритмом, доказано в следующих леммах.

**Лемма 2.4.2.** Для любой КС-грамматики можно построить эквивалентную, которая не содержит правила с неодиночными терминалами.

Доказательство. Каждое правило  $A \to B_0 B_1 \dots B_k, k \ge 1$  заменить на множество правил:

- $A \rightarrow C_0C_1 \dots C_k$
- $\{C_i \to B_i \mid B_i \in \Sigma, C_i$  новый нетерминал $\}$

**Лемма 2.4.3.** Для любой КС-грамматики можно построить эквивалентную, которая не содержит правил длины больше 2.

Доказательство. Каждое правило  $A \to B_0 B_1 \dots B_k, k \ge 2$  заменить на множество правил:

- $\bullet$   $A \rightarrow B_0C_0$
- $C_0 \rightarrow B_1C_1$
- ...
- $C_{k-3} \to B_{k-2}C_{k-2}$
- $\bullet$   $C_{k-2} \to B_{k-1}B_k$

**Лемма 2.4.4.** Для любой КС-грамматики можно построить эквивалентную, не содержащую  $\varepsilon$ -правил.

 $\mathcal{A}$ оказательство. Определим  $\varepsilon$ -правила:

- $A \to \varepsilon$
- $A \to B_0 \dots B_k, \forall i : B_i \varepsilon$ -правило.

Каждое правило  $A \to B_0 B_1 \dots B_k$  заменяем на множество правил, где каждое  $\varepsilon$ -правило удалено во всех возможных комбинациях.  $\square$ 

### Лемма 2.4.5. Можно удалить все цепные правила

Доказательство. Цепное правило — правило вида  $A \to B$ , где  $A, B \in N$  . Цепная пара — упорядоченная пара (A,B), в которой  $A \stackrel{*}{\Rightarrow} B$ , используя только цепные правила.

### Алгоритм:

- 1. Найти все цепные пары в грамматике G. Найти все цепные пары можно по индукции: Базис: (A,A) цепная пара для любого нетерминала, так как  $A \stackrel{*}{\Rightarrow} A$  за ноль шагов. Индукция: Если пара  $(A,B_0)$  цепная, и есть правило  $B_0 \to B_1$ , то  $(A,B_1)$  цепная пара.
- 2. Для каждой цепной пары (A, B) добавить в грамматику G' все правила вида  $A \to a$ , где  $B \to a$  нецепное правило из G.
- 3. Удалить все цепные правила

Пусть G — контекстно-свободная грамматика. G' — грамматика, полученная в результате применения алгоритма к G. Тогда L(G) = L(G').

**Лемма 2.4.6.** Можно удалить все бесполезные (непорождающие) нетерминалы

Доказательство. После удаления из грамматики правил, содержащих непорождающие нетерминалы, язык не изменится, так как непорождающие нетерминалы по определению не могли участвовать в выводе какого-либо слова.

Алгоритм нахождения порождающих нетерминалов:

- 1. Множество порождающих нетерминалов пустое.
- 2. Найти правила, не содержащие нетерминалов в правых частях и добавить нетерминалы, встречающихся в левых частях таких правил, в множество.
- 3. Если найдено такое правило, что все нетерминалы, стоящие в его правой части, уже входят в множество, то добавить в множество нетерминалы, стоящие в его левой части.

4. Повторить предыдущий шаг, если множество порождающих нетерминалов изменилось.

В результате получаем множество всех порождающих нетерминалов грамматики, а все нетерминалы, не попавшие в него, являются непорождающими. Их можно удалить.

**Пример 2.4.1.** Приведем в Нормальную Форму Хомского однозначную грамматику правильных скобочных последовательностей:  $S \to aSbS \mid \varepsilon$ 

Первым шагом добавим новый нетерминал и сделаем его стартовым:

$$S_0 \to S$$
$$S \to aSbS \mid \varepsilon$$

Заменим все терминалы на новые нетерминалы:

$$S_0 \to S$$

$$S \to LSRS \mid \varepsilon$$

$$L \to a$$

$$R \to b$$

Избавимся от длинных правил:

$$S_0 \to S$$

$$S \to LS' \mid \varepsilon$$

$$S' \to SS''$$

$$S'' \to RS$$

$$L \to a$$

$$R \to b$$

Избавимся от  $\varepsilon$ -продукций:

$$S_0 \to S \mid \varepsilon$$

$$S \to LS'$$

$$S' \to S'' \mid SS''$$

$$S'' \to R \mid RS$$

$$L \to a$$

$$R \to b$$

Избавимся от цепных правил:

$$S_0 \to LS' \mid \varepsilon$$

$$S \to LS'$$

$$S' \to b \mid RS \mid SS''$$

$$S'' \to b \mid RS$$

$$L \to a$$

$$R \to b$$

**Определение 2.4.3.** Контекстно-свободная грамматика  $\langle \Sigma, N, P, S \rangle$  находится в *ослабленной Нормальной Форме Хомского*, если она содержит только правила следующего вида:

- $A \to BC$ , где  $A, B, C \in N$
- $A \to a$ , где  $A \in N, a \in \Sigma$
- $A \to \varepsilon$ , где  $A \in N$

То есть ослабленная НФХ отличается от НФХ тем, что:

- $1. \ \varepsilon$  может выводиться из любого нетерминала
- $2. \, \, S$  может появляться в правых частях правил

### 2.4.1 Конъюнктивные и булевы грамматики

Впервые конъюнктивные и булевы грамматики были предложены Александром Охотиным [50, 51]. Дадим определение конъюнктивной грамматики.

**Определение 2.4.4.** Контюнктивной грамматикой называется  $G = (\Sigma, N, P, S)$ , где:

- $\Sigma$  и N дизъюнктивные конечные непустые множества терминалов и нетерминалов.
- P конечное множество продукций, каждая вида

$$A \rightarrow \alpha_1 \& \dots \& \alpha_n$$

,где 
$$A \in N, n \geq 1$$
 и  $\alpha_1, ..., \alpha_n \in (\Sigma \cup N)^*$ .

•  $S \in N$  — стартовый нетерминал.

Конъюнктивная грамматика генерирует строки, выводя их из начального символа, так же, как это происходит в контекстно-свободных грамматиках в параграфе 2.1. Промежуточные строки, используемые в процессе вывода, являются формулами следующего вида:

**Определение 2.4.5.** Пусть  $G = (\Sigma, N, P, S)$  — конъюнктивная грамматика. Множество конъюнктивных формул  $\mathcal{F}$  определяется индуктивно:

- Пустая строка  $\varepsilon$  конъюнктивная формула.
- Любой символ из  $(\Sigma \cup N)$  формула.
- $\bullet$  Если  $\mathcal{A}$  и  $\mathcal{B}$  непустые формулы, тогда  $\mathcal{AB}$  формула.
- Если  $A_1, \ldots, A_n \ (n \geqslant 1)$  формула, тогда  $(A_1 \& \ldots \& A_n)$  формула.

**Определение 2.4.6.** Пусть  $G = (\Sigma, N, P, S)$  — конъюнктивная грамматика. Аналогично определению отношения непосредственной выводимости в контекстносвободной грамматике 2.1.2 определим  $\Rightarrow_G$  как отношение непосредственной выводимости на множестве конъюнктивных формул.

• Любой нетерминал в любой формуле может быть перезаписан телом любого правила для этого терминала заключенным в скобки. То есть для любых  $s', s'' \in (\Sigma \cup N \cup \{(, \&,)\})^*$  и  $A \in N$ , таких что s'As'' - формула, и для всех правил вида  $A \to \alpha_1 \& \dots \& \alpha_n \in P$ , имеем  $s'As'' \Rightarrow s'(\alpha_1 \& \dots \& \alpha_n)s''$ .

35

• Если формула содержит подформулу в виде конъюнкции одной или нескольких одинаковых терминальных строк, заключенных в скобки, тогда подформула может быть перезаписана терминальной строкой без скобок. То есть для любых  $s^{'}, s^{''} \in (\Sigma \cup N \cup \{(, \&,)\})^*, (n \geqslant 1)$  и  $w \in \Sigma^*$ , таких что  $s^{'}(w\& \ldots\&w)s^{''}$  — формула, имеем  $s^{'}(w\& \ldots\&w)s^{''} \Rightarrow s^{'}ws^{''}$ .

Как и в случае контекстно-свободной грамматики обозначим  $\Rightarrow^*_G$  рефлексивное транзитивное замыкание отношения  $\Rightarrow_G$ .

Определение 2.4.7. Пусть  $G = (\Sigma, N, P, S)$  — конъюнктивная грамматика. Язык, порождаемый формулой, это множество всех терминальных строк выводимых из этой формулы:  $L_G(\mathcal{A}) = \{w \in \Sigma^* \mid \mathcal{A} \Longrightarrow_G^* w\}$ . Очевидно, что язык порождаемый грамматикой, это язык порождаемый стартовым нетерминалом  $S: L(G) = L_G(S) = L(S)$ .

**Теорема 2.4.7.** Пусть  $G = (\Sigma, N, P, S)$  — конъюнктивная грамматика. Пусть  $A_1, \ldots, A_n, \mathcal{B}$  — формулы,  $A \in N$ ,  $a \in \Sigma$ . Тогда,

- 1.  $L(\varepsilon) = \{\varepsilon\}$ .
- 2.  $L(a) = \{a\}.$
- 3.  $L(A) = \bigcup_{A \to \alpha_1 \& k} \mathcal{L}(\alpha_1 \& \dots \& \alpha_m)$ .
- 4.  $L(\mathcal{AB}) = L(\mathcal{A}) * L(\mathcal{B})$
- 5.  $L((\mathcal{A}_1 \& \dots \& \mathcal{A}_n)) = \bigcap_{i=1}^n L(\mathcal{A}_i).$

Теорема 2.4.7 уже подразумевает интерпретацию грамматики как системы уравнений. Используем математический подход, чтобы лучше охарактеризовать конъюнктивные языки с помощью систем уравнений.

Определение 2.4.8 (Выражение). Пусть  $\Sigma$  конечный непустой алфавит. Пусть  $X = \{X_1, \dots, X_N\}$  вектор переменных. Выражение над алфавитом  $\Sigma$ , зависящее от переменных X, определяется индуктивно:

- $\varepsilon$  выражение.
- Любой символ  $a \in \Sigma$  выражение.
- Любая переменная  $X_i \in X$  выражение.
- Если  $\phi_1$  и  $\phi_2$  выражения, то  $\phi_1\phi_2$ ,  $(\phi_1 \mid \phi_2)$ ,  $(\phi_1\&\phi_2)$  также выражения.

Заметим, что любая формула, в терминах определения 2.4.5, является выражением, где нетерминалы формулы это переменные выражения. С другой стороны, любое выражение, не содержащее дизъюнкции, формула.

Предположим, что переменные  $X_i$  приняли в качестве значений слова из языка над алфавитом  $\Sigma$ . Определим значение всего выражения.

Определение 2.4.9 (Значение выражения). Пусть  $L = (L_1, ..., L_n)(L_i \subseteq \Sigma^*)$  вектор из n языков над  $\Sigma$ , где  $n \geqslant 1$ . Пусть  $\phi$  выражение над  $\Sigma$ , зависящее от переменных  $X_1, ..., X_n$ . Значение выражения  $\phi$  на векторе L — это язык над тем же алфавитом  $\Sigma$ . Обозначим его  $\phi(L)$  и определим индуктивно на структуре выражения:

- $\varepsilon(L) = \{\varepsilon\}.$
- $a(L) = \{a\}$  для любого  $a \in \Sigma$ .
- $X_i(L) = L_i$  для любого  $X_i \in X$ .
- $\phi_1\phi_2 = \phi_1(L) * \phi_2(L), (\phi_1 \mid \phi_2)(L) = \phi_1(L) \cup \phi_2(L), (\phi_1\&\phi_2)(L) = \phi_1(L) \cap \phi_2(L)$  для любых выражений  $\phi_1$  и  $\phi_2$ .

Обобщим определение 2.4.9 на случай вектора выражений.

Определение 2.4.10 (Значение вектора выражений). Пусть  $L = (L_1, \ldots, L_n)(L_i \subseteq \Sigma^*)$  вектор из n языков над  $\Sigma$ , где  $n \geqslant 1$ . Пусть  $\phi_1, \ldots, \phi_m$  выражения над  $\Sigma$ , зависящее от переменных  $X_1, \ldots, X_n$ . Значение вектора выражений  $P = (\phi_1, \ldots, \phi_m)$  на векторе L — это вектор языков  $P(L) = (\phi_1(L), \ldots, \phi_m(L))$  над тем же алфавитом  $\Sigma$ .

Зададим частичный порядок относительно включения "  $\preccurlyeq$  " на множестве языков и расширим его на вектора языков длины  $n\colon (L_1',\dots,L_n') \preccurlyeq (L_1'',\dots,L_n'')$  если и только если  $L_i'\subseteq L_i''$  для любого  $1\leqslant i\leqslant n$ 

Определение 2.4.11. X = P(X) система уравнений над алфавитом  $\Sigma$  и  $X = \{X_1, \dots, X_n\}$ , где  $P = (\phi_1, \dots, \phi_n)$  вектор выражений над алфавитом  $\Sigma$ , зависящий от X.

Вектор языков  $L = (L_1, \dots, L_n)$  является решением системы уравнений если L = P(L).

Наименьшее решение L это вектор языков, такой что для любого другого сравнимого вектора языков  $L^{'}$  выполняется  $L \preccurlyeq L^{'}$ .

37

Заметим, что оператор P на множестве  $2^{\Sigma} \times \ldots \times 2^{\Sigma}$ , что решение системы 2.4.11 это неподвижная точка P и что наименьшее решение системы это наименьшая неподвижная точка оператора P.

**Теорема 2.4.8.** Для любой системы из определения 2.4.11 с переменными  $X_1, \ldots, X_n$ , оператор  $P = (\phi_1, \ldots, \phi_n)$  имеет наименьшую неподвижную точку  $L = (L_1, \ldots, L_n) = \lim_{i \to \infty} P^i \underbrace{(\varnothing, \ldots, \varnothing)}_n$ .

Приведем пример конъюнктивной грамматики.

**Пример 2.4.2** (Пример конъюнктивной грамматики). Следующая конъюнктивная грамматика G порождает язык  $\{a^nb^nc^n \mid n \geq 0\}$ :

$$1. S \to AB\&DC$$

2. 
$$A \rightarrow aA \mid \varepsilon$$

3. 
$$B \rightarrow bBc \mid \varepsilon$$

4. 
$$C \rightarrow cC \mid \varepsilon$$

5. 
$$D \to aDb \mid \varepsilon$$

Легко видеть, что  $L(AB)=\{a^ib^jc^k\mid j=k\}$  и  $L(DC)=\{a^ib^jc^k\mid i=j\}.$  Тогда  $L(S)=L(AB)\cap L(DC)=\{a^nb^nc^n\mid n\geq 0\}.$ 

В этой грамматике строка *abc* может быть получена следующим образом. Для начала представим грамматику в виде системы уравнений:

$$S = AB \cap DC$$

$$A = \{a\}A \cup \varepsilon$$

$$B = \{b\}B\{c\} \cup \varepsilon$$

$$C = \{c\}C \cup \varepsilon$$

$$D = \{a\}D\{b\} \cup \varepsilon$$

Используя теорему 2.4.8, будем итеративно вычислять  $P^i(\underbrace{\varnothing,\ldots,\varnothing}_{\mathtt{E}})$ . На каж-

дом шаге будем подставлять все терминальные строки из языков, порожденных нетерминалами на предыдущем шаге, в соответствующие нетерминалы правой части каждого уравнения и записывать получившиеся терминальные строки в языки нетерминалов текущего шага. Продолжаем до тех пор пока язык, порождаемый нетерминалом S, не будет содержать терминальную строку "abc".

- 1. На начальном этапе имеем  $P^0(\varnothing,\ldots,\varnothing)=(S:\varnothing,A:\varnothing,B:\varnothing,C:\varnothing,D:\varnothing)$
- 2. Подставляем в первое уравнение терминальные строки из шага 1 в соответствующие нетерминалы, т.е.

$$S: \varnothing = \varnothing \varnothing \cap \varnothing \varnothing$$

$$A: \{\varepsilon\} = \{a\} \varnothing \cup \{\varepsilon\}$$

$$B: \{\varepsilon\} = \{b\} \varnothing \{c\} \cup \{\varepsilon\}$$

$$C: \{\varepsilon\} = \{c\} \varnothing \cup \{\varepsilon\}$$

$$D: \{\varepsilon\} = \{a\} \varnothing \{b\} \cup \{\varepsilon\}$$

В конце итерации получаем  $P^1(\varnothing,\ldots,\varnothing)=(S:\varnothing,A:\{\varepsilon\},B:\{\varepsilon\},C:\{\varepsilon\},D:\{\varepsilon\})$ 

3. Делаем еще одну итерацию,

$$S: \{\varepsilon\} = \{\varepsilon\} \{\varepsilon\} \cap \{\varepsilon\} \{\varepsilon\}$$

$$A: \{a, \varepsilon\} = \{a\} \{\varepsilon\} \cup \{\varepsilon\}$$

$$B: \{bc, \varepsilon\} = \{b\} \{\varepsilon\} \{c\} \cup \{\varepsilon\}$$

$$C: \{c, \varepsilon\} = \{c\} \{\varepsilon\} \cup \{\varepsilon\}$$

$$D: \{ab, \varepsilon\} = \{a\} \{\varepsilon\} \{b\} \cup \{\varepsilon\}$$

В конце итерации получаем  $P^2(\varnothing,\ldots,\varnothing)=(S:\{\varepsilon\},A:\{a,\varepsilon\},B:\{bc,\varepsilon\},C:\{c,\varepsilon\},D:\{ab,\varepsilon\})$ 

4. Еще одна итерация,

$$S: \{ [abc], \varepsilon \} = \{a, \varepsilon \} \{bc, \varepsilon \} \cap \{ab, \varepsilon \} \{c, \varepsilon \}$$

$$A: \{a, aa, \varepsilon \} = \{a\} \{a, \varepsilon \} \cup \{\varepsilon \}$$

$$B: \{bc, bbcc, \varepsilon \} = \{b\} \{bc, \varepsilon \} \{c \} \cup \{\varepsilon \}$$

$$C: \{c, cc, \varepsilon \} = \{c \} \{c, \varepsilon \} \cup \{\varepsilon \}$$

$$D: \{ab, aabb, \varepsilon \} = \{a\} \{ab, \varepsilon \} \{b \} \cup \{\varepsilon \}$$

В конце итерации получили  $P^3(\varnothing,\ldots,\varnothing)=(S:\{abc,\varepsilon\},A:\{a,aa,\varepsilon\},B:\{bc,bbcc,\varepsilon\},C:\{c,cc,\varepsilon\},D:\{ab,aabb,\varepsilon\})$ . Заметим, что терминальная строка "abc" появилась в языке, который порождает стартовый нетерминал S. Т.е. терминальная строка "abc" выводима в грамматике G, что и требовалось показать.

39

Заметим, что строку "abc" также можно получить применением правил вывода. здесь цифра над стрелкой соответствует номеру примененного правила.

$$S \stackrel{1}{\Rightarrow} (AB\&DC)$$

$$\stackrel{?}{\Rightarrow} (aAB\&DC) \stackrel{?}{\Rightarrow} (a\varepsilon B\&DC)$$

$$\stackrel{3}{\Rightarrow} (abBc\&DC) \stackrel{3}{\Rightarrow} (ab\varepsilon c\&DC)$$

$$\stackrel{5}{\Rightarrow} (abc\&aDbC) \stackrel{5}{\Rightarrow} (abc\&a\varepsilon bC)$$

$$\stackrel{4}{\Rightarrow} (abc\&abcC) \stackrel{4}{\Rightarrow} (abc\&abc\varepsilon)$$

$$\Rightarrow (abc\&abc) \Rightarrow abc$$

**Пример 2.4.3.** Конъюнктивная грамматика G для языка  $L = \{wcw \mid w \in \{a,b\}^*\}$ :

$$\begin{split} S &\to C\&D \\ C &\to aCa \mid aCb \mid bCa \mid bCb \mid c \\ D &\to aA\&aD \mid bB\&bD \mid cE \\ A &\to aAa \mid aAb \mid bAa \mid bAb \mid cEa \\ B &\to aBa \mid aBb \mid bBa \mid bBb \mid cEb \\ E &\to aE \mid bE \mid \varepsilon \end{split}$$

Подробнее о конъюнктивных грамматиках можно прочитать в статьях [50, 55, 52, 53].

Дадим определение булевой грамматики.

**Определение 2.4.12.** *Булевой грамматикой* называется  $G = (\Sigma, N, P, S)$ , где:

- $\Sigma$  и N дизъюнктивные конечные непустые множества терминалов и нетерминалов.
- Р конечное множество продукций, каждая вида

$$A \to \alpha_1 \& \dots \& \alpha_m \& \neg \beta_1 \& \dots \& \neg \beta_n$$

,где 
$$A \in N, m, n >= 0, m + n \ge 1$$
 и  $\alpha_i, \beta_j \in (\Sigma \cup N)^*$ .

•  $S \in N$  — стартовый нетерминал.

Приведем пример булевой грамматики.

**Пример 2.4.4.** Следующая булева грамматика порождает язык  $\{a^mb^nc^n\mid m,n\geq 0,m\neq n\}$ :

$$S \to AB \& \neg DC$$

$$A \to aA \mid \varepsilon$$

$$B \to bBc \mid \varepsilon$$

$$C \to cC \mid \varepsilon$$

$$D \to aDb \mid \varepsilon$$

Очевидно, что  $L(AB) = \{a^mb^nc^n \mid m,n \in \mathbb{N}\}$  и  $L(DC) = \{a^nb^nc^m \mid m,n \in \mathbb{N}\}$ . Тогда  $L(AB) \cap \overline{L(DC)} = \{a^mb^nc^n \mid m,n \geq 0, m \neq n\}$ .

Подробнее о булевых грамматиках можно прочитать в статьях [51, 54]. Определим бинарную нормальную форму конъюнктивной грамматики.

**Определение 2.4.13** (Бинарная нормальная форма). Конъюнктивная грамматика  $G = (\Sigma, N, P, S)$  находится в бинарной нормальной форме, если каждое правило из P имеет вид,

- $A \to B_1 C_1 \& \dots \& B_m C_m$ , где  $m \geqslant 1; A, B_i, C_i \in N$ .
- $A \to a$ , где  $A \in N$ ,  $a \in \Sigma$ .
- $S \to \varepsilon$ , если только S не содержится в правой части всех правил.

**Теорема 2.4.9.** Для каждой конъюнктивной грамматики G можно построить конъюнктивную грамматику в бинарной нормальной форме G', такую что L(G) = L(G').

Доказательство теоремы 2.4.9 описано в статье [50].

### 2.5 Вопросы и задачи

- 1. Постройте дерево вывода цепочки w=aababb в грамматике  $G=\langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \mid S \mid b \mid S\}, S \rangle$ .
- 2. Постройте все левосторонние выводы цепочки w = ababab в грамматике  $G = \langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \ S \ b \ | S \ S\}, S \rangle.$

- 3. Постройте все правосторонние выводы цепочки w=ababab в грамматике  $G=\langle\{a,b\},\{S\},\{S
  ightarrow\varepsilon\mid a\ S\ b\ |S\ S\},S\rangle.$
- 4. Постройте все деревья вывода цепочки w=ababab в грамматике  $G=\langle \{a,b\}, \{S\}, \{S\to\varepsilon\mid a\ S\ b\ |S\ S\}, S\rangle,$  соответствующие левосторонним выводам.
- 5. Постройте все деревья вывода цепочки w = ababab в грамматике  $G = \langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \ S \ b \ | S \ S\}, S \rangle$ , соответствующие правосторонним выводам.

# Глава 3

# Задача о поиске путей с ограничениями в терминах формальных языков

В данной главе сформулируем постановку задачи о поиске путей в графе с ограничениями. А также приведём несколько примеров областей, в которых применяются алгоритмы решения этой задачи.

# 3.1 Постановка задачи

Пусть нам дан конечный ориентированный помеченный граф  $\mathcal{G} = \langle V, E, L \rangle$ . Функция  $\omega(\pi) = \omega((v_0, l_0, v_1), (v_1, l_1, v_2), \dots, (v_{n-1}, l_{n-1}, v_n)) = l_0 \cdot l_1 \cdot \dots \cdot l_{n-1}$  строит слово по пути посредством конкатенации меток рёбер вдоль этого пути. Очевидно, для пустого пути данная функция будет возвращать пустое слово, а для пути длины n > 0— непустое слово длины n.

Если теперь рассматривать задачу поиска путей, то окажется, что то множество путей, которое мы хотим найти, задаёт множество слов, то есть язык. А значит, критерий поиска мы можем сформулировать следующим образом: нас интересуют такие пути, что слова из меток вдоль них принадлежат заданному языку.

Определение 3.1.1. Задача поиска путей с ограничениями в терминах формальных языков заключается в поиске множества путей  $\Pi = \{\pi \mid \omega(\pi) \in \mathcal{L}\}.$ 

В задаче поиска путей мы можем накладывать дополнительные ограничения на путь (например, чтобы он был простым, кратчайшим или Эйлеровым [42]), но это уже другая история.

Другим вариантом постановки задачи является задача достижимости.

**Определение 3.1.2.** Задача достижимости заключается в поиске множества пар вершин, для которых найдется путь с началом и концом в этих вершинах, что слово, составленное из меток рёбер пути, будет принадлежать заданному языку.  $\Pi' = \{(v_i, v_j) \mid \exists v_i \pi v_j, \omega(\pi) \in \mathcal{L}\}.$ 

При этом, множество  $\Pi$  может являться бесконечным, тогда как  $\Pi'$  конечно, по причине конечности графа  $\mathcal{G}$ .

Язык  $\mathcal{L}$  может принадлежать разным классам и быть задан разными способами. Например, он может быть регулярным, или контекстно-свободным, или многокомпонентным контекстно-свободным.

Если  $\mathcal{L}$  — регулярный,  $\mathcal{G}$  можно рассматривать как недетерминированный конечный автомат (НКА), в котором все вершины и стартовые, и конечные. Тогда задача поиска путей, в которой  $\mathcal{L}$  — регулярный, сводится к пересечению двух регулярных языков.

Более подробно мы рассмотрим случай, когда  $\mathcal{L}$  — контекстно-свободный язык.

Путь  $G = \langle \Sigma, N, P \rangle$  — контекстно-свободная граммтика. Будем считать, что  $L \subseteq \Sigma$ . Мы не фиксируем стартовый нетерминал в определении грамматики, поэтому, чтобы описать язык, задаваемый ей, нам необходимо отдельно зафиксировать стартовый нетерминал. Таким образом, будем говорить, что  $L(G, N_i) = \{w | N_i \overset{*}{\underset{G}{\Rightarrow}} w\}$  — это язык задаваемый граммтикой G со стартовым нетерминалом  $N_i$ .

#### Пример 3.1.1. Пример задачи поиска путей.

Дана грамматика G:


$$S \to ab$$
$$S \to aSb$$

Эта грамматика задаёт язык  $\mathcal{L} = a^n b^n$ .


И дан граф  $\mathcal{G}$ :

#### 3.2. О разрешимости задачи

45



Тогда примерами путей, принадлежащих множеству  $\Pi = \{\pi \mid \omega(\pi) \in \mathcal{L}\},$  являются:



## 3.2 О разрешимости задачи

Задачи из определения 3.1.1 и 3.1.2 сводятся к построению пересечения языка  $\mathcal{L}$  и языка, задаваемого путями графа, R. А мы для обсуждения разрешимости задачи рассмотрим более слабую постановку задачи:

**Определение 3.2.1.** Необходимо проверить, что существует хотя бы один такой путь  $\pi$  для данного графа, для данного языка  $\mathcal{L}$ , что  $\omega(\pi) \in \mathcal{L}$ .

Эта задача сводится к проверке пустоты пересечения языка  $\mathcal{L}$  с R — регулярным языком, задаваемым графом. От класса языка  $\mathcal{L}$  зависит её разрешимость:

• Если  $\mathcal{L}$  регулярный, то получаем задачу пересечения двух регулярных языков:

 $\mathcal{L} \cap R = R'$ . R' — также регулярный язык. Проверка регулярного языка на пустоту — разрешимая проблема.

- $\bullet$  Если  $\mathcal L$  контекстно-свободный, то получаем задачу
  - $\mathcal{L} \cap R = CF$  контекстно-свободный. Проверка контекстно-свободного языка на пустоту разрешимая проблема.
- Помимо иерархии Хомского существуют и другие классификации языков. Так например, класс конъюнктивных (Conj) языков [50] является строгим расширением контекстно-свободных языков и все так же позволяет полиномиальный синтаксический анализ.
  - Пусть  $\mathcal{L}$  конъюнктивный. При пересечении конъюнктивного и регулярного языков получается конъюнктивный ( $\mathcal{L} \cap R = Conj$ ), а проблема проверки Conj на пустоту не разрешима [52].
- Ещё один класс языков из альтернативной иерархии, не сравнимой с Иерархией Хомского, MCFG (multiple context-free grammars) [67]. Как его частный случай TAG (tree adjoining grammar) [37].
  - Если  $\mathcal{L}$  принадлежит классу MCFG, то  $\mathcal{L} \cap R$  также принадлежит MCFG. Проблема проверки пустоты MCFG разрешима [67].

Существует ещё много других классификаций языков, но поиск универсальной иерархии до сих пор продолжается.

Далее, для изучения алгоритмов решения, нас будет интересовать задача  $R\cap CF$ .

# 3.3 Области применения

- Статанализ. Введено Томасом Репсом [60].
- Социальные сети [32].
- RDF обработка [86].
- Биоинформатика [68].
- Применяется для различных межпроцедурных задач [57, 11, 87].
- Графовые БД Впервые предложил Михалис Яннакакис [84].

47

# 3.4 Вопросы и задачи

- 1. Пусть есть граф. Задайте грамматику для поиска всех путей, таких, что....
- 2. Существует ли в графе !!! путь из А в Б, такой что!!!
- 3. Для графа !!! постройте все пути, удовлетворяющие !!!!
- 4. Задача 1
- 5. Задача 2

48 Глава 3. Задача о поиске путей с ограничениями в терминах формальных языков

# Глава 4

# СҮК для вычисления КС запросов

В данной главе мы рассмотрим алгоритм СҮК, позволяющий установить принадлежность слова грамматике и предоставить его вывод, если таковой имеется.

Наш главный интерес заключается в возможности применения данного алгоритма для решения описанной в предыдущей главе задачи — поиска путей с ограничениями в терминах формальных языков. Как уже было указано выше, будем рассматривать случай контекстно-свободных языков.

# 4.1 Алгоритм СҮК

Алгоритм СҮК (Cocke-Younger-Kasami) — один из классических алгоритмов синтаксического анализа. Его асимптотическая сложность в худшем случае —  $O(n^3*|G|)$  (n — размер входной строки, G — входная грамматика), что выгодно выделяет его среди других алгоритмов парсинга. [36]

Для его применения необходимо, чтобы подаваемая на вход грамматика находилась в Нормальной Форме Хомского (НФХ) 2.4.

В основе алгоритма лежит принцип динамического программирования. Используются два соображения (здесь  $\omega$  — слово, A, B, C — нетерминалы грамматики, a — терминал грамматики):

1. Для правила вида  $A \to a$  очевидно, что из A выводится  $\omega$  (с применением этого правила) тогда и только тогда, когда  $a = \omega$ :

$$A \Rightarrow a \stackrel{*}{\Rightarrow} \omega \iff \omega = a$$

2. Для правила вида  $A \to BC$  понятно, что из A выводится  $\omega$  (с применением этого правила) тогда и только тогда, когда существуют две цепочки  $\omega_1$  и  $\omega_2$  такие, что  $\omega_1$  выводима из B,  $\omega_2$  выводима из C и при этом  $\omega = \omega_1 \omega_2$ :

$$A \Rightarrow BC \stackrel{*}{\Rightarrow} \omega \iff \exists \omega_1, \omega_2 : \omega = \omega_1 \omega_2, B \stackrel{*}{\Rightarrow} \omega_1, C \stackrel{*}{\Rightarrow} \omega_2$$

Или в терминах позиций в строке:

$$A \Rightarrow BC \stackrel{*}{\Rightarrow} \omega \iff \exists k \in [1 \dots |\omega|] : B \stackrel{*}{\Rightarrow} \omega[1 \dots k], C \stackrel{*}{\Rightarrow} \omega[k+1 \dots |\omega|]$$

В процессе работы алгоритма заполняется булева трехмерная матрица размера  $|N| \times n \times n$ , где n — размер входной цепочки, N — множество нетерминалов в нормализованной грамматике.  $M[i,j,A] = true \iff A \stackrel{*}{\Rightarrow} \omega[i\dots j]$ 

Первым шагом инициализируем матрицу, заполнив значения M[i,j,A], где i=j:

- M[i,i,A]=true, если в грамматике есть правило  $A \to \omega[i].$
- M[i, i, A] = false, иначе.

Далее используем динамику: на шаге m>1 предполагаем, что ячейки матрицы M[i',j',A] заполнены для всех нетерминалов A и пар i',j':j'-i'< m. Тогда можно заполнить ячейки матрицы M[i,j,A], где j-i=m

$$M[i,j,A] = \bigvee_{A \to BC} \bigvee_{k=i}^{j-1} M[i,k,B] \land M[k,j,C]$$

По итогу работы алгоритма значение в ячейке  $M[0,|\omega|,S]$ , где S — стартовый нетерминал грамматики, отвечает на вопрос о выводимости цепочки  $\omega$  в грамматике.

**Пример 4.1.1.** Рассмотрим пример работы алгоритма СҮК на грамматике правильных скобочных последовательностей в Нормальной Форме Хомского.

$$S \to AS_2 \mid \varepsilon$$

$$S_1 \to AS_2$$

$$S_2 \to b \mid BS_1 \mid SS_3$$

$$S_3 \to b \mid BS_1$$

$$A \to a$$

$$B \to b$$

Проверим выводимость цепочки  $\omega = aabbab$ .

Так как трехмерные матрицы рисовать на двумерной бумаге не очень удобно, мы будем иллюстрировать работу алгоритма двумерными матрицами размера  $n \times n$ , где в ячейках указано множество нетерминалов, выводящих соответствующую подстроку.

Шаг 1. Инициализируем матрицу элементами на главной диагонали:

$$\begin{pmatrix} \{A\} & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing \\ \varnothing & \{A\} & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \varnothing & \{A\} & \varnothing \\ \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} \end{pmatrix}$$

Шаг 2. Заполняем диагональ, находящуюся над главной:

$$\begin{pmatrix} \{A\} & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing \\ \varnothing & \{A\} & \{S_1\} & \varnothing & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \varnothing & \{A\} & \{S_1\} \\ \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} \end{pmatrix}$$

Шаг 3. Заполняем следующую диагональ:

$$\begin{pmatrix} \{A\} & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing \\ \varnothing & \{A\} & \{S_1\} & \{S_2\} & \varnothing & \varnothing \\ \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \{S_2, S_3\} \\ \varnothing & \varnothing & \varnothing & \varnothing & \{A\} & \{S_1\} \\ \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \emptyset & \{B, S_2, S_3\} \end{pmatrix}$$

Шаг 4. И следующую за ней:

$$\begin{pmatrix} \{A\} & \varnothing & \varnothing & \{S_1, S\} & \varnothing & \varnothing \\ \varnothing & \{A\} & \{S_1\} & \{S_2\} & \varnothing & \varnothing \\ \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \{S_2, S_3\} \\ \varnothing & \varnothing & \varnothing & \varnothing & \{A\} & \{S_1\} \\ \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} \end{pmatrix}$$

Шаг 5 Заполняем предпоследнюю диагональ:

$$\begin{pmatrix} \{A\} & \varnothing & \varnothing & \{S_1, S\} & \varnothing & \varnothing \\ \varnothing & \{A\} & \{S_1\} & \{S_2\} & \varnothing & \{S_2\} \\ \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \{S_2, S_3\} \\ \varnothing & \varnothing & \varnothing & \varnothing & \{A\} & \{S_1\} \\ \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} \end{pmatrix}$$

Шаг 6. Завершаем выполнение алгоритма:

$$\begin{pmatrix} \{A\} & \varnothing & \varnothing & \{S_1, S\} & \varnothing & \{S_1, S\} \\ \varnothing & \{A\} & \{S_1\} & \{S_2\} & \varnothing & \{S_2\} \\ \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \{S_2, S_3\} \\ \varnothing & \varnothing & \varnothing & \varnothing & \{A\} & \{S_1\} \\ \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \emptyset & \{B, S_2, S_3\} \end{pmatrix}$$

Стартовый нетерминал находится в верхней правой ячейке, а значит цепочка aabbab выводима в нашей грамматике.

**Пример 4.1.2.** Теперь выполним алгоритм на невыводимой цепочке abaa.

Шаг 1. Инициализируем таблицу:

$$\begin{pmatrix}
\{A\} & \varnothing & \varnothing & \varnothing \\
\varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing \\
\varnothing & \varnothing & \{A\} & \varnothing \\
\varnothing & \varnothing & \varnothing & \{A\}
\end{pmatrix}$$


Шаг 2. Заполняем следующую диагональ:

$$\begin{pmatrix}
\{A\} & \{S_1, S\} & \varnothing & \varnothing \\
\varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing \\
\varnothing & \varnothing & \{A\} & \varnothing \\
\varnothing & \varnothing & \varnothing & \{A\}
\end{pmatrix}$$

Больше ни одну ячейку в таблице заполнить нельзя, а значит эта строка не выводится в грамматике правильных скобочных последовательностей.

# 4.2 Алгоритм для графов на основе СҮК

Теперь изменим вид входного слова и немного модифицируем алгоритм. Прежде мы сопоставляли каждому символу слова номер его позиции в цепочке, поэтому при инициализации заполняли главную диагональ матрицы. Вместо этого обозначим числами позиции между буквами таким образом (в качестве примера рассмотрим слово *aabbab* из предыдущего пункта):



Что нужно изменить в описании алгоритма, чтобы он продолжал работать при подобной нумерации? Каждая буква теперь идентифицируется не одним числом, а парой – номера слева и справа от нее. При этом чисел стало на одно больше, чем при прежнем способе нумерации.

Возьмем матрицу  $|N| \times (n+1) \times (n+1)$  и при инициализации будем заполнять не главную диагональ, а диагональ прямо над ней. Таким образом, мы начинаем наш алгоритм с определения значений M[i,j,A], где j=i+1. При этом наши дальнейшие действия в рамках алгоритма не изменятся.

На шаге инициализации матрица выглядит следующим образом:

$$\begin{pmatrix} \varnothing & \{A\} & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \{A\} & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \{A\} & \varnothing \\ \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} \\ \varnothing & \varnothing \end{pmatrix}$$

А в результате работы алгоритма имеем:

$$\begin{pmatrix} \varnothing & \{A\} & \varnothing & \varnothing & \{S_1, S\} & \varnothing & \{S_1, S\} \\ \varnothing & \varnothing & \{A\} & \{S_1\} & \{S_2\} & \varnothing & \{S_2\} \\ \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \varnothing & \varnothing \\ \varnothing & \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \{S_2, S_3\} \\ \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \{B, S_2, S_3\} & \varnothing & \{S_2, S_3\} \\ \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \varnothing & \{A\} & \{S_1\} \\ \varnothing & \varnothing \end{pmatrix}$$

Мы представили входную строку в виде линейного графа, а на шаге инициализации получили его матрицу смежности. Шаги алгоритма очень напоминают построение транзитивного замыкания графа. Различие заключается в том, что мы "добавляем ребра" только для тех пар нетерминалов, для которых существует правило в грамматике, их выводящее.

Алгоритм можно обобщить и на произвольные графы с метками, рассматриваемые в этом курсе. При этом накладывается ограничение на форму входной грамматики: она должна находиться в ослабленной Нормальной Форме Хомского 2.4. То есть будем требовать выполнение только следующих правил:

- $A \to BC$ , где  $A, B, C \in N$
- $A \to a$ , где  $A \in N$ ,  $a \in \Sigma$

Шаг инициализации в алгоритме заключается в том, что мы с помощью продукций вида

$$A \to a$$
, где  $A \in N, a \in \Sigma$ 

заменяем терминалы на ребрах входного графа на нетерминалы, из которых они выводятся. Затем используем матрицу смежности получившегося графа (обозначим ее M) в качестве начального значения. Дальнейший ход алгоритма можно описать псевдокодом:


55

#### Algorithm 2 Context-free recognizer for graphs

```
1: function CONTEXTFREEPATHQUERYING(G, \mathcal{G})
        n \leftarrow the number of nodes in \mathcal{G}
        M \leftarrow the modified adjacency matrix of \mathcal{G}
 3:
        P \leftarrow the set of production rules in G
 4:
 5:
        while M is changing do
            for k \in 0..n do
 6:
                for i \in 0..n do
 7:
                    for j \in 0..n do
 8:
                        for all N_1 \in M[i, k], N_2 \in M[k, j] do
 9:
10:
                            if N_3 \to N_1 N_2 \in P then
                                M[i, j] += \{N_3\}
11:
12:
        return M
```

Если в некоторой ячейке результирующей матрицы с номером (i,j) находятся стартовый нетерминал, то это означает, что существует путь из вершины i в вершину j, удовлетворяющий данной грамматике.

Пример 4.2.1. Рассмотрим работу алгоритма на графе



и грамматике:

$$S \to AB$$

$$S \to AS_1$$


$$S_1 \to SB$$

$$A \to a$$

$$B \to b$$

Данный пример является классическим и еще не раз будет использоваться в рамках данного курса.

**Инициализация.** Заменяем терминалы на ребрах графа на нетерминалы, из которых они выводятся, и строим матрицу смежности получившегося графа:



$$\begin{pmatrix} \varnothing & \{A\} & \varnothing & \varnothing \\ \varnothing & \varnothing & \{A\} & \varnothing \\ \{A\} & \varnothing & \varnothing & \{B\} \\ \varnothing & \varnothing & \{B\} & \varnothing \end{pmatrix}$$

**Итерация 1.** Итерируемся по k, i и j, пытаясь найти пары нетерминалов, для которых существуют правила вывода, их выводящие. Нам интересны следующие случаи:

- $k=2, i=1, j=3: A \in M[1,2], B \in M[2,3]$ , так как в грамматике присутствует правило  $S \to AB$ , добавляем нетерминал S в ячейку M[1,3].
- $k=3, i=1, j=2: S\in M[1,3], B\in M[3,2]$ , поскольку в грамматике есть правило  $S_1\to SB$ , добавляем нетерминал  $S_1$  в ячейку M[1,2].

В остальных случаях либо какая-то из клеток пуста, либо не существует продукции в грамматике, выводящей данные два нетерминала.

Матрица после данной итерации:

$$\begin{pmatrix} \varnothing & \{A\} & \varnothing & \varnothing \\ \varnothing & \varnothing & \{A, S_1\} & \{S\} \\ \{A\} & \varnothing & \varnothing & \{B\} \\ \varnothing & \varnothing & \{B\} & \varnothing \end{pmatrix}$$

57

**Итерация 2.** Снова итерируемся по k, i, j. Рассмотрим случаи:

- $k = 1, i = 0, j = 2 : A \in M[0, 1], S_1 \in M[1, 2]$ , так как в грамматике присутствует правило  $S \to AS_1$ , добавляем нетерминал S в ячейку M[0, 2].
- $k=2, i=0, j=3: S\in M[0,2], B\in M[2,3]$ , поскольку в грамматике есть правило  $S_1\to SB$ , добавляем нетерминал  $S_1$  в ячейку M[0,3].

Матрица на данном шаге:

$$\begin{pmatrix}
\varnothing & \{A\} & \{S\} & \{S_1\} \\
\varnothing & \varnothing & \{A, S_1\} & \{S\} \\
\{A\} & \varnothing & \varnothing & \{B\} \\
\varnothing & \varnothing & \{B\} & \varnothing
\end{pmatrix}$$

Итерация 3. Рассматриваемые на данном шаге случаи:

- $k = 0, i = 2, j = 3 : A \in M[2, 0], S_1 \in M[0, 3]$ , так как в грамматике присутствует правило  $S \to AS_1$ , добавляем нетерминал S в ячейку M[2, 3].
- $k=3, i=2, j=2: S\in M[2,3], B\in M[3,2]$ , поскольку в грамматике есть правило  $S_1\to SB$ , добавляем нетерминал  $S_1$  в ячейку M[2,2].

Матрица после этой итерации:

$$\begin{pmatrix}
\varnothing & \{A\} & \{S\} & \{S_1\} \\
\varnothing & \varnothing & \{A, S_1\} & \{S\} \\
\{A\} & \varnothing & \{S_1\} & \{B, S\} \\
\varnothing & \varnothing & \{B\} & \varnothing
\end{pmatrix}$$

Итерация 4. Рассмариваемые случаи:

- $k = 2, i = 1, j = 2 : A \in M[1, 2], S_1 \in M[2, 2]$ , так как в грамматике присутствует правило  $S \to AS_1$ , добавляем нетерминал S в ячейку M[1, 2].
- $k=2, i=1, j=3: S\in M[1,2], B\in M[2,3]$ , поскольку в грамматике есть правило  $S_1\to SB$ , добавляем нетерминал  $S_1$  в ячейку M[1,3].

Матрица:

$$\begin{pmatrix} \varnothing & \{A\} & \{S\} & \{S_1\} \\ \varnothing & \varnothing & \{A, S, S_1\} & \{S, S_1\} \\ \{A\} & \varnothing & \{S_1\} & \{B, S\} \\ \varnothing & \varnothing & \{B\} & \varnothing \end{pmatrix}$$

#### Итерация 5. Рассмотрим на это шаге:

- $k = 1, i = 0, j = 3 : A \in M[0, 1], S_1 \in M[1, 3]$ , поскольку в грамматике есть правило  $S \to AS_1$ , добавляем нетерминал S в ячейку M[0, 3].
- $k=3, i=0, j=2: S\in M[0,3], B\in M[3,2]$ , поскольку в грамматике есть правило  $S_1\to SB$ , добавляем нетерминал  $S_1$  в ячейку M[0,2].

Матрица на этой итерации:

$$\begin{pmatrix} \varnothing & \{A\} & \{S, S_1\} & \{S, S_1\} \\ \varnothing & \varnothing & \{A, S, S_1\} & \{S, S_1\} \\ \{A\} & \varnothing & \{S_1\} & \{B, S\} \\ \varnothing & \varnothing & \{B\} & \varnothing \end{pmatrix}$$

#### Итерация 6. Интересующие нас на этом шаге случаи:

- $k=0, i=2, j=2: A\in M[2,0], S_1\in M[0,2]$ , поскольку в грамматике есть правило  $S\to AS_1$ , добавляем нетерминал S в ячейку M[2,2].
- $k=2, i=2, j=3: S\in M[2,2], B\in M[2,3]$ , поскольку в грамматике есть правило  $S_1\to SB$ , добавляем нетерминал  $S_1$  в ячейку M[2,3].

Матрица после данного шага:

$$\begin{pmatrix} \varnothing & \{A\} & \{S, S_1\} & \{S, S_1\} \\ \varnothing & \varnothing & \{A, S, S_1\} & \{S, S_1\} \\ \{A\} & \varnothing & \{S, S_1\} & \{B, S, S_1\} \\ \varnothing & \varnothing & \{B\} & \varnothing \end{pmatrix}$$

На следующей итерации матрица не изменяется, поэтому заканчиваем работу алгоритма. В результате, если ячейка M[i,j] содержит стартовый нетерминал S, то существует путь из i в j, удовлетворяющий ограничениям, заданным грамматикой.

Можно заметить, что мы делаем много лишних итераций. Можно переписать алгоритм так, чтобы он не просматривал заведомо пустые ячейки. Данную модификацию предложил Хеллингс [31], также она реализована в работе [86].

Псевдокод алгоритма Хеллингса.

#### **Algorithm 3** Context-free recognizer for graphs. Hellings.

```
1: function CONTEXTFREEPATHQUERYING(G = \langle \Sigma, N, P, S \rangle, \mathcal{G} = \langle V, E, L \rangle)
                                                                                  r \leftarrow \{(N_i, v, v) \mid v \in V \land N_i \rightarrow \varepsilon \in P\} \cup \{(N_i, v, u) \mid (v, t, u) \in E \land N_i \rightarrow v \in E \land V_i \rightarrow V_i \rightarrow V_i \rightarrow v \in E \land V_i \rightarrow v \in E \land V_i \rightarrow V_i
                                         t \in P
                                                                              m \leftarrow r
           3:
                                                                                  while m \neq \emptyset do
           4:
                                                                                                                          (N_i, v, u) \leftarrow \text{m.pick}()
           5:
                                                                                                                       for (N_i, v', v) \in r do
           6:
                                                                                                                                                               for N_k \to N_j N_i \in P таких что ((N_k, v', u) \notin r) do
           7:
                                                                                                                                                                                                      m \leftarrow m \cup \{(N_k, v', u)\}
           8:
                                                                                                                                                                                                      r \leftarrow r \cup \{(N_k, v', u)\}
           9:
                                                                                                                       for (N_i, u, v') \in r do
10:
                                                                                                                                                             for N_k \to N_i N_j \in P таких что ((N_k, v, v') \notin r) do
11:
                                                                                                                                                                                                      m \leftarrow m \cup \{(N_k, v, v')\}
12:
                                                                                                                                                                                                      r \leftarrow r \cup \{(N_k, v, v')\}
13:
14:
                                                                              return r
```

Пример 4.2.2. Запустим алгоритм Хеллингса на нашем примере.

#### Инициализация

$$m = r = \{(A, 0, 1), (A, 1, 2), (A, 2, 0), (B, 2, 3), (B, 3, 2)\}$$

**Итерации внешнего цикла.** Будем считеть, что r и m — упорядоченные списки и pick возврпщает его голову, оставляя хвост. Новые элементы добавляются в конец.

- 1. Обрабатываем (A,0,1). Ни один из вложенных циклов не найдёт новых путей, так как для рассматриваемого ребра есть только две возможности достроить путь:  $2 \xrightarrow{A} 0 \xrightarrow{A} 1$  и  $0 \xrightarrow{A} 1 \xrightarrow{A} 2$  и ни одна из соответствующих строк не выводтся в заданной граммтике.
- 2. Перед началом итерации

$$m = \{(A, 1, 2), (A, 2, 0), (B, 2, 3), (B, 3, 2)\},\$$

r не изменилось. Обрабатываем (A,1,2). В данной ситуации второй цикл найдёт тройку (B,2,3) и соответсвующее правило  $S \to A$  B. Это значит, что и в m и в r добавится тройка (S,1,3).

#### 3. Перед началом итерации

$$m = \{(A,2,0), (B,2,3), (B,3,2), (S,1,3)\},$$
 
$$r = \{(A,0,1), (A,1,2), (A,2,0), (B,2,3), (B,3,2), (S,1,3)\}.$$

Обрабатываем (A, 2, 0). Внутринние циклы ничего не найдут, новых путей и появится.

#### 4. Перед началом итерации

$$m = \{(B,2,3), (B,3,2), (S,1,3)\},$$
 
$$r = \{(A,0,1), (A,1,2), (A,2,0), (B,2,3), (B,3,2), (S,1,3)\}.$$

Обрабатываем (B,2,3). Первый цикл мог бы найти (A,1,2), однако при проверке во вложенном цикле выяснится, что (S,1,3) уже найдена. В итоге, на данной итерации новых путей н появится.

#### 5. Перед началом итерации

$$m = \{(B, 3, 2), (S, 1, 3)\},\$$
  
$$r = \{(A, 0, 1), (A, 1, 2), (A, 2, 0), (B, 2, 3), (B, 3, 2), (S, 1, 3)\}.$$

Обрабатываем (B, 3, 2). Первый цикл найдёт (S, 1, 3) и соответствующее правило  $S_1 \to S$  B. Это значит, что и в m и в r добавится тройка  $(S_1, 1, 2)$ .

#### 6. Перед началом итерации

$$m = \{(S, 1, 3), (S_1, 1, 2)\},\$$
  
$$r = \{(A, 0, 1), (A, 1, 2), (A, 2, 0), (B, 2, 3), (B, 3, 2), (S, 1, 3), (S_1, 1, 2)\}.$$

Обрабатываем (S,1,3). Второй цикл мог бы найти (B,3,2), однако при проверке во вложенном цикле выяснится, что  $(S_1,1,2)$  уже найдена. В итоге, на данной итерации новых путей н появится.

#### 7. Перед началом итерации

$$m = \{(S_1, 1, 2)\},\$$
  
 $r = \{(A, 0, 1), (A, 1, 2), (A, 2, 0), (B, 2, 3), (B, 3, 2), (S, 1, 3), (S_1, 1, 2)\}.$ 

Обрабатываем  $(S_1, 1, 2)$ . Первый цикл найдёт (A, 0, 1) и соответствующее правило  $S \to A S_1$ . Это значит, что и в m и в r добавится тройка (S, 0, 2).

61

8. Перед началом итерации

$$m = \{(S, 0, 2)\},\$$

 $r = \{(A, 0, 1), (A, 1, 2), (A, 2, 0), (B, 2, 3), (B, 3, 2), (S, 1, 3), (S_1, 1, 2), (S, 0, 2)\}.$ 

Обрабатываем (S,0,2). Найдено: (B,2,3) и соответствующее правило  $S_1 \to S$  B. В m и в r добавится тройка  $(S_1,0,3)$ .

9. Перед началом итерации

$$m = \{(S_1, 0, 3)\},\$$

$$r = \{(A, 0, 1), (A, 1, 2), (A, 2, 0), (B, 2, 3), (B, 3, 2), (S, 1, 3), (S_1, 1, 2), (S, 0, 2), (S_1, 0, 3)\}.$$

Обрабатываем  $(S_1,0,3)$ . Найдено: (A,2,0) и соответствующее правило  $S \to A S_1$ . В m и в r добавится тройка (S,2,3).

10. Перед началом итерации

$$m = \{(S, 2, 3)\},\$$

$$r = \{(A,0,1), (A,1,2), (A,2,0), (B,2,3), (B,3,2), (S,1,3), (S_1,1,2), (S,0,2), (S_1,0,3), (S,2,3)\}.$$

Обрабатываем (S,2,3). Найдено: (B,3,2) и соответствующее правило  $S_1 \to S$  B. В m и в r добавится тройка  $(S_1,2,2)$ .

11. Перед началом итерации

$$m = \{(S_1, 2, 2)\},\$$

$$r = \{(A, 0, 1), (A, 1, 2), (A, 2, 0), (B, 2, 3), (B, 3, 2), (S, 1, 3), (S_1, 1, 2), (S, 0, 2), (S_1, 0, 3), (S, 2, 3), (S_1, 0, 2), (S_2, 0, 2), (S_2, 0, 2), (S_3, 0, 2), ($$

Обрабатываем  $(S_1, 2, 2)$ . Найдено: (A, 1, 2) и соответствующее правило  $S \to A$   $S_1$ . В m и в r добавится тройка (S, 1, 2).

12. Перед началом итерации

$$m = \{(S, 1, 2)\},\$$

$$r = \{(A, 0, 1), (A, 1, 2), (A, 2, 0), (B, 2, 3), (B, 3, 2), (S, 1, 3), (S_1, 1, 2), (S, 0, 2), (S_1, 0, 3), (S, 2, 3), (S_1, 0, 2), (S_2, 0, 2), ($$

Обрабатываем (S,1,2). Найдено: (B,2,3) и соответствующее правило  $S_1 \to S$  B. В m и в r добавится тройка  $(S_1,1,3)$ .

13. Перед началом итерации

$$m=\{(S_1,1,3)\},$$
 
$$r=\{(A,0,1),(A,1,2),(A,2,0),(B,2,3),(B,3,2),(S,1,3),(S_1,1,2),(S,0,2),(S_1,0,3),(S,2,2),(S,2,3),(S,$$

14. Перед началом итерации

$$m=\{(S,0,3)\},$$
 
$$r=\{(A,0,1),(A,1,2),(A,2,0),(B,2,3),(B,3,2),(S,1,3),(S_1,1,2),(S,0,2),(S_1,0,3),(S,2,2)\}$$
 Обрабатываем  $(S,0,3)$ . Найдено:  $(B,3,2)$  и соответствующее правило  $S_1\to S$   $B$ . В  $m$  и в  $r$  добавится тройка  $(S_1,0,2)$ .

15. Перед началом итерации

$$m=\{(S_1,0,2)\},$$
 
$$r=\{(A,0,1),(A,1,2),(A,2,0),(B,2,3),(B,3,2),(S,1,3),(S_1,1,2),(S,0,2),(S_1,0,3),(S,2,2)\}$$
 Обрабатываем  $(S_1,0,2)$ . Найдено:  $(A,2,0)$  и соответствующее правило  $S\to A$   $S_1$ . В  $m$  и в  $r$  добавится тройка  $(S,2,2)$ .

16. Перед началом итерации

$$m=\{(S,2,2)\},$$
 
$$r=\{(A,0,1),(A,1,2),(A,2,0),(B,2,3),(B,3,2),(S,1,3),(S_1,1,2),(S,0,2),(S_1,0,3),(S,2,2)\}$$
 Обрабатываем  $(S,2,2)$ . Найдено:  $(B,2,3)$  и соответствующее правило  $S_1\to S$   $B$ . В  $m$  и в  $r$  добавится тройка  $(S_1,2,3)$ .

17. Перед началом итерации

содержится всё ршение.

$$m=\{(S_1,2,3)\},$$
  $r=\{(A,0,1),(A,1,2),(A,2,0),(B,2,3),(B,3,2),(S,1,3),(S_1,1,2),(S,0,2),(S_1,0,3),(S,2,2),(S_1,2,3),(S_1,2,3),(S_2,2,2,3),(S_2,2,2,3),(S_2,2,2,2),(S_2,2,2,2),(S_2,2,2,2),(S_2,2,2,2),(S_2,2,2),(S_2,2,2),(S_2,2,2),(S_2,2,2),(S_2,2,2),(S_2,2,2),(S_2,2,$ 

Как можно заметить, количество итераций внешнего цикла также получилось достаточно большим. Проверьте, зависит ли оно от порядка обработки элементов из m. При этом внутренние циклы в нашем случае достаточно короткие, так как просматриваются только "существенные" элементы и избегается дублирование.

# 4.3 Вопросы и задачи

1. Проверить работу алгоритма СҮК для цепочек на грамматике

$$E \to E + E$$
 
$$E \to E * E$$
 
$$E \to (E)$$
 
$$E \to n$$
 и словах (алфавит  $\Sigma = \{n, +, *, (,)\}$ )


$$(n+n)*n$$

$$n+n*n$$

$$n+n+n+n$$

$$n+(n*n)+n$$

- 2. Посчитать вычислительную сложность алгоритма СҮК для матриц в зависимости от размера входного графа (размер грамматики считать фиксированным)
- 3. Проверить работу алгоритма СҮК для графов на графе



И грамматике

$$S \rightarrow SS \\ S \rightarrow AB \\ A \rightarrow a \\ B \rightarrow b$$

4. Оцените временную сложность алгоритма Хеллингса и сравните её с оценкой для наивного обобщения СҮК.

# Глава 5

# Алгоритм на матричных операциях

#### 5.1 Описание

В главе 4.2 был изложен алгоритм для графов на основе СҮК. Заметим, что обход матрицы напоминает матричное умножение:

$$M_1 \times M_2 = M_3$$
  
 $M_3[i,j] = \sum_{k=1}^{n} M[i,k] * M[k,j]$ 

, где

$$\sum_{k=1}^{n} = \bigcup_{k=1}^{n}$$
 
$$S_1 * S_2 = \{N_1^0 ... N_1^m\} * \{N_2^0 ... N_2^l\} = \{N_3 \mid (N_3 \to N_1^i N_2^j) \in P\}$$


Для линейного входа существует алгоритм Валианта [76], но он не обобщается на графы с сохранением асимптотики [84], поэтому рассмотрим идею, изложенную в статье Рустама Азимова [6].

Пусть  $\mathcal{G}=(V,E)$  — входной граф и  $G=(N,\Sigma,P)$  — входная грамматика.

#### Algorithm 4 Context—free recognizer for graphs

```
1: function CONTEXTFREEPATHQUERYING(\mathcal{G}, G)
 2:
        n \leftarrow количество узлов в \mathcal{G}
        E \leftarrow направленные ребра в \mathcal{G}
 3:
        P \leftarrow набор продукций из G
 4:
        T \leftarrow матрица n \times n, в которой каждый элемент \varnothing
 5:
        for all (i, x, j) \in E do
                                                                 ⊳ Инициализация матрицы
 6:
             T_{i,j} \leftarrow T_{i,j} \cup \{A \mid (A \rightarrow x) \in P\}
 7:
        while матрица T меняется do
 8:
             T \leftarrow T \cup (T \times T)
                                               ⊳ Вычисление транзитивного замыкания
 9:
        return T
10:
```

**Пример 5.1.1** (Пример работы). Пусть есть граф  $\mathcal{G}$ :



и грамматика G:

$$S \to AB$$

$$S \to AS_1$$

$$S_1 \to SB$$

$$A \to a$$

$$B \to b$$

Тогда  $T_0$ , полученная напрямую из графа, выглядит так:

$$T_0 = \begin{pmatrix} \varnothing & \{A\} & \varnothing & \{B\} \\ \varnothing & \varnothing & \{A\} & \varnothing \\ \{A\} & \varnothing & \varnothing & \varnothing \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

5.1. Описание 67

Пусть  $T_i$  — матрица, полученная из T после применения цикла на строках **8-9** алгоритма 4 i раз. Далее показано получение матрицы  $T_1$ .

$$T_{1} = T_{0} \cup (T_{0} \times T_{0}) = \begin{pmatrix} \varnothing & \{A\} & \varnothing & \{B\} \\ \varnothing & \varnothing & \{A\} & \varnothing \\ \{A\} & \varnothing & \varnothing & \{S\} \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

Когда алгоритм находит новые пути в графе  $\mathcal{G}$ , он добавляет соответствующие нетерминалы в матрицу T. Например, после первого цикла нетерминал S добавляется к матрице T. Этот нетерминал добавляется в ячейку [2,3]. Это означает, что существует такой путь  $\pi$  из вершины 2 в вершину 3, что  $S \stackrel{*}{\to} \omega(\pi)$ . В данном примере путь состоит из двух ребер с именами a и b, так что  $S \stackrel{*}{\to} ab$ .

Вычисление транзитивного замыкания заканчивается через k итераций, когда достигается фиксированная точка:  $T_{k-1} = T_k$ . Для данного примера k = 13, так как  $T_{13} = T_{12}$ . Процесс вычисления транзитивного замыкания показан ниже (на каждой итерации новые элементы выделены жирным).

$$T_{2} = \begin{pmatrix} \varnothing & \{A\} & \varnothing & \{B\} \\ \varnothing & \varnothing & \{A\} & \varnothing \\ \{A, S_{1}\} & \varnothing & \varnothing & \{S\} \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{3} = \begin{pmatrix} \varnothing & \{A\} & \varnothing & \{B\} \\ \{S\} & \varnothing & \{A\} & \varnothing \\ \{A, S_{1}\} & \varnothing & \varnothing & \{S\} \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{4} = \begin{pmatrix} \varnothing & \{A\} & \varnothing & \{B\} \\ \{S\} & \varnothing & \{A\} & \{S_{1}\} \\ \{A, S_{1}\} & \varnothing & \varnothing & \{S\} \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{5} = \begin{pmatrix} \{A\} & \varnothing & \{B, S\} \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{6} = \begin{pmatrix} \{S_{1}\} & \{A\} & \varnothing & \{B, S\} \\ \{S\} & \varnothing & \{A\} & \{S_{1}\} \\ \{A, S_{1}\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{7} = \begin{pmatrix} \{S_{1}\} & \{A\} & \varnothing & \{B, S\} \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{7} = \begin{pmatrix} \{S_{1}\} & \{A\} & \varnothing & \{B, S\} \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{8} = \begin{pmatrix} \{S_{1}\} & \{A\} & \varnothing & \{B, S\} \\ \{S\} & \varnothing & \{A\} & \{S_{1}\} \\ \{A, S_{1}, S\} & \varnothing & \varnothing & \{S, S_{1}\} \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{8} = \begin{pmatrix} \{S_{1}\} & \{A\} & \varnothing & \{B, S\} \\ \{S, S_{1}\} & \varnothing & \{A\} & \{S_{1}, S\} \\ \{A, S_{1}, S\} & \varnothing & \varnothing & \{S, S_{1}\} \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{10} = \begin{pmatrix} \{S_{1}\} & \{A\} & \varnothing & \{B, S\} \\ \{S, S_{1}\} & \varnothing & \{A\} & \{S_{1}, S\} \\ \{A, S_{1}, S\} & \varnothing & \varnothing & \{S, S_{1}\} \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{11} = \begin{pmatrix} \{S_{1}, S\} & \{A\} & \varnothing & \{B, S\} \\ \{S, S_{1}\} & \varnothing & \{A\} & \{S_{1}, S\} \\ \{A, S_{1}, S\} & \varnothing & \varnothing & \{S, S_{1}\} \\ \{B\} & \varnothing & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{12} = \begin{pmatrix} \{S_{1}, S\} & \{A\} & \varnothing & \{B, S, S_{1}\} \\ \{S, S_{1}\} & \varnothing & \{A\} & \{S_{1}, S\} \\ \{A, S_{1}, S\} & \varnothing & \varnothing & \{S, S_{1}\} \\ \{B\} & \varnothing & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

$$T_{13} = \begin{pmatrix} \{S_{1}, S\} & \{A\} & \varnothing & \{B, S, S_{1}\} \\ \{S, S_{1}\} & \varnothing & \{A\} & \{S_{1}, S\} \\ \{S, S_{1}\} & \varnothing & \{A\} & \{S_{1}, S\} \\ \{S, S_{1}\} & \varnothing & \{A\} & \{S_{1}, S\} \\ \{S, S_{1}\} & \varnothing & \varnothing & \{S, S_{1}\} \\ \{B\} & \varnothing & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

Таким образом, результат алгоритма 4 для нашего примера — это матрица  $T_{13} = T_{12}$ .

# 5.1.1 Матричный алгоритм для конъюнктивных грамматик

Матричный алгоритм для конъюнктивных грамматик отличается от алгоритма 4 для контекстно-свободных грамматик только операцией умножения матриц, в остальном алгоритм остается без изменений. Определим операцию умножения матриц.

**Определение 5.1.1.** Пусть  $M_1$  и  $M_2$  матрицы размера n. Определим операцию  $\circ$ .  $M_1 \circ M_2 = M_3$ , где  $M_3[i,j] = \{A \mid \exists (A \to B_1C_1\& \dots \& B_mC_m) \in$ 

5.1. Описание 69

$$P, (B_k, C_k) \in d[i, j] \forall k = 1, \dots, m\}$$
, где  $d[i, j] = \bigcup_{k=1}^n M_1[i, k] \times M_2[k, j]$ .


Важно заметить, что алгоритм для конъюнктивных грамматик, в отличие от алгоритма для контекстно-свободных грамматик, дает лишь верхнюю оценку. То есть все нетерминалы, которые должны быть в ячейках матрицы результата, содержатся там, но вместе с ними содержатся и лишние нетерминалы. Рассмотрим пример, иллюстрирующий появление лишних нетерминалов.

**Пример 5.1.2.** Грамматика G:

$$S \rightarrow AB\&DC$$
 
$$A \rightarrow a$$
 
$$B \rightarrow BC \mid b$$
 
$$C \rightarrow c$$
 
$$D \rightarrow DC \mid b$$

Очевидно, что грамматика G задает язык из одного слова  $L(G)=\{abc\}=\{abc^*\}\cap\{a^*bc\}.$ 

Пусть есть граф  $\mathcal{G}$ :



Применяя алгоритм, получим, что существует путь из вершины 0 в вершину 4 из нетерминала S. Очевидно, что такого пути нет. Это происходит из-за того, что существует путь "abcc", соответствующий  $L(AB) = \{abc^*\}$  и путь "aabc", соответствующий  $L(DC) = \{a^*bc\}$ , но они различны и проверить их в общем случае нельзя. Поэтому для классической семантики результат работы алгоритма является оценкой сверху.

Существует альтернативная семантика, когда мы трактуем конъюнкцию как в Datalog. Подробнее о Datalog в параграфе 12. Т.е если есть правило  $S \to AB\&DC$ , то должен быть путь принадлежащий языку L(AB) и путь принадлежащий языку L(DC). В альтернативной семантике алгоритм дает точный ответ.

Подробнее алгоритм описан в статье Рустама Азимова и Семена Григорьева [7].

В общем случае для булевых грамматик подобного алгоритма не существует.

# 5.2 Особенности реализации матричного алгоритма

Матричные алгоритмы удобны тем, что их удобно вычислять на GPU и для них можно создать модификацию, которая будет работать параллельно на нескольких вычислителях [48].

Так как множество нетерминалов и правил конечно, то мы можем свести алгоритм к булевым матрицам: для каждого нетерминала заводим матрицу, такую что в ячейке стоит 1 тогда и только тогда, когда в исходной матрице в соответствующей ячейке был этот нетерминал. Тогда перемножение пары таких матриц — это применение правила.

Пример 5.2.1. Представим в таком виде следующую матрицу:

$$T_0 = \begin{pmatrix} \varnothing & \{A\} & \varnothing & \{B\} \\ \varnothing & \varnothing & \{A\} & \varnothing \\ \{A\} & \varnothing & \varnothing & \varnothing \\ \{B\} & \varnothing & \varnothing & \varnothing \end{pmatrix}$$

Тогда:

$$T_{0\_A} = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} \quad T_{0\_B} = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{pmatrix}$$

Тогда при наличии правила  $S \to AB$  получим  $T_{1\_S} = T_{0\_A} \times T_{0\_B}$  :

С другой стороны, для небольших запросов практически может быть выгодно представлять множества нетерминалов в виде битового вектора. Нумеруем все нетерминалы с нуля, в векторе стоит 1 на і позиции, если в множестве есть нетерминал с номером і. Таким образом, в каждой ячейке хранится битовый вектор длины |N|. Тогда операцию умножения надо определить следующим образом:

$$v_1 \times v_2 = \{v \mid \exists (v, v_3) \in P, append(v_1, v_2) \& v_3 = v_3\},\$$

где & — побитовое "и". Чтобы это было возможно, правила надо кодировать соответственно: продукция это пара, где первый элемент — битовый вектор длины N с единственной единицей в позиции, соответствующей нетерминалу в правой части, а второй элемент — вектор длины 2|N|, с двумя единицами кодирующими первый и второй нетерминалы, соответственно.

**Пример 5.2.2.** Пусть  $N = \{S, A, B\}$  и есть продукция  $S \to AB$ . Тогда занумеруем нетерминалы  $S \to 0, A \to 1, B \to 2$  и продукция примет вид  $[1,0,0] \to [0,1,0,0,0,1]$ . Матрица  $T_0$  примет вид(в нашей нотации . означает, что в ячейке стоит [0,0,0]):

$$T_0 = \begin{pmatrix} \cdot & [0,1,0] & \cdot & [0,0,1] \\ \cdot & \cdot & [0,1,0] & \cdot \\ [0,1,0] & \cdot & \cdot & \cdot \\ [0,0,1] & \cdot & \cdot & \cdot \end{pmatrix}$$

После выполнения умножения получим  $T_1 = T_0 \times T_0$ :

$$T_1 = \begin{pmatrix} . & [0,1,0] & . & [0,0,1] \\ . & . & [0,1,0] & . \\ [0,1,0] & . & . & [1,0,0] \\ [0,0,1] & . & . & . \end{pmatrix}$$

На практике в роли векторов могут выступать беззнаковые целые. Например, 32 бита под ячейки в матрице и 64 бита под правила (или 8 и 16, если запросы совсем маленькие, или 16 и 32). Тогда умножение выражается через битовые операции и сравнение.

Это может оказаться быстрее — в данном случае скорость зависит от деталей реализации.

При таких представлениях данные часто оказываются разреженны — возникает вопрос, как представлять матрицу. Среди способов — разреженные матрицы, GraphBLAS<sup>1</sup>, GPGPU, CUTLASS<sup>2</sup>. Quad Tree [25].

 $<sup>^1{\</sup>rm GraphBLAS}-$ открытый стандарт для графовых алгоритмов — https://github.com/gunrock/graphblast

<sup>&</sup>lt;sup>2</sup>Репозиторий библиотеки CUTLASS: https://github.com/NVIDIA/cutlass

Для вычислений лучше всего, когда все нужные для вычисления матрицы помещаются на одну карту. Хуже — если только одна пара матриц. Хуже всего, когда не помещается даже пара матриц. Поэтому хороши распределенные решения, например через GraphBLAS.

## **5.3** Обзор

- Lee. О конвертации парсеров КС-грамматик в перемножение булевых матриц [44]
- OpenCypher [41]
- J.Hellings. CFPQ [31, 33, 32]
- Zhang. CFPQ on rdf graphs [86]
- Bradford [14, 80, 17, 15]

Асимптотически приведенные алгоритмы имеют большую сложность, например

 $O(n^2|N|^2|P|\ (MM(n))$ , где MM(n) — сложность перемножения матриц  $n \times n$ , |P| — мощность множества продукций, |N| — мощность множества нетерминалов. Однако такая большая сложность компенсируется возможностью их распараллеливания, в результате чего они работают быстрее однопоточных алгоритов с лучшей сложностью.

Брэдфорт получил субкубическую сложность для частного случая — языка Дика с одним типом скобок [16].

# 5.4 Вопросы и задачи

- 1. Находить кратчайшие пути в графах, используя идеи из секции 5.1.
- 2. Превратить граф, использующийся для CFPQ, в дерево.
- 3. Реализовать предложенные идеи на различных архитектурах.
- 4. Замерить производительность и расходы памяти по сравнению с существующими реализациями.

### Глава 6

## Через тензорное произведение

Предыдущий подход позволяет выразить задачу поиска путей с ограничениями в терминах формальных языков через набор матричных операций. Это позволяет использовать высокопроизводительные библиотеки и массовопараллельные архитектуры и вообще круто. Однако, такой подход требует, чтобы грамматика находилась в ослабленной нормальной форме Хомского, что приводит к её разрастанию. Можно ли как-то избежать этого?

В данном разделе мы попробуем предложить альтернативное сведение задачи поиска путей к матричным операциям. В результате мы сможем избежать преобразования грамматики в ОНФХ, однако, матрицы, с которыми нам предётся работать, будут существенно большего размера.

В основе подхода лежит использование рекурсивных сетей или рекурсивных автоматов в качестве представления контекстно-свободных грамматик.

#### 6.1 Рекурсивные автоматы и сети

Рекурсивный автомат или сеть — это представление контекстно-свободных грамматик, обобщающее конечные автоматы. В нашей работе мы будем придерживаться термина **рекурсивный автомат**. Классическое определение рекурсивного автомата выглядит следующим образом.

**Определение 6.1.1.** Рекурсивный автомат — это кортеж вида  $\langle N, \Sigma, S, D \rangle$ , где

- N нетерминальный алфавит;
- $\Sigma$  терминальный алфавит;

- S стартовый нетерминал;
- D конечный автомат над  $N \cup \Sigma$  в котором стартовые и финальные состояния помечены подмножествами N.


Построим рекурсивный автомат для грамматики G:

$$S \to ASB$$

$$S \to AB$$

$$A \to a$$

$$B \to b$$



Используем стандартные обозначения для стартовых и финальных состояний. Дополнительно в стартовых и финальных состояниях укажем нетерминалы, для которых эти состояния стартовые/финальные.

В некоторых случаях рекурсивный автомат можно рассматривать как конечный автомат над смешанным алфавитом. Именно такой взгляд мы будем использовать при изложении алгоритма.

#### 6.2 Тензорное произведение

Тензорное произведение матриц или произведение Кронекера — это бинарная операция, обозначаемая ⊗ и определяемая следующим образом.

**Определение 6.2.1.** Пусть даны две матрицы: A размера  $m \times n$  и B размера  $p \times q$ . Произведение Кронекера или тензорное произведение матриц A и B — это блочная матрица C размера  $mp \times nq$ , вычисляемая следующим образом:

$$C = A \otimes B = \begin{pmatrix} A_{0,0}B & \cdots & A_{0,n-1}B \\ \vdots & \ddots & \vdots \\ A_{m-1,0}B & \cdots & A_{m-1,n-1}B \end{pmatrix}$$

#### Пример 6.2.1.

$$\begin{pmatrix}
1 & 2 \\
3 & 4
\end{pmatrix} \otimes \begin{pmatrix}
5 & 6 & 7 & 8 \\
9 & 10 & 11 & 12 \\
13 & 14 & 15 & 16
\end{pmatrix} = \begin{pmatrix}
1 & 5 & 6 & 7 & 8 \\
9 & 10 & 11 & 12 \\
13 & 14 & 15 & 16
\end{pmatrix} = \begin{pmatrix}
5 & 6 & 7 & 8 \\
9 & 10 & 11 & 12 \\
13 & 14 & 15 & 16
\end{pmatrix} = \begin{pmatrix}
5 & 6 & 7 & 8 \\
9 & 10 & 11 & 12 \\
13 & 14 & 15 & 16
\end{pmatrix} = \begin{pmatrix}
5 & 6 & 7 & 8 \\
9 & 10 & 11 & 12 \\
13 & 14 & 15 & 16
\end{pmatrix} = \begin{pmatrix}
5 & 6 & 7 & 8 \\
9 & 10 & 11 & 12 \\
13 & 14 & 15 & 16
\end{pmatrix} = \begin{pmatrix}
5 & 6 & 7 & 8 \\
9 & 10 & 11 & 12 \\
13 & 14 & 15 & 16
\end{pmatrix} = \begin{pmatrix}
6 & 7 & 8 & 10 & 12 & 14 & 16 \\
9 & 10 & 11 & 12 & 18 & 20 & 22 & 24 \\
13 & 14 & 15 & 16 & 26 & 28 & 30 & 32 \\
15 & 18 & 21 & 24 & 20 & 24 & 28 & 32 \\
27 & 30 & 33 & 36 & 36 & 40 & 44 & 48 \\
39 & 42 & 45 & 48 & 52 & 56 & 60 & 64
\end{pmatrix} (6.2)$$

Заметим, что для определения тензорного произведения матриц достаточно определить операцию умножения на элементах исходных матриц. Также отметим, что произведение Кронекера не является коммутативным. При этом всегда существуют две матрицы перестоновок P и Q такие, что  $A \otimes B = P(B \otimes A)Q$ . Это свойство потребуется нам в дальнейшем.

Теперь перейдём к графам. Сперва дадим классическое определение тензорного произведения двух неориентированных графов.

Определение 6.2.2. Пусть даны два графа:  $\mathcal{G}_1 = \langle V_1, E_1 \rangle$  и  $\mathcal{G}_2 = \langle V_2, E_2 \rangle$ . Тензорным произведением этих графов будем называть граф  $\mathcal{G}_3 = \langle V_3, E_3 \rangle$ , где  $V_3 = V_1 \times V_2$ ,  $E_3 = \{((v_1, v_2), (u_1, u_2)) \mid (v_1, u_1) \in E_1 \text{ и } (v_2, u_2) \in E_2\}$ .

Иными словами, тензорным произведением двух графов является граф, такой что:

- 1. множество вершин это прямое произведение множеств вершин исходных графов;
- 2. ребро между вершинами  $v = (v_1, v_2)$  и  $u = (u_1, u_2)$  существует тогда и только тогда, когда существуют рёбра между парами вершин  $v_1$ ,  $u_1$  и  $v_2$ ,  $u_2$  в соответсвующих графах.

Для того, чтобы построить тензорное произведение ориентированных графов, необходимо в предыдущем определении, в условии существования ребра в результирующем графе, дополнительно потребовать, чтобы направления рёбер совпадали. Данное требование получается естесвенным образом, если считать, что пары вершин, задающие ребро, упорядочены, поэтому формальное определение отличаться не будет.


Осталось добавить метки к рёбрам. Это приведёт к логичному усилению требованя к существованию ребра: метки рёбер в исходных графах должны совпадать. Таким образом, мы получаем следующее определение тензорного произведения ориентированных графов с метками на рёбрах.

**Определение 6.2.3.** Пусть даны два ориентированных графа с метками на рёбрах:  $\mathcal{G}_1 = \langle V_1, E_1, L_1 \rangle$  и  $\mathcal{G}_2 = \langle V_2, E_2, L_2 \rangle$ . Тензорным произведением этих графов будем называть граф  $\mathcal{G}_3 = \langle V_3, E_3, L_3 \rangle$ , где  $V_3 = V_1 \times V_2$ ,  $E_3 = \{((v_1, v_2), l, (u_1, u_2)) \mid (v_1, l, u_1) \in E_1 \text{ и } (v_2, l, u_2) \in E_2\}$ ,  $L_3 = L_1 \cap L_2$ .

Нетрудно заметить, что матрица смежности графа  $\mathcal{G}_3$  равна тензорному произведению матриц смежностей исходных графов  $\mathcal{G}_1$  и  $\mathcal{G}_2$ .

**Пример 6.2.2.** Рассмотрим пример. В качестве одного из графов возьмём рекурсивный автомат, построенный ранее (изображение 6.1). Его матрица смежности выглядит следующим образом.

$$M_1 = \begin{pmatrix} . & [a] & . & . \\ . & . & [S] & [b] \\ . & . & . & [b] \\ . & . & . & . \end{pmatrix}$$



Второй граф представлен на изображении 6.3. Его матрица смежности имеет следующий вид.

$$M_2 = \begin{pmatrix} . & [a] & . & . \\ . & . & [a] & . \\ [a] & . & . & [b] \\ . & . & [b] & . \end{pmatrix}$$

6.3. Алгоритм 77

Теперь вычислим  $M_1 \otimes M_2$ .

Побалуемся с некоммутативностью и перестановками.

#### 6.3 Алгоритм

Идея алгоритма основана на обобщении пересечения двух конечных автоматов до пересечения рекурсивного автомата, построенного по грамматике, со входным графом.

Пересечение двух конечных автоматов — тензорное произведение соответствующих графов. Пересечение языков коммутативно, тензорное произведение нет, но это не страшно.

В итоговом автомате для любого нетерминала должен существовать хотя бы один путь из правильного стартового состояния в финальное, содержащий только терминалы. Если это не так, то данная грамматика непорождающая, то есть она не может породить ни одной цепочки, содержайщей только терминалы. Это делает задачу бессодержательной.

#### Listing 5 Поиск путей через тензорное произведение

```
1: function CONTEXTFREEPATHQUERYINGTP(G, \mathcal{G})
 2:
        R \leftarrow рекурсивный автомат для G
        N \leftarrow нетерминальный алфавит для R
 3:
        S \leftarrow стартовые состояния для R
 4:
        F \leftarrow конечные состояния для R
 5:
 6:
        M_1 \leftarrow матрица смежности R
        M_2 \leftarrow матрица смежности \mathcal{G}
 7:
        while матрица M_2 изменяется do
            M_3 \leftarrow M_1 \otimes M_2
                                                                    ⊳ Пересечение графов
 9:
            tC_3 \leftarrow transitiveClosure(M_3)
10:
            n \leftarrow количество строк и столбцов матрицы M_3 \triangleright размер матрицы
11:
    M_3 = n \times n
12:
            for i \in 0..n do
                for j \in 0..n do
13:
                    if tC_3[i,j] then
14:
                        s \leftarrow стартовая вершина ребра tC_3[i,j]
15:
                        f \leftarrow конечная вершина ребра tC_3[i,j]
16:
                        if s \in S and f \in F then
17:
                            x, y \leftarrow getCoordinates(i, j)
18:
                            M_2[x,y] \leftarrow M_2[x,y] \cup \{getNonterminals(s,f)\}
19:
20:
        return M_2
```

Алгоритм исполняется до тех пор, пока матрица смежности  $M_2$  изменяется. На каждой итерации цикла алгоритм последовательно проделывает следующие команды: пересечение двух автоматов через тензорное произведение, транзитивное замыкание результата тензорного произведения и итерация по всем ячейкам получившейся после транзитивного замыкания матрицы. Во время итерации по ячейкам матрицы транзитивного замыкания алгоритм сначала проверяет наличие ребра в данной ячейке, а затем — принадлежность стартовой и конечной вершин ребра к стартовому и конечному состоянию входного рекурсивного автомата. При удовлетворении этих условий алгоритм добавляет нетерминал/нетерминалы, соответствующие стартовой и конечной вершинам ребра, в ячейку матрицы  $M_2$ , полученной с благодаря функции getCoordinates(i, j).

Вместо того, чтобы перезаписывать каждый раз матрицу смежности  $M_2$  можно вычислять только разницу. Для этого, правда, потребуется хранить в памяти ещё одну матрицу. Также для данной реализации надо проверять, что вычислительно дешевле: поддерживать разницу и потом каждый раз поэлементно складывать две матрицы или каждый раз вычислять полностью произведение.

Отметим, что для реальных графов и запросов результат тензорного произведения будет очень разрежен. Таким образом на готовых либах вычисление должно быть быстро.


#### 6.4 Примеры

Рассмотрим подробно ряд примеров работы описанного алгоритма. Будем для каждой итерации внешнего цикла выписывать результаты основных операций: тензорного произведения, транзитивного замыкания, обновления матрицы смежности входного графа. Новые, по сравнению с предыдущим состоянием, элементы матриц будем выделять жирным.

**Пример 6.4.1.** Теоретически худший случай. Такой же как и для матричного.

**Итерация 1 (конец).** Начало в разделе 6.2, где мы вычислили тензорное произведение матриц смежности. Теперь нам осталось только вычислить транзитивное замыкание полученной матрицы.

Мы видим, что в результате транзитивного замыкания появилось новое ребро с меткой ab из вершины (0,1) в вершину (3,3). Так как вершина 0 является стартовой в рекурсивном автомате, а 3 является финальной, то слово вдоль пути из вершины 1 в вершину 3 во входном графе выводимо из нетерминала S. Это означает, что в графе должно быть добавлено ребро из 0 в 3 с меткой S, после чего граф будет выглядеть следующим образом:



Матрица смежности обновлённого графа:


$$M_2 = \begin{pmatrix} . & [a] & . & . \\ . & . & [a] & [S] \\ [a] & . & . & [b] \\ . & . & [b] & . \end{pmatrix}$$

Итерация закончена. Возвращаемся к началу цикла и вновь вычисляем тензорное произведение.

Итерация 2. Вычисляем тензорное произведение матриц смежности.

Вычисляем транзитивное замыкание полученной матрицы:

В транзитивном замыкании появилось три новых ребра, однако только одно из них соединяет вершины, соответствующие стартовому и конечному состоянию входного рекурсивного автомата. Таким образом только это ребро должно быть добавлено во входной граф. В итоге, обновлённый граф:




И его матрица смежности:

$$M_2 = \begin{pmatrix} . & [a] & [S] & . \\ . & . & [a] & [S] \\ [a] & . & . & [b] \\ . & . & [b] & . \end{pmatrix}$$

Итерация 3. Снова начинаем с тензорного произведения.

Затем вычисляем транзитивное замыкание:

И наконец обновляем граф:



Матрица смежности обновлённого графа:

$$M_2 = \begin{pmatrix} . & [a] & [S] & . \\ . & . & [a] & [S] \\ [a] & . & . & [b, \mathbf{S}] \\ . & . & [b] & . \end{pmatrix}$$


Уже можно заметить закономерность: на каждой итерации мы добавляем ровно одно новое ребро во входной граф. То есть находим ровно одну новую

пару вешин, между которыми существует интересующий нас путь. Попробуйте спрогонозировать, сколько итераций нам ещё осталось сделать.

Итерауия 4. Продолжаем. Вычисляем тензорное произведение.

Затем транзитивное замыкание:

И снова обновляем граф, так как в транзитивном замыкании появился один (и снова ровно один) новый элемент, соответствующий принимающему пути в автомате.




Матрица смежности обновлённого графа:

$$M_2 = \begin{pmatrix} . & [a] & [S] & . \\ . & . & [a, \mathbf{S}] & [S] \\ [a] & . & . & [b, S] \\ . & . & [b] & . \end{pmatrix}$$

**Итерация 5.** Приступаем к выполнению следующей итерации основного цикла. Вычисляем тензорное произведение.

Затем вычисляем транзитивное замыкание:

Обновляем граф:




Матрица смежности обновлённого графа:

$$M_2 = \begin{pmatrix} . & [a] & [S] & [\mathbf{S}] \\ . & . & [a, S] & [S] \\ [a] & . & . & [b, S] \\ . & . & [b] & . \end{pmatrix}$$

**Итерация 6.** И наконец последняя содержательная итерация основного цикла.

Транзитивное замыкание:

Обновлённый граф:



И матрица смежности:

$$M_2 = \begin{pmatrix} . & [a] & [S] & [S] \\ . & . & [a, S] & [S] \\ [a] & . & [S] & [b, S] \\ . & . & [b] & . \end{pmatrix}$$

Следующая итерация не приведёт к изменению графа. Читатель может убедиться в этом самостоятельно. Соответственно, алгоритм можно завершать. Нам потребовалось семь итераций (шесть содержательных и одна проверочная).

Матрица смежности получилась такая же, как и раньше, ответ правильный. Мы видим, что количество итераций внешнего цикла такое же как и у алгоритма СҮК (пример 4.2.1). И ещё что-то видим и можем понять.

**Пример 6.4.2.** В данном примере мы увидим, как структура грамматики и, соответственно, рекурсивного автомата, влияет на процесс вычислений.

Интуитивно понятно, что чем меньше состояний в рекурсивной сети, тем лучше. То есть желательно получить как можно более компактное описание контекстно-свободного языка.

Для примера возьмём в качестве КС языка язык Дика на одном типе скобок и опишем его двумя различными грамматиками. Первая граммтика классическая:


$$G_1 = \langle \{a, b\}, \{S\}, \{S \rightarrow a \ S \ b \ S \mid \varepsilon \} \rangle$$

Во второй грамматике мы будем использовать конструкции регулярных выражений в правой части правил. То есть вторая грамматика находитмся в EBNF (Расширенная форма Бэкуса-Наура [34, 82]).

$$G_2 = \langle \{a, b\}, \{S\}, \{S \to (a \ S \ b)^*\} \rangle$$

Построим рекурсивные автоматы  $N_1$  и  $N_2$  и их матрицы смежности для этих грамматик.


Рекурсивный автомат  $N_1$  для грамматики  $G_1$ :



Матрица смежности  $N_1$ :

$$M_1^1 = \begin{pmatrix} . & [a] & . & . & . \\ . & . & [S] & . & . \\ . & . & . & [b] & . \\ . & . & . & . & [S] \end{pmatrix}$$

Рекурсивный автомат  $N_2$  для грамматики  $G_2$ :




Матрица смежности  $N_2$ :

$$M_1^2 = \begin{pmatrix} . & [a] & . \\ . & . & [S] \\ [b] & . & . \end{pmatrix}$$

Первое очевидное наблюдение — количество состояний в  $N_2$  меньше, чем в  $N_1$ . Это значит, что матрицы будут меньше, считать быстрее.

Для того, чтобы проще было сделать второе, сперва выполним пошагово алгоритм для двух заданных рекурсивных сетей.

Вход возьмём линейный:



Сразу дополним матрицу смежности нетерминалами, выводящими пустую строку, и получим следующую матрицу:

$$M_{2} = \begin{pmatrix} [S] & [a] & . & . & . & . & . \\ . & [S] & [b] & . & . & . & . \\ . & . & [S] & [a] & . & . & . \\ . & . & . & [S] & [b] & . & . \\ . & . & . & . & [S] & [a] & . \\ . & . & . & . & . & . & [S] & [b] \\ . & . & . & . & . & . & . & . & [S] \end{pmatrix}$$

Сперва запустим алгоритм на входе и  $N_2$ . Первый шаг первой итерации — вычисление тензорного произведения  $M_1^2\otimes M_2$ .

$$M_{3} = M_{1}^{2} \otimes M_{2} = \begin{pmatrix} \cdot & [a] & \cdot \\ \cdot & [S] & [b] & \cdot & \cdot & \cdot \\ \cdot & \cdot & [S] & [a] & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & [S] & [b] & \cdot & \cdot \\ \cdot & \cdot & \cdot & [S] & [b] & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & [S] & [b] & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & [S] & [b] \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \cdot & \vdots & \vdots \\ \cdot &$$

Опустим промежуточные шаги вычисления транзитивного замыкания  $M_3$ 


и сразу представим конечный результат:

$$tc(M_3) =$$

• •	[aSb]	•	[aSbaSb	] .	[aSbaSbaSb]		$\lfloor a \rfloor$		[aSba]		[aSbaSba]	•	[aS]	•	[aSbaS]	•	[aSbaSbaS]	•
	•	•		٠	•		•	٠		٠	•	•	•	•	•	٠	•	•
			[aS b]		[aSbaSb]				[a]		[aSba]			•	[aS]	•	[aSbaS]	
					•										•	•	•	
					[aSb]						[a]				•		[aS]	
	•	•	•		•						•			•	٠	•	•	
		•		•	•						•			•	•	•	•	
												[S]			•			
													[S]					
														[S]	•			
					•									•	[S]		•	
															•	[S]		
					•	.											[S]	
					•						•				•			[5
											•							
	[b]													•	٠		•	
			[b]															
					•									•	•		•	
					[b]									•	•	•	•	
					•													

В результате вычисления транзитивного замыкания появилось большое количество новых рёбер, однако нас будут интересновать только те, информация о которых храниться в левом верхнем блоке. Остальные рёбра не соответствуют принимающим путям в рекурсивном автомате (убедитесь в этом самостоятельно).

После добавления соответствующих рёбер, мы получим следующий граф:



Его матрица смежности:

$$M_{2} = \begin{pmatrix} [S] & [a] & [S] & . & [S] & . & [S] \\ . & [S] & [b] & . & . & . & . \\ . & . & [S] & [a] & [S] & . & [S] \\ . & . & . & [S] & [b] & . & . \\ . & . & . & . & . & [S] & [a] & [S] \\ . & . & . & . & . & . & . & [S] \end{pmatrix}$$

Таким образом видно, что для выбранных входных данных алгоритму достаточно двух итераций основного цикла: первая содержательная, вторая, как обычно, проверочная. Читателю предлагается самостоятельно выяснить, сколько умножений матриц потребуется, чтобы вычислить транзитивное замыкание на первой итерации.

Теперь запустим алгоритм на второй грамматике и том же входе.


$M_3$	$=M_1^1\otimes M_2$	2 =	( · [	[a] 	[S]	[b]	. `` 	$\bigg)$ $\otimes$	$\geqslant$	([S]	[a] [S]	. [b] [S]	: [a] [S] : :	[b] [S]	] ] [d	a] S]	[b]		=						
	<i>(</i>	.[a]				.								ļ					.						
					•		•																		
			. [	a].			•																		
						$\cdot$		•																	
					[a]	$\cdot$	•	•		•															
			•		•		•	•	•	•					•										•
	<u> </u>		•		•	·		•	•	•		•	•		•	•	•			•	•		•	•	•
			•		•		[S]		•			•	•		•	٠				•	•	•	•	•	•
			•		•		. [	S		•	٠	•	٠		•	•	•			•	•		•	•	•
			•		•		•		[S]		•	•	•		•	•	•			•	•	•	•	٠	•
			•		•		•	•	٠	[S]	[ <i>C</i> ]	•	٠	• •	•	٠	•			•	•	•	•	•	•
			•		٠		•	•	•	٠	[S]	[ <i>C</i> ]	•	•••	•	•	•	• •		•	•	•	•	٠	•
			•		•		•	•	•	•	•		[ <i>C</i> ]		•	•	•			•	•	•	•	•	•
			•		•	•	•	•	•	•	•	•			•	•	•	• •		•	•	•	•	•	•
			•		•		•	•	•	•	•	•	•		[h]	1	•			•	•	•	•	•	•
			•		•		•	•	•	•	•	•	•		Įυ.		•			•	•	•	•	•	•
=			•		•		•	•	•	•	•	•	•		•	•	[b]			•	•	•	•	•	•
_			•	• •	•		•	•	•	•	•	•	•		•	•	[0]			•	•	•	•	•	•
									•	•		•			•	•		. [b]	:			•	•		
					•		•		•						•	•	•	. [ ]	:						
	<del></del>																		[S]						
																				[S]					
																					[S]				
																						[S]			
																							[S]		
																								[S]	
																									[S]
							•																		
							•																		
						$\cdot  $								<b> </b>					.						
						$\cdot  $													.						
					•	$\cdot  $		•						<b> </b>					.						
	<b>\</b>				•	$\cdot  $		•	•										.						•
																				(6	.18)				

Уже сейчас можно заметить, что размер матриц, с которыми нам придётся работать, существенно увеличился, по сравнению с предыдущим вариантом. Это, конечно, закономерно, ведь в рекурсивном автомате для предыдущего варианта меньше состояний, а значит и матрица смежности имеет меньший размер.

Транзитивное замыкание:

 $tc(M_3) =$ (6.19)

Обновлённый граф:



Его матрица смежности:

$$M_{2} = \begin{pmatrix} [S] & [a] & [\mathbf{S}] & . & . & . & . \\ . & [S] & [b] & . & . & . & . \\ . & . & [S] & [a] & [\mathbf{S}] & . & . \\ . & . & . & [S] & [b] & . & . \\ . & . & . & . & [S] & [a] & [\mathbf{S}] \\ . & . & . & . & . & . & [S] & [b] \\ . & . & . & . & . & . & . & . & [S] \end{pmatrix}$$

Потребуется ещё одна итерация.

$M_3$	$=M_1^1\otimes M_2$	=	(. [	a] . [	$\begin{bmatrix} S \end{bmatrix}$	[b]	· ` `		$\otimes$		[a] [S] · ·	$ [S] \\ [b] \\ [S] \\ \cdot \\ \cdot \\ \cdot \\ \cdot $	. [a] [S]	$\begin{bmatrix} S \end{bmatrix}$ $\begin{bmatrix} S \end{bmatrix}$ $\begin{bmatrix} S \end{bmatrix}$	! [a [S	[	. \								
	<i>[</i>	.[a]	١.,		•	.																			
			. [6	i].																					
					•		•		•																
					[a]																				
							•																		
	<u> </u>																								•
						. [	S		[S]																
					•		. [		•																•
					•		•		[S]		[S]														•
					•		•		•	[S]		•							•		•		•	•	•
					•		•		•		[S]		[S]						•		•		•	•	•
		• •			•		•	•	٠		•				•		•				•	•	•	•	•
	<u></u>		•		•		•	•	•	•	•	•	[S]		•		•				•	•	•	•	_ •
					•		•	•	•	•	•	•	•				•		•	•	•	•	•	•	•
					•		•	•	•	•	•	•	•		[b]		•		•	•	•	•	•	•	•
			•		•		•	•	•	٠	•	٠	•		•		•		•	•	•	•	•	•	٠
=					•		•	•	•	•	•	•	٠		•	. [	[b]		•	٠	•	•	•	•	•
			•		•		•	•	•	٠	•	٠	•		•	•	•		•	•	•	•	•	•	٠
			•		•		•	•	•	٠	•	٠	•		•	•	•	. [b]	•	•	•	•	•	•	٠
	<u></u>		•	• •	•	•	•	•	•	•	•	•	•		•	•	•	• •		•		•	•	•	•
					•		•	•	•	•	•	•	•		•	•	•		[S]		[S]	•	•	•	٠
			•		•	•	•	•	•	٠	•	•	•		•	•	•		•	[S]	[ <i>C</i> ]	•	[0]	•	•
			•		•		•	•	٠	٠	•	•	٠		•	•	•		•	•	[S]	[ <i>C</i> ]	[S]	•	•
			•		•		•	•	٠	٠	•	•	٠		•	•	•		•	•	٠	[S]	[ <i>C</i> ]	•	[C
			•		•	1	•	•	•	•	•	•	•		•	•	•		•	•	•	•	[S]	[ <i>C</i> ]	[S
			•		•		•	•	•	•	•	•	•		•	•	•		•	•	•	•	•	[S]	[ <b>Q</b>
			•	• •	•	+	•	•	•	•	•	•	•		•	•	•	• •	٠	•	•	•	•	•	[S]
			•	•	•		•	•	•	•	•	•	•		•	•	•		•	•	•	•	•	•	•
			•	• •	•		•	•	•	٠	•	•	•		٠	•	•		•	•	•	•	•	•	•
					•		•	•	•	•	•	•	•		•	•	•		•	•	•	•	•	•	•
			•		•		•	•	•	•	•	•	•		•	•	•		•	•	•	•	•	•	•
			•	•	•		•	•	•	•	•	•	•		•	•	•			•	•	•	•	•	•
			•	•	•		•	•	•	•	•	•	•		•	•	•			•	•	•	•	•	•
	(	۱۰ .	•		•	•	•	•	•	•	•	•	•	•••	•	•	•	•		(6.	20)	٠	٠	•	•


Транзитивное замыкание:

 $tc(M_3) =$ 

•	 •	• •	$\cdot   \cdot$	L	a	•		•	•	•			٠	[a8	3]	•	[aS]	•	٠	٠		[aSb	] .	[aSb]	] •	•			[aSbS]	•	[aSbS]	•	•
	 •	• •	. -		•	•	۲,		•	•		•	•	•		•		•		•		•	•				•	•	٠	•		•	
	 •	• •	1		•	•	[(	$\iota_{ floor}$	•	•		1	•	•		•	[aS]	•	[aS]	•		•	•	[aSb]		[aSb]	•	•	•	•	[aSbS]	•	[aSbS
		•	. .		•	•		•	•	[0	.1	1	•	•		•	•	•	[aS]	•		•	•	•	•	· [aSb]	•	•	•	•	•	•	[aSbS
	 •	•			•	•		•	•	Įα	<u>'</u> ] '		•	•		•	•	•	[aa]	•		•	•	•	•	[asu]	•	•	•	•	•	•	[aoua
	 •	•			•	•		•	•	•			•	•		•	•	•	•	•		•	•	•	•	•	•	•	•	•	•	•	•
-	 _		1		_	_		<u>.                                    </u>	_				$\overline{[S]}$			$\frac{\cdot}{[S]}$			<u>.</u>			<u>.</u>	•		•	•		<u>.</u>			<u> </u>		
																[~ ]										•							
														١~٠	J	[S]		[S]															
			. .														[S]				l												
			. .									- 1								[S]													
			. .																[S]														
			. .																	$\Gamma \Omega$													
			. .																														
			. .																			[b]											
			. .																														
			$\cdot$																					[b]									
			$\cdot   \cdot$																														
			. .																							[b]							
			. .																													•	
			$\cdot   \cdot$									$\cdot  $															[S]		[S]				
			. .																									[S]					
			$\cdot   \cdot$					•									•												[S]		[S]		
			$\cdot   \cdot$																											[S]			
	 •		$\cdot   \cdot$					•										•							•						[S]		[S]
	 •		$\cdot   \cdot$			•		•								•	•	•				•			•					•		[S]	
_			. .			•		•								•	•	•	•	•		•	•	•	•	•		•	•	•	•	•	[S]
	 •		$\cdot   \cdot$			•		•									•	•					•	٠	•	•				•	•	•	
	 •		$\cdot   \cdot$		•	•		•						•		•	•			•		•	•		٠				•	•		•	•
	 •		$\cdot   \cdot$		•	•		•						•		•	•			•		•	•		٠				•	•		•	•
	 •		$\cdot   \cdot$		•			•		•		•	•	•		•	•	•	•	٠		•	•	•	•	•			•	•	•	•	٠
	 •		$\cdot   \cdot$		•			•		•		•	•	•		•	•	•	•	٠		•	•	•	•	•			•	•	•	•	•
	 •		$\cdot   \cdot$		•			•					•	٠		٠	٠	•	٠	٠		•	•	•	٠	•	•	•	٠	•	•	•	•
	 •		$\cdot   \cdot$			•		•	•	•		$\cdot  $					•	•	•	•	• •		•		•							•	

Обновлённый граф:

На этом шаге мы смогли "склеить" из подстрок, выводимых из S, более длинные пути. Однако, согласно правилам грамматики, мы смогли "склеить" только две подстроки в единое целое.



Матрица смежности обновлённого графа:

$$M_{2} = \begin{pmatrix} [S] & [a] & [S] & . & [\mathbf{S}] & . \\ . & [S] & [b] & . & . & . \\ . & . & [S] & [a] & [S] & . & [\mathbf{S}] \\ . & . & . & [S] & [b] & . & . \\ . & . & . & . & . & [S] & [a] & [S] \\ . & . & . & . & . & . & . & [S] \end{pmatrix}$$

И, наконец, последняя содержательная итерация.

$M_3$	$=M_1^1\otimes M_2$	2 =		[a]	. [2	[6] . [6] .	[S		$\otimes$		[a] [S]	$ [S] \\ [b] \\ [S] \\ \cdot \\ \cdot \\ \cdot \\ \cdot $	[S]	[S] [S] [b] [S]	[a]	[S] ] [S] [S]	[] ]	=							
	<i>(</i>	. [a	].				١.										•		١.						. \
		ļ		[a]									•					•		•	•				
				•									•												
				•	. [	a].							•					•		•	•		•		
				•			•	•		•	•	•	•				•	•		•	•	•	•	•	
	<u> </u>		•	•	•			•				•	•		•		•	•	•	•	•	•	•	•	
			•	•	•		[S]	[ <i>C</i> ]	[S]	•	[S]	•	•		•		•	•		•	•	•	٠	•	.
			•	٠	•		•	[S]	[S]	•	[S]	•	[S]		•		•	•		•	•	•	•	•	•
			•	•	•	• •	•	•		[S]		٠	[D]		•		•	•		•	•	•	•	•	
			•	•							[S]	•	[S]				•	•		•	•	•	•	•	
					•							[S]													
													[S]												
															[b]										
=																. [b	] .				•				
		ļ																							
													•					[b]		•	•				
				•									•				•	•		•	•	•			
										•		•	•						S		[S]	•	[S]		
			٠	•								•	•							[S]		•			.
			٠	•			•	٠	٠	٠	٠	•	•				•	•		•	[S]		[S]	•	[S]
				•	•			•	•	•	•	•	٠	• •	•		•	•		•	•	[S]	[ <i>[</i> ]	•	
			٠	٠	•		•	٠	•	•	٠	•	•		٠		٠	•		•	•	٠	[S]	[ <i>C</i> ]	[S]
			•	•	•		•	•	•	•	•	•	٠		•		•	•	•	٠	٠	•	٠	[S]	[S]
	• • • • • • •		•	•	•	• •	•	•	•	•	•	•	•		•		•	•	•	•	•	•	•	•	
			•	•	•		•	•	•	•	•	•	•		•		•	•		•	•	•	•	•	•
			•	•	•			•	•	•	•	•	•		•		•	•		•	•	•	•	•	.
			•	•			•	•	•	•	•	•	•		•		•	•		•	•	•	•	•	
								•	•	•	•		•					•		•	•		•		
													•								•				. )
	\	I					I							I					I	(6	.22)				/

Транзитивное замыкание:

 $tc(M_3) =$ [S] . [S](6.23)

В конечном итоге мы получаем такой же результат, как и при первом за-

пуске. Однако нам потребовалось выполнить существенно больше итераций внешнего цикла, а именно четыре (три содержательных и одна проверочная). При этом, в ходе работы нам пришлось оперировать существенно бо́льшими матрицами:  $35 \times 35$  против  $21 \times 21$ .

Таким образом — минимизация рекурсивного автомата как конечного автомата над смешанным алфавитом может быть полезна.

#### 6.5 Замечания о реализации

Блочная структура матриц даёт хорошую основу для распределённого умножения при построении транзитивного замыкания. В наших матрицах куча пустых ячеек, для которых можно даже не выделять память. Аналогично и для пустых блоков. Поэтому каждую матрицу можно представить в виде блочно-разреженной.

Транзитивное замыкание.

#### 6.6 Вопросы и задачи

- 1. Оценить пространсвенную сложность алгоритма.
- 2. Оценить временную сложность алгоритма.
- 3. Найти библиотеку для тензорного произведения. Реализовать алгоритм. Можно предпологать, что запросы содержат ограниченное число терминалов и нетерминалов. Провести замеры. Сравнить с матричным.
- 4. Реализовать распределённое решение. См. блочную структуру

#### Глава 7

# Сжатое представление леса разбора

Матричный алгоритм даёт нам ответ на вопрос о достижимости, но не предоставляет самих путей. Что делать, если мы хотим построить все пути, удовлетворяющие ограичениям?

Проблема в том, что искомое множество путей может быть бесконечным. Можем ли мы предложить конечную структуру, однозначно описывающую такое множество? Вспомним, что пересечение контекстно-свободного языка с регулярным — это контекстно-свободный язык. Мы знаем, что конекстно-свободный язык можно описать коньекстно-своюодной граммтикой, которая конечна. Это и есть решение нашего вопроса. Осталось толко научиться строить такую грамматику.

Прежде, чем двинуться дальше, рекомендуется вспомнить всё, что касается деревьев вывода 2.2.

# 7.1 Лес разбора как представление контекстно-свободной грамматики


Для начала нам потребуется внести некоторые изменения в конструкцию дерева вывода.

Во-первых, заметим, что в дереве вывода каждый узел соответсвует выводу какой-то подстроки с известными позициями начала и конца. Давайте будем сохранять эту информацию в узлах дерева. Таким образом, метка любого узла это тройка вида (i, q, j), где i— координата начала подстроки, со-

ответствующей этому узлу, j — координата конца,  $q \in \Sigma \cup N$  — метка как в исходном определении.

Во-вторых, заметим, что внутренний узел со своими сыновьями связаны с продукцией в граммтике: узел появляется благодаря применению конкретной продукции в процессе вывода. Давайте занумеруем все продукции в граммтике и добавим в дерево вывода ещё один тип узлов (дополнительные узлы), в которых будем хранить номер применённой продукции. Получим следующую конструкцию: непосредственный предок дополнительного узла — это левая часть продукции, а непосредственные сыновья дополнительного узла — это правая часть продукции.


**Пример 7.1.1.** Построим модифицированное дерево вывода цепочки  $_0a_1b_2a_3b_4a_5b_6$  в грамматике




Сохраняемая нами дополнительная информация позволит переиспользовать узлы в том случае, если деревьев вывода оказалось несколько (в случае неоднозначной грамматики). При этом мы можем не бояться, что переиспользование узлов может привести к появлению ранее несуществовавших деревьев вывода, так как дополнительная информация позволяет делать только "безопасные" склейки и затем восстанавливать только корректные деревья.

**Пример 7.1.2.** Сжатие леса вывода. Построим несколько деревьев вывода цепочки  $_0a_1b_2a_3b_4a_5b_6$  в грамматике


Пердположим, что мы строим левосторонний вывод. Тогда после первого применеия продукции 0 у нас есть два варианта переписывания первого нетерминала: либо с применением продукции 0, либо с применением продукции 1. В первом случае мы примени переписываение по подукции 0. Дальнейшие шаги деретерминированы и в результате мы получим следующее дерево разбора:



Второй вариант — применить продукцию 1. Остальные шаги также детерминированы. Тогда мы получим следующее дерево вывода:



В двух построенных деревьях большое количество одинаковых узлов. Построим структуру, которая содержит оба дерева и при этом никакие нетерминальные и терминальные узлы не встречаются дважды. В результате мы молучим следующий граф:



Мы получили очень простой вариянт сжатого представления леса разбора (Shared Packed Parse Forest, SPPF). Впервые подобная идея была предложена Джоаном Рекерсом в его кандидатской диссертации [59]. В дальнейшем она нашла широкое применеие в обобщённом (generalized) синтаксическом анализе и получила серьёзное развитие. В частности, наш вариант, хоть и позволяет избежать экспоненциального разростания леса разбора, всё же не является оптимальным. Оптимальное асимптотическое поведение достигается при использовании бинаризованного SPPF [12] — в этом случае объём леса составляет  $O(n^3)$ , где n — это длина входной строки.


SPPF применяется в таких алгоритмах синтаксического анализа, как RNGLR [64], бинаризованная верся SPPF в BRNGLR [66] и GLL [65, 2] $^{1}$ .

<sup>&</sup>lt;sup>1</sup>Ещё немного полезной информации про SPPF: http://www.bramvandersanden.com/

В действительности SPPF может содержать в себе циклы. Для линейного входа можно получить граф, когда есть возможность выводить по грамматике бесконечные эпсилон-цепочки. Циклы будут вырожденными, но они будут. SPPF также можно построить и для графов.

В графе может существовать множество способов получить путь из одной вершины в другую. И точно так же при построении деревьев вывода путей может появиться несколько одинаковых нетерминалов, получаемых в разных деревьях по-разному. При объединении в SPPF может оказаться, что какой-то путь из вершины a в вершину b является подпутем другого пути из вершины a в вершину b, просто более длинного. То есть появятся циклические зависимости.

#### **Пример 7.1.3.** Дан граф $\mathcal{G}$ :



Дана грамматика

$$G = \langle \{a, b\}, \{S\}, S, \{$$


$$(0) S \to a S b,$$

$$(1) S \to a b,$$


$$\} \rangle$$

Попробуем найти все пути из вершины 2 в вершину 2, выводимые из нетерминала S. Методом пристального взгляда найдем один из них. Пусть это будет  $2a_0a_1a_2a_0a_1a_2b_3b_2b_3b_2b_3b_2$ . Построим дерево его вывода.

post/2014/06/shared-packed-parse-forest/.



Так как это только один путь, а таких путей гораздо больше, то к нетерминалу  $_1S_3$  применим также применим продукцию 0. Тогда мы получим нетерминал  $_2S_2$ , который и создаст цикл.



Таким образом мы построили SPPF. Обойдя эту структуру необходимое количество раз, мы можем получить любой путь, удовлетворяющий условию. Более того, в полученном графе можно получать любые другие пути по соответствующим нетерминалам, содержащимся в узлах леса.

По полученному графу построим грамматику:

$$(0) {}_{2}S_{2} \rightarrow {}_{2}a_{0} {}_{0}S_{3} {}_{3}b_{2}$$

$$(1) {}_{0}S_{3} \rightarrow {}_{0}a_{1} {}_{1}S_{2} {}_{2}b_{3}$$

$$(2) {}_{1}S_{2} \rightarrow {}_{1}a_{2} {}_{2}S_{3} {}_{3}b_{2}$$

$$(3) {}_{2}S_{3} \rightarrow {}_{2}a_{0} {}_{0}S_{2} {}_{2}b_{3}$$

$$(4) {}_{0}S_{2} \rightarrow {}_{0}a_{1} {}_{1}S_{3} {}_{3}b_{2}$$

$$(5) {}_{1}S_{3} \rightarrow {}_{1}a_{2} {}_{2}S_{2} {}_{2}b_{3}$$

$$(6) {}_{1}S_{3} \rightarrow {}_{1}a_{2} {}_{2}b_{3}$$

Видим, что для одного единственного нетерминала  $_1S_3$  существует 2 правила, одно из которых рекурсивное. Попробуем получить левосторонний вывод какой-нибудь цепочки в этой грамматике:

```
 2S_{2} \overset{(0)}{\Longrightarrow} 
 2a_{0} \ _{0}S_{3} \ _{3}b_{2} \overset{(1)}{\Longrightarrow} 
 2a_{0} \ _{0}a_{1} \ _{1}S_{2} \ _{2}b_{3} \ _{3}b_{2} \overset{(2)}{\Longrightarrow} 
 2a_{0} \ _{0}a_{1} \ _{1}a_{2} \ _{2}S_{3} \ _{3}b_{2} \overset{(2)}{\Longrightarrow} 
 2a_{0} \ _{0}a_{1} \ _{1}a_{2} \ _{2}S_{3} \ _{3}b_{2} \ _{2}b_{3} \ _{3}b_{2} \overset{(3)}{\Longrightarrow} 
 2a_{0} \ _{0}a_{1} \ _{1}a_{2} \ _{2}a_{0} \ _{0}a_{1} \ _{1}a_{2} \ _{2}b_{3} \ _{3}b_{2} \ _{2}b_{3} \ _{3}b_{2} \overset{(5)}{\Longrightarrow} 
 2a_{0} \ _{0}a_{1} \ _{1}a_{2} \ _{2}a_{0} \ _{0}a_{1} \ _{1}a_{2} \ _{2}S_{2} \ _{2}b_{3} \ _{3}b_{2} \ _{2}b_{3} \ _{3}b_{2} \ _{2}b_{3} \ _{3}b_{2} \overset{(5)}{\Longrightarrow} 
 2a_{0} \ _{0}a_{1} \ _{1}a_{2} \ _{2}a_{0} \ _{0
```

Мы получили цепочку, которая действительно является путем из вершины 2 в вершину 2 в заданном графе. Таким образом выводятся и любые другие соответствующие пути.

#### 7.2 Вопросы и задачи

- 1. Постройте дерево вывода цепочки w=aababb в грамматике  $G=\langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \ S \ b \ S\}, S \rangle.$
- 2. Постройте все левосторонние выводы цепочки w = ababab в грамматике  $G = \langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \ S \ b \ | S \ S\}, S \rangle$ .
- 3. Постройте все правосторонние выводы цепочки w = ababab в грамматике  $G = \langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \mid S \mid b \mid S \mid S\}, S \rangle$ .
- 4. Постройте все деревья вывода цепочки w = ababab в грамматике  $G = \langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \mid S \mid b \mid S\}, S \rangle$ , соответствующие левосторонним выводам.
- 5. Постройте все деревья вывода цепочки w = ababab в грамматике  $G = \langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \ S \ b \ | S \ S\}, S \rangle$ , соответствующие правосторонним выводам.
- 6. Как связаны между собой леса, полученные в предыдущих двух задачах (4 и 5)? Какие выводы можно сделать из такой связи?
- 7. Постройте сжатое представление леса разбора, полученного в задаче 4.
- 8. Постройте сжатое представление леса разбора, полученного в задаче 5.
- 9. Предъявите контекстно-свободную граммтику существенно неоднозначного языка. Возьмите цепочку длины болше пяти, при надлежащую этому языку, и постройте все деревья вывода этой цепочки в предъявленной граммтике.
- 10. Постройте сжатое представление леса, полученного в задаче 9.

# Глава 8

# Алгоритм на основе восходящего анализа

Традиционно, алгоритмы, применяемые для анализа языков программирования как раз умеют строить дерево разбора— то, что нам надо. Только нам бы лес. Вот и посмотрим, как это можно сделать.

Сперва поговорим про классический синтаксический анализ, потом про его адаптацию к анализу графов.

### 8.1 Восходящий синтаксический анализ

LR(k) — алгоритм восходящего синтаксического анализа. Идея заключается в следующем: входная последовательность символов считывается слева направо с попутным добавлением в стек и выполнением сворачивания — замены последовательности терминалов и нетерминалов, лежащих наверху стека, на нетерминал, если существует соответствующее правило в исходной грамматике.

**Определение 8.1.1.** Слот (item) — правило грамматики, в правой части которого имеется точка, отделяющая уже разобранную часть правила (слева от точки) от того, что еще предстоит распознать (справа от точки).

**Определение 8.1.2.** LR-автомат — автомат с магазинной памятью, состояния которого задаются "слотами", также он имеет следующий набор инструкций:

1. shift p — прочитать следующий символ входной последовательности, положив его в стек, и перейти в состояние р

2. reduce k — применить k-ое правило грамматики, правая часть которого уже лежит на стеке: снимаем правую часть и кладём левую часть

**Определение 8.1.3.** Предпросмотр — метод, применяемый в синтаксическом анализе. Заключается в следующем: устанавливается максимальное количество входящих символов, которое может быть использовано анализатором для решения того, какое правило использовать (в случае восходящего анализа: к какому правилу нужно свернуться).

Определение 8.1.4. Управляющая таблица — таблица, которая для всех состояний LR-автомата содержит: инструкции для выполнения, если на вершине стека — терминал (при этом в случае LR(k) в каждой ячейке может находиться не более одной инструкции), номер состояния, в которое нужно перейти, если на вершине стека — нетерминал.

Когда в текущем состоянии '.' стоит в конце, мы можем выполнить reduceинструкцию и перейти в новое состояние. Однако при этом могут возникать следующие конфликты:

- shift-reduce ситуация, когда не понятно, читать ли следующий символ или выполнить reduce. Например, если правая часть одного из правил является префиксом правой части другого правила:  $N \to w, M \to ww'$ .
- reduce-reduce ситуация, когда не понятно, к какому правилу нужно применить reduce. Например, если есть два правила с одинаковыми правыми частями:  $N \to w, M \to w$ .

Возьмем следующую грамматику:

$$0)S \to aSbS$$
$$1)S \to \varepsilon$$

Расширим вышеупомянутую грамматику, добавив новый стартовый нетерминал S', и далее будем работать с этой расширенной грамматикой:

$$0)S \to aSbS$$
$$1)S \to \varepsilon$$
$$2)S' \to S\$$$

**Определение 8.1.5.** Замыкание — обобщение понятия "item", заключающееся в добавлении для каждого item'а вида  $N \to \alpha.M\beta$  item'ов вида  $M \to .\gamma$ 

123

**Определение 8.1.6.** Ядро — исходный item, до применения к нему замыкания.

Пример 8.1.1. Пример ядра и замыкания.

Возьмем правило 2 нашей грамматики, предположим, что мы только начинаем разбирать данное правило.

Ядром в таком случае является item исходного правила:  $S' \to .S$ \$

При замыкании добавятся ещё два item'a с правилами по выводу нетерминала 'S', поэтому получаем три item'a:  $S' \to .S\$$ ,  $S \to .aSbS$  и  $S \to .\varepsilon$ 

**Пример 8.1.2.** Пример построения LR-автомата для нашей грамматики с применением замыкания.

1. Добавляем стартовое состояние: item правила 0 и его замыкание (вместо item'a  $S \to .\varepsilon$  будем писать  $S \to .$ ).

$$\begin{pmatrix}
S' \to .S\$ \\
S \to .aSbS \\
S \to .
\end{pmatrix}$$


2. По 'S' добавляем переход из стартового состояния в новое состояние 1.

$$\begin{array}{c}
S' \to .S\$ \\
S \to .aSbS \\
S \to .
\end{array}$$


$$S$$

$$S' \to S.\$$$


3. По '\$' добавляем переход из состояния 1 в новое состояние 2.




4. По 'а' добавляем переход из стартового состояния в новое состояние 3 и делаем его замыкание. Также добавляем переход по 'а' из этого состояния в себя же.




5. По 'S' добавляем переход из состояния 3 в новое состояние 4.



6. По 'b' добавляем переход из состояния 4 в новое состояние 5 и делаем его замыкание. Также добавляем переход по 'a' из этого состояния в состояние 3.



7. По 'S' добавляем переход из состояния 5 в новое состояние 6. Завершаем построение LR-автомата.



**Пример 8.1.3.** Пример управляющей таблицы для работы с построенным ранее LR-автоматом.

	a	b	\$	S
0	shift 3	reduce 1	reduce 1	1
1			ACCEPT	
2				
3	shift 3	reduce 1	reduce 1	4
4		shift 5		
5	shift 3	reduce 1	reduce 1	6
6		reduce 0	reduce 0	

**Ход работы LR-парсера.** Пусть у нас есть входная строка, LR-автомат со стеком и управляющая таблица.

В начальный момент на стеке лежит стартовое состояние LR-автомата, позиция во входной строке соответствует её началу. На каждом шаге анализируется текущий символ входа и текущее состояние, в котором находится автомат, и совершается одно из действий:

- Если текущая позиция конец строки и в стеке стартовый нетерминал исходной грамматики, то успешно завершаем разбор.
- Если в управляющей таблице нет инструкции для текущего состояния автомата и текущего символа на входе, то завершаем разбор с ошибкой.
- Иначе выполняем инструкцию:
  - 1) в случае shift кладем на стек текущий символ входа, сдвигая при

этом текущую позицию, и номер нового состояния с переходом в него.

2) в случае reduce — снимаем со стека 2k элементов: k состояний и k терминалов/нетерминалов (где k — длина правой части правила, участвующего в свёртке), кладём на стек нетерминал левой части правила и, оказавшись в некотором состоянии, в котором мы были ранее (самое близкое к вершине из хранимых на стеке состояний), выполняем переход в новое состояние с добавлением его номера в стек, если в управляющей таблице пересечение текущего состояния и добавленного ранее нетерминала — не пусто.

**Пример 8.1.4.** Пример LR-разбора входного слова abab\$ из языка нашей грамматики с использованием построенных ранее LR-автомата и управляющей таблицы.

1. Начало разбора. На стеке — стартовое состояние 0.

Вход: **a** b a b \$ Стек: 0

2. Выполняем shift 3: сдвигаем указатель на входе, кладем на стек 'a', новое состояние 3 и переходим в него.

Вход: а <mark>b</mark> a b \$ Стек: 0 a 3

3. Выполняем reduce 1 (кладем на стек 'S'), кладем новое состояние 4 и переходим в него.

Вход: а b a b \$ Стек: 0 a 3 S 4

4. Выполняем shift 5: сдвигаем указатель на входе, кладем на стек 'b', новое состояние 5 и переходим в него.

Вход: а b a b \$ Стек: 0 a 3 S 4 b 5

5. Выполняем shift 3.

Вход: а b a b \$ Стек: 0 a 3 S 4 b 5 a 3

6.	Выполняем	$_{ m reduce}$	1,	кладем	новое	состояние	4	И	переходим	В	него.
----	-----------	----------------	----	--------	-------	-----------	---	---	-----------	---	-------

Вход: а b a b \$ Стек: 0 a 3 S 4 b 5 a 3 S 4

7. Выполняем shift 5.

Вход: b \$ Стек: 0 3 S 4 b 5 3 S b 5  $\mathbf{a}$ b a a

8. Выполняем reduce 1, кладем новое состояние 6 и переходим в него.

Вход: а b a b <mark>\$</mark> Стек: 0 a 3 S 4 b 5 a 3 S 4 b 5 S 6

9. Выполняем reduce 0 (снимаем со стека 8 элементов и кладем 'S'), оказываемся в состоянии 5 и делаем переход в новое состояние 6 с добавлением его на стек.

Вход: a b a b \$ Стек: 0 a 3 S 4 b 5 S 6

10. Снова выполняем reduce 0, оказываемся в состоянии 0 и делаем переход в новое состояние 1 с добавлением его на стек. Заканчиваем разбор.

Вход: а b a b \$ Стек: 0 S 1

На практике конфликты стараются решать ещё и на этапе генерации. Да, реальные тулы могут сгенерировать парсер по неоднозначной грамматике: из переноса или свёртки выбирать перенос, из нескольких свёрток — первую в каком-то порядке (обычно в порядке появления соответствующих продукций в грамматике).

Существует также модификация LR-разбора, которая называется SLR (Simple LR). Основная идея заключается в том, чтобы хранить в управляющей таблице reduce-инструкции только для тех терминалов, которые встречаются в правилах грамматики сразу после нетерминала, к которому выполняется свертка. Также существует LALR модификация (Look-Ahead LR). В ней применяется склеивание нескольких состояний автомата, входные дуги которых имеют общие символы переходы, в одно состояние. Данные модификации позволяют избежать большее число конфликтов, однако иногда могут иметь таблицы

большего размера, чем в классическом LR. Стоит отметить, что LALR(1)-парсер — менее мощный, чем LR(1)-парсер, но более мощный, чем SLR(1)-парсер.

# 8.2 GLR и его применение для KC запросов

Алгоритм LR довольно эффективен, однако позволяет работать не со всеми КС-грамматиками, а только с их подмножеством LR(k). Если грамматика находится за рамками допускаемого класса, некоторые ячейки управляющей таблицы могут содержать несколько значений. В этом случае грамматика отвергалась анализатором.

Чтобы допустить множестенные значения в ячейках управляющей таблицы, потребуется некоторый вид недетерминизма, который даст возможность анализатору обрабатывать несколько возможных вариантов синтаксического разбора параллельно. Именно это и предлагает анализатор Generalized LR (GLR) [74]. Далее мы рассмотрим общий принцип работы, проиллюстрируем его с помощью примера, а также рассмотрим модификации GLR.

#### 8.2.1 Классический GLR алгоритм

Впервые GLR парсер был представлен Масару Томитой в 1987 [74]. В целом, алгоритм работы идентичен LR с несколькими принципиальными исключениями:

- Управляющая таблица модифицирована таким образом, чтобы допускать множественные значения в ячейках.
- Для каждой операции reduce, которую мы можем применить на каком-то этапе разбора, создается копия всего стека, после чего, к ней применяется эта операция.
- Если к стеку нельзя применить ни одну операцию shift на следующем входном символе, то этот стек отбрасывается.

Однако, полное копирование стеков приводит к тому, что дублируется слишком много информации. Поэтому можно сделать следующее:

• Объединять одинаковые состояния.

129

• Объединять одинаковые правые префиксы стеков (то есть верхние их части, к которым быстрее всего доберутся операции reduce).

Для этого стоит использовать более сложную структуру стека:  $spa\phi$ -cmpykmypupoванный <math>cmek или (GSS, Graph Structured Stack). Это направленный граф, в котором вершины соответствуют элементам стека, а ребра их соединяют по правилам управляющей таблицы. У каждой вершины может быть несколько входящих и исходящих узлов: таким образом реализуется то самое объединение, упомянутое в предыдущем абзаце.

Пример 8.2.1. Рассмотрим пример GLR разбора с использованием GSS.

Возьмем грамматику G следующего вида:

$$0. S' \rightarrow S$$

1. 
$$S \rightarrow abC$$

2. 
$$S \rightarrow aBC$$


3. 
$$B \rightarrow b$$

4. 
$$C \rightarrow c$$

Входное слово w:

$$w = abc$$
\$

Построим для данной грамматики LR автомат:



И управляющую таблицу:

	a	b	c	\$	В	С	S
0	shift 2					goto 1	
1				accept			
2		shift 3			goto 4		
3			shift 6 OR reduce 3			goto 5 goto 7	
4			shift 6			goto 7	
5				reduce 1			
6				reduce 4			
7				reduce 2			

Разберем слово w с помощью алгоритма GLR. Использована следующая аннотация: вершины-состояния обозначены кругами, вершины-символы — прямоугольниками.

1. Инициализируем GSS стартовым состоянием  $v_0$ :

Bход:  $\boxed{\mathbf{a} \hspace{0.1cm} | \hspace{0.1cm} \mathbf{b} \hspace{0.1cm} \mathbf{c} \hspace{0.1cm} \$}$  GSS:  $\boxed{0}^{v_0}$ 


2. Видим входной символ 'a', ищем соответствующую ему операцию в управляющей таблице —  $shift\ 2$ , строим новый узел  $v_1$ :




3. Повторяем для символа 'b', операции shift 3 и узла  $v_2$ :




4. При обработке узла  $v_3$  у нас возникает конфликт shift-reduce: shift 6 OR reduce 3. Мы смотрим на вершины, смежные  $v_2$ , на управляющую таблицу и на правило вывода под номером 3 для поиска альтернативного построения стека. Находим goto 4 и строим вершину  $v_3$  с соответствующим переходом по нетерминалу B из  $v_1$  (т.к. количество символов в правой части правила вывода 3 равняется 1, значит мы в дереве опустимся на глубину 1 по вершинам-состояниям):




5. Читаем символ 'c' и ищем в управляющей таблице переходы из состояний 3 и 4 (так как узлы  $v_2$  и  $v_3$  находятся на одном уровне, то есть были построены после чтения одного символа из входного слова). Таким переходом оказывается shift 6 в обоих случаях, поэтому соединяем узел  $v_4$  с обоими рассмотренными узлами:




6. При обработке узла  $v_4$  находим соответствующею 6-ому состоянию редукцию по правилу 4. Его правая часть содержит один символ 'c', 2 вершины-символа с которым достижимы из  $v_4$ . Находим вершины-состояния, которые смежны с этими вершинами-символами и обрабатываем переходы по левой части правила 4. Такими переходами по нетерминалу C оказываются goto 5 и goto 7. Строим соответствующие им вершины  $v_5$  и  $v_6$ :



7. При обработке узлов  $v_5$  и  $v_6$  находим редукции с символом 'S' в левой части и тремя символами в правой. Возвращаемся на 3 вершины-состояния назад и строим вершину  $v_7$  с переходом по S:



8. Наконец, обрабатывая вершину  $v_7$ , читаем символ '\$' и строим узел  $v_8$ , который соответствует допускающим состоянием:



#### 8.2.2 Модификации GLR

Алгоритм, представленный Томитой имел большой недостаток: он корректно работал не со всеми КС грамматиками, хоть и расширял класс допустимых LR анализаторами. Объем потребляемой памяти классическим GLR можно оценить как  $O(n^3)$  с учетом оптимизаций, о которых говорилось ранее.

Спустя пару лет после публикации Томита-парсера, Элизабет Скотт и Эндриан Джонстоун представили RNGLR (Right Nulled GLR) [64] — модифицированная версия GLR, которая решала проблему скрытых рекурсий. Это позволило расширить класс допускаемых грамматик до КС. Однако объем потребляемой памяти можно оценить сверху уже полиномом  $O(n^{k+1})$ , где k — длина самого длинного правила грамматики, что несколько ухудшило оценку классического GLR.

С этой проблемой справился BRNGLR (Binary RNGLR) [66]. За счет бинаризации удалось получить кубическую оценку сложности и при этом также, как и RNGLR, допускать все КС грамматики.

Кроме того, GLR довольно естесственно обобщается до последовательности входных вместо набора. Это происходит следующим образом: элементами во входной структуре теперь будем считать не позиции символа в слове, а вершины графа (то есть "позиция"и множество смежных вершин). Это приводит к тому, что при применении операции shift, следующих символов может быть несколько и каждый из них должен быть рассмотрен отдельно, сдвигаясь по соответствующему ребру и проходя входной граф в ширину. Подробное описание алгоритма и псевдокод представлены в работе [77].

### 8.3 Вопросы и задачи

- 1. Постройте LR автомат и управляющую таблицу для грамматики  $G_1$ :  $S \to aSb; S \to \epsilon$ .
- 2. Постройте LR автомат и управляющую таблицу для грамматики  $G_2$ :  $S \to SSS; S \to SS; S \to a$ .
- 3. Проведите GLR разбор для грамматики  $G_2$  и входного слова w = aaa\$.
- 4. Реализуйте LR анализатор на любом языке программирования. Программа должна принимать на вход файл с однозначной грамматикой и входное слово, строить LR автомат и управляющую таблицу (во внутреннем представлении), и сообщать, выводимо ли входное слово в данной грамматике.
- 6\*. Реализуйте GLR анализатор на любом языке программирования. Программа должна принимать на вход файл с однозначной грамматикой и входное слово, работать согласно алгоритму GLR и сохранять GSS, а также сообщать, выводимо ли входное слово в данной грамматике.

# Глава 9

# Алгоритм на основе нисходящего анализа

```
GLL [29]
Другие реализации [45]
```

### 9.1 Нисходящий синтаксический анализ

Рекурсивный спуск, LL, таблицы, неоднозначности, левая рекурсия.

## 9.1.1 Рекурсивный спуск

**Пример 9.1.1.** Постороим функцию рекурсивного спуска для продукции  $S \to aSbS$ .

#### Listing 6 Функция рекурсивного спуска

```
1: function S(hd', tl')
      res = \{\}
      if hd' = a then
3:
         res = S(tl')
4:
         else error
5:
      if head(res) = b then
6:
         res = S(tail(res))
7:
         else error
8:
9:
      return res
```

Если возвращаеммое значение этой функции пусто, то разбор завершился успехом.


#### 9.1.2 LL(k)-алгоритм синтаксического анализа

LL(k) — алгоритм синтаксического анализа — нисходящий анализ без отката, но с предпросмотром. Решение о том, какую продукцию применять, принимается на основании k следующих за текущим символом. Временная сложность алгоритма O(n), где n — длина слова.

Алгоритм использует входной буфер, стек для хранения промежуточных данных и таблицу анализатора, которая управляет процессом разбора. В ячей-ке таблицы указано правило, которое нужно применять, если рассматривается нетерминал A, а следующие m символов строки  $-t_1 \dots t_m$ , где  $m \le k$ . Также в таблице выделена отдельная колонка для \$ — маркера конца строки.

	 $t_1 \dots t_m$	 \$
$\overline{A}$	 $A \to \alpha$	 

Для построения таблицы вычисляются множества  $\operatorname{FIRST}_k$  и  $\operatorname{FOLLOW}_k$ . Идейно их можно понимать, как первые или последующие k символов в результирующем выводе, при использовании нетерминала A. Данную мысль хорошо иллюстрирует рисунок:



Определим их формально:

Определение 9.1.1. Пусть  $G = \langle N, \Sigma, P, S \rangle$  — КС-грамматика. Множество FIRST<sub>k</sub> определено для сентециальной формы  $\alpha$  следующим образом:

$$\mathrm{FIRST}_k(\alpha) = \{\omega \in \Sigma^* \mid \alpha \stackrel{*}{\Rightarrow} \omega \text{ и } |\omega| < k \text{ либо } \exists \beta : \alpha \stackrel{*}{\Rightarrow} \omega \beta \text{ и } |\omega| = k \}, \text{ где } \alpha, \beta \in (N \cup \Sigma)^*$$

**Определение 9.1.2.** Пусть  $G = \langle N, \Sigma, P, S \rangle$  — КС-грамматика. Множество FOLLOW определено для сентециальной формы  $\beta$  следующим образом:

$$FOLLOW_k(\beta) = \{ \omega \in \Sigma^* \mid \exists \gamma, \alpha : S \stackrel{*}{\Rightarrow} \gamma \beta \alpha \text{ и } \omega \in FIRST_k(\alpha) \}$$

В частном случае для k = 1:

$$\mathrm{FIRST}_1(\alpha) = \{ a \in \Sigma \mid \exists \gamma \in (N \cup \Sigma)^* : \alpha \stackrel{*}{\Rightarrow} a\gamma \},$$
 где  $\alpha \in (N \cup \Sigma)^*$ 

$$FOLLOW_1(\beta) = \{a \in \Sigma \mid \exists \gamma, \alpha \in (N \cup \Sigma)^* : S \stackrel{*}{\Rightarrow} \gamma \beta a \alpha \},$$
 где  $\beta \in (N \cup \Sigma)^*$ 

Множество  ${\tt FIRST}_1$  можно вычислить, пользуясь следующими соотношениями:

- FIRST<sub>1</sub> $(a\alpha) = \{a\}, a \in \Sigma, \alpha \in (N \cup \Sigma)^*$
- FIRST<sub>1</sub>( $\varepsilon$ ) = { $\varepsilon$ }
- $FIRST_1(\alpha\beta) = FIRST_1(\alpha) \cup (FIRST_1(\beta), если \varepsilon \in FIRST_1(\alpha))$
- FIRST<sub>1</sub>(A) = FIRST<sub>1</sub>( $\alpha$ ) $\cup$ FIRST<sub>1</sub>( $\beta$ ), если в грамматике есть правило  $A \to \alpha \mid \beta$

Алгоритм для вычисления множества FOLLOW<sub>1</sub>:

- Положим  $FOLLOW_1(X) = \emptyset, \forall X \in N$
- $\bullet$  FOLLOW $_1(S)=$  FOLLOW $_1(S)\cup\{\$\}$ , где S- стартовый нетерминал
- Для всех правил вида  $A \to \alpha X\beta$  :  $FOLLOW_1(X) = FOLLOW_1(X) \cup (FIRST_1(\beta) \setminus \{\varepsilon\})$
- Для всех правил вида  $A \to \alpha X$  и  $A \to \alpha X \beta$ , где  $\varepsilon \in \text{FIRST}_1(\beta) : \text{FOLLOW}_1(X) = \text{FOLLOW}_1(X) \cup \text{FOLLOW}_1(A)$
- Последние два пункта применяются пока есть что добавлять в строящиеся множества.

Пример множеств FIRST<sub>1</sub> для нетерминалов следующей грамматики:

$$S \to aS'$$

$$S' \to AbBS' \mid \varepsilon$$

$$A \to aA' \mid \varepsilon$$

$$B \to c \mid \varepsilon$$
FIRST<sub>1</sub>(S) = {a}
FIRST<sub>1</sub>(A) = {a, \varepsilon}
FIRST<sub>1</sub>(A) = {a, \varepsilon}
FIRST<sub>1</sub>(B) = {c, \varepsilon}
FIRST<sub>1</sub>(B') = {a, b, \varepsilon}

Пример множеств FOLLOW<sub>1</sub> для нетерминалов следующей грамматики:

$$S \to aS'$$
 FOLLOW<sub>1</sub>(S) = {\$}  
S' \to AbBS' | \varepsilon \text{ FOLLOW}\_1(S') = {\$}  
A \to aA' | \varepsilon \text{ FOLLOW}\_1(A) = {b} \text{ (S' \to AbBS')}  
A' \to b | a \text{ FOLLOW}\_1(A') = {b} \text{ (A \to aABS')}  
B \to c | \varepsilon \text{ FOLLOW}\_1(B) = {a, b, \$} \text{ (S' \to AbBS')}, \varepsilon \varepsilon \text{ FIRST}\_1(S')

Таблица заполняется следующим образом: продукции  $A \to \alpha, \alpha \neq \varepsilon$  помещаются в ячейки (A, a), где  $a \in \text{FIRST}_1(\alpha)$ , продукции  $A \to \alpha$  — в ячейки (A, a), где  $a \in \text{FOLLOW}_1(A)$ , если  $\varepsilon \in \text{FIRST}_1(\alpha)$ 

**Пример 9.1.2.** Пример таблицы для грамматики  $S \to aSbS \mid \varepsilon$ 

Однако, не для всех грамматик по множествам  $FIRST_k$  и  $FOLLOW_k$  возможно выбрать применяемую продукцию, а значит, нельзя однозначно построить таблицу, необходимую для работы алгоритма, поэтому данный алгоритм применим только для грамматик особого класса — LL(k).

**Определение 9.1.3.** LL(k) грамматика — грамматика, для которой на основании множеств  $FIRST_k$  и  $FOLLOW_k$  можно однозначно определить, какую продукцию применять.

Важно заметить, что при больших k строимая нами таблица сильно разрастается, поэтому на практике данный алгоритм применим для небольших значений k.

139

**Ход работы:** Интерпретатор автомата принимает входную строку и построенную управляющую таблицу и работает следующим образом. В каждый момент времени конфигурация автомата это позиция во входной строке и стек. В начальный момент времени стэк пуст, а позиция во входной строке соответствует её началу. На певом шаге в стек добавляются последовательно сперва симаол концы строки, затем стартовый нетерминал. На каждом шаге анализируется существующая конфигурация и совершается одно из действий.

- Если текущая позиция конец строки и вершина стека символ конца строки, то успешно завершаем разбор.
- Если текушая вершина стека терминал, то проверяем, что позиция в строке соответствует этому терминалу. Если да, то снимаем элемент со стека, сдвигаем позицию на единицу и продолжаем разбор. Иначе завершаем разбор с ошибкой.
- Если текущая врешина стека нетерминал  $N_i$  и текущий входной символ  $t_j$ , то ищем в управляющей таблице ячейку с координатами  $(N_i, t_j)$  и записываем на стек содержимое этой ячейки.

**Пример 9.1.3.** Пример работы LL анализатора. Рассмотрим грамматику  $S \to aSbS \mid \varepsilon$  и выводимое слово  $\omega = abab$ .

Расмотрим пошагово работу алгоритма, будем использовать таблицу, построенную в предыдущем примере:

1. Начало работы.



Финальный символ лежит на стеке, а указатель указывает на первый символ слова.

2. кладем стартовый символ на стек



3. Ищем ячейку с координатами (S, a), применяем продукцию из ячейки.



4. Снимаем терминал a со стека и двигаем указатель.



5. Ищем ячейку с координатами (S, b), применяем продукцию из ячейки.



6. Снимаем терминал b со стека и двигаем указатель.

Стек:	S	входное слово:	a	b	a	b	\$
	\$						


7. Ищем ячейку с координатами (S, a), применяем продукцию из ячейки.

Стек:	Стек:
-------	-------

8. Снимаем терминал a со стека и двигаем указатель.

	S						
Стек:	b	входное слово:	a	b	a	b	\$
	S					ļ.	
	\$						

9. Ищем ячейку с координатами (S, b), применяем продукцию из ячейки.



10. Снимаем терминал b со стека и двигаем указатель.



11. Ищем ячейку с координатами (S, \$), применяем продукцию из ячейки.



12. Оказались в конце строки и на вершине стека символ конца — завершаем разбор.

Еще одна существенная проблема данного алгоритма — грамматики, содержащие леворекурсивные правила, т.е правила вида  $Q \to Q \omega$ . Действительно, встретив на вершине стека нетерминал Q и применив данное правило, на вершине стека снова окажется Q и мы будем вынуждены вновь применять это правило, таким образом алгоритм зациклится. Та же проблема встречаестя и в грамматиках со скрытой левой рекурсией.

А ещё надо бы деревья научиться строить.

**Пример 9.1.4.** Пример работы LL анализатора с деревом. Таблца вида (стек, указатель во входе, дерево, комментарии)

Итого. По некоторым граммтикам можно построить LL(k) анализатор (назовём их LL(k) граммтиками), но не по всем. С левой рекурсией, конечно, можно бороться, существуют алгоритмы устранения левой и скрытой левой рекурсии, а вот с неодносзначностями ничего не поделаешь.

# 9.2 GLL и его применение для КС запросов

Можно построить анализатор, работающий с произвольными КС-грамматиками. Generalized LL (GLL) [65, 2]

Принцип работы остается абсолютно таким же как и для табличного LL:

- Сначала по грамматике строится управляющая таблица
- Затем построенная таблица команд и непосредственно анализируемое слово поступают на вход абстрактному интерпретатору.
- Для своей работы интерпретатор поддерживает некоторую вспомогательную структуру данных (стек для LL).
- Один шаг разбора состоит в том, чтобы рассмотреть текущую позицию в слове, применить соответствующее ей правило из таблицы и при возможности сдвинуть позицию разбора вправо.

Где в этой схеме возникают ограничения на вид обрабатываемой грамматики для алгоритма LL? На самом первом шаге — при построении таблицы может возникнуть ситуация, когда одному нетерминалу  $N_j$  и последовательности  $first_k(N_j)$  соответствует несколько продукций грамматики. В этом случае грамматика признавалась не соответствующей классу LL(k) и отвергалась анализатором.

Теперь же мы разрешим такую ситуацию и в этом случае в ячейку таблицы будем записывать все продукции грамматики, соответствующие этой ячейке. Однако сразу же возникает вопрос — а что делать интерпретатору, когда при разборе ему необходимо применить правило, состоящее из нескольких продукций? Общий ответ такой — необходим некоторый вид недетерминизма, при котором интерпретатор мог бы "параллельно" обрабатывать несколько возможных вариантов синтаксического разбора.

Эти два свойства (модифицированная управляющая таблица и недетерминизм) суть главные принципиальные отличия GLL(k) от LL(k). Далее мы перейдем к рассмотрению непосредственно технической реализации описанного алгоритма.

Нам необходимо научиться задавать различные ветви (пути) синтаксического разбора и переключаться между ними. Заметим, что состояние любой ветви в любой момент времени суть следующее: необходимо распознать символ  $N_j \in N \cup \Sigma$  из продукции X, начиная с элемента слова под индексом i. Т.е. имеем позицию в слове и позицию символа в продукции. Последнее принято называть слотом грамматики.

Определение 9.2.1. Пусть  $G = \langle N, \Sigma, P, S \rangle$  — КС-грамматика. Слотом грамматики G (позицией грамматики G) назовем пару из продукции  $X \in P$  и позиции  $0 \le q \le length(body(X))$  тела продукции X. При этом введем следующее обозначение  $X ::= \alpha \cdot \beta$ ,  $\alpha, \beta \in (N \cup \Sigma)^*$ , где  $\cdot$  указывает на позицию в продукции.

Описанная пара позиций уже однозначно задает состояние синтаксического разбора. Имеем множество состояний и переходов между ними — возникает естественное желание воспользоваться терминами графов для представления этой структуры. Такую конструкцию называют граф-структурированный стек или GSS (Graph Structured Stack), который впервые был предложен Масару Томитой [75] в контексте восходящего анализа. GSS будет являться рабочей структурой нашего нового интерпретатора вместо стека для LL. Состояние разбора вместе с узлом GSS мы будет называть дескриптором.

**Определение 9.2.2.** Пусть  $G = \langle N, \Sigma, P, S \rangle$  — КС-грамматика, X слот грамматики G, i позиция в слове w над алфавитом  $\Sigma$ , а u узел GSS. Дескриптором назовём тройку (X, u, i).

Есть несколько способов задания GSS для алгоритма GLL. Вариант, предложенный самими авторами алгоритма, оперирует непосредственно парами из позиции слова и слота грамматики в качестве состояний (и узлов графа) — такой метод является довольно простым и наглядным, но, как описано в работе [2], не самым эффективным. Предложим сразу чуть более оптимальное представление: заметим, что шаги разбора, соответствующие одному и тому же нетерминалу и позиции слова, должны выдавать один и тот же результат независимо от конкретной продукции грамматики, в которой стоит этот нетерминал. Поэтому заводить по узлу на каждый слот грамматики довольно избыточно — вместо этого в качестве состояния будет использовать пары из нетерминала и позиции слова, а позиции грамматики будем записывать на рёбрах.

Итак, мы научились задавать состояния с помощью дескрипторов, а также определились со вспомогательной структурой GSS. Теперь можно перейти к рассмотрению непосредственно самого алгоритма, суть которого довольно проста и напоминает BFS по неявному графу.

Дескриптор задает состояние, которое необходимо обработать. При этом мы без какой-либо дополнительной информации можем продолжить анализ входа из состояния, задаваемого этим дескриптором. В процессе обработки мы можем получить несколько новых состояний. Поэтому будем поддерживать множество R дескрипторов на обработку — на каждом шаге извлекаем один из множества, проводим анализ и кладем в множество новые полученные.

При каких условиях этот процесс будет конечен? Ну, например, если мы каждое состояние будем обрабатывать не более одного раза. И действительно, поскольку наш интерпретатор является "чистым" в том смысле, что для оного и того же состояния каждый раз будут получены одинаковые результаты, проводить анализ дважды не имеет смысла. Поэтому будем также поддержи-

вать множество U всех полученных в ходе разбора дескрипторов, и добавлять в R только те, которых еще нет в U.

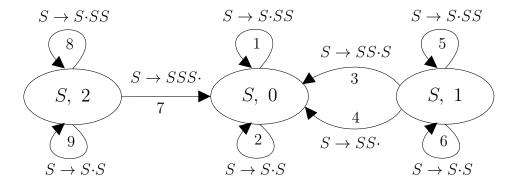
W наконец, заключительная и самая главная часть — как происходит обработка дескриптора? Пусть дескриптор имеет вид (X,u,i), а входное слово обозначим W. Есть три возможных варианта, в зависимости от вида позиции грамматики X — разберем каждый из них по отдельности;

- $X ::= \alpha \cdot t \beta$ , т.е. указатель смотрит на терминал в этом случае новых дескрипторов добавлено не будет. Если W[i] = t, то мы сдвигаем указатель слота, переходя к рассмотрению  $X ::= \alpha t \cdot \beta$ , и инкрементируем позицию i в слове. В противном же случае сразу переходим к следующему дескриптору, т.о. терминируя текущую ветвь разбора.
- $X ::= \alpha \cdot A\beta$ , т.е. указатель смотрит на нетерминал. Нам нужен GSS узел v вида (A,i) и ребро  $(u,X ::= \alpha A \cdot \beta,v)$  (ребро из u в v с пометкой  $X ::= \alpha A \cdot \beta$ ). Если такой узел и ребро уже существуют в нашем GSS, берем их, иначе создаём. Далее в R добавляем по дескриптору для узла v и каждого правила грамматики из ячейки управляющей таблицы для нетерминала A (конечно, если их еще не было в U). На этом обработка текущего дескриптора завершается.
- $X := \alpha \cdot$ , т.е. указатель находится в конце продукции. Продукция разобрана, а значит, интерпретатору необходимо вернуться из разбора X к вызывающему правилу и продолжить разбор там (это, в некотором смысле, соответствует возврату из функции разбора нетерминала в методе рекурсивного спуска). По каждому исходящему ребру (u, Y, v) добавляем (если уже не существует) дескриптор (Y, v, i).

Результатом синтаксического разбора является успех тогда и только тогда, когда был достигнут дескриптор вида  $(S := \alpha \cdot, s, n)$ , где слот грамматики представляет собой любое правило для аксиомы S, узел GSS s состоит из аксиомы S и 0, а позиция входного слова равна его длине n. Если же после разбора всех полученных дескрипторов указанный найден не был, результатом будет являться провал.

Давайте посмотрим, как такой алгоритм справится с неоднозачной грамматикой с леворекурсивным правилом.

**Пример 9.2.1.** Пусть грамматика G имеет вид  $S \to SSS \mid SS \mid a$ , а разбираемое слово w = aaa. Тогда GSS, соответствующий разбору  $S \Rightarrow SSS \Rightarrow aSS \Rightarrow aaS \Rightarrow aaa$ , будет выглядеть следующим образом (для удобства каждое ребро дополнительно пронумеровано):



Далее мы пошагово рассмотрим процесс его построения, а пока отметим несколько особенностей:

- Это неполный GSS. Для задачи синтаксического анализа такого достаточно, поскольку если в какой-то момент был достигнут финальный дескриптор, то обрабатывать все последующие уже не нужно. Однако, для задачи построения SPPF, как мы отметим далее, это уже не так, поскольку она требует агрегирования всех возможных путей разбора.
- Обратите особое внимание на наличие петель. Они как раз-таки и обеспечивают эффективную работу с леворекурсивными правилами, поскольку переиспользуются уже существующие узлы. При этом кратных петель, понятно, не создается, т.к. мы запоминаем все достигнутые дескрипторы в множестве U и дублирующих дескрипторов в рабочее множество R не добавляем.
- В GSS не создаются узлы, соответствующие разбору терминалов (например, a, 0). В действительности так можно было бы сделать. Но тогда при обработке слота, указывающего на терминал, сначала бы создался узел GSS, затем интерпретатор сверил бы терминал и символ в слове, после чего, если они совпали, произошел бы возврат из узла, а если нет, узел был бы отброшен и интерпретатор перешел бы к другому дескриптору. Таким образом, при любом случае сначала создается узел, затем выполняется проверка, после чего узел сразу отбрасывается. Для того, чтобы не создавать такие "одноразовые" узлы, проверка терминалов выполняется in-place.

Пронумеруем продукции и выпишем управляющую таблицу:

Разумеется, что конкретный порядок исполнения алгоритма будет зависеть, например, от используемой в качестве рабочего множества R структуры данных и от порядка обработки правил из ячейки управляющей таблицы. Рассмотрим лишь один из возможных вариантов:

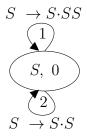
1. Для начала мы создаем узел GSS  $s_0 = (S,0)$  и дескрипторы для правил из ячейки таблицы  $S,a:(S \to \cdot SSS,s_0,0),(S \to \cdot SS,s_0,0),(S \to \cdot a,s_0,0).$ 



2. При обработке  $(S \to \cdot SSS, s_0, 0)$  образовываются петля 1 и дескрипторы  $(S \to \cdot SSS, s_0, 0), (S \to \cdot SS, s_0, 0), (S \to \cdot a, s_0, 0)$ , которые уже содержатся в множестве U после шага 1 и поэтому не добавляются повторно.



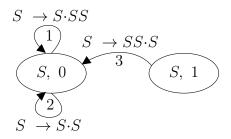
3. При обработке  $(S \to SS, s_0, 0)$  образовывается петля 2, а в остальном аналогично шагу 2.




- 4. При обработке  $(S \to \cdot a, s_0, 0)$  мы распознаем терминал a на позиции 0 и, возвращаясь по петлям 1 и 2, добавляем дескрипторы  $(S \to S \cdot SS, s_0, 1), (S \to S \cdot SS, s_0, 1)$ .
- 5. При обработке  $(S \to S \cdot SS, s_0, 1)$  образовываем узел  $s_1 = (S, 1)$  с исходящим ребром 3 и добавляем дескрипторы  $(S \to \cdot SSS, s_1, 1), (S \to \cdot SS, s_1, 1), (S \to \cdot SS, s_1, 1)$ .

#### 9.2. GLL и его применение для КС запросов


147




6. При обработке  $(S \to S \cdot S, s_0, 1)$  образовываем ребро 4, новых дескрипторов не добавляется.




7. Обработка дескриптора  $(S \to \cdot SSS, s_1, 1)$  аналогична шагу 2 с добавлением петли 5.




8. Обработка дескриптора  $(S \to \cdot SS, s_1, 1)$  аналогична шагу 3 с добавлением петли 6.



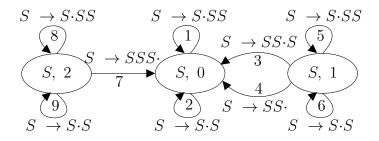
- 9. При обработке  $(S \to \cdot a, s_1, 1)$  мы распознаем терминал a на позиции 1 и, возвращаясь по ребрам 3 и 4, добавляем дескрипторы  $(S \to SS \cdot S, s_0, 2), (S \to SS \cdot S, s_0, 2),$  а также, возвращаясь по петлям 5 и 6, добавляем дескрипторы  $(S \to S \cdot SS, s_1, 2), (S \to S \cdot S, s_1, 2).$
- 10. При обработке  $(S \to SS \cdot S, s_0, 2)$  образовываем узел  $s_2 = (S, 2)$  с исходящим ребром 7 и добавляем дескрипторы  $(S \to SSS, s_2, 2), (S \to SS, s_2, 2), (S \to SS, s_2, 2)$ .



11. Обработка дескриптора  $(S \to SSS, s_2, 2)$  аналогична шагу 2 с добавлением петли 8.



12. Обработка дескриптора  $(S \to \cdot SS, s_2, 2)$  аналогична шагу 3 с добавлением петли 9.



- 13. При обработке  $(S \to \cdot a, s_2, 2)$  мы распознаем терминал a на позиции 2 и, возвращаясь по ребру 7, добавляем дескриптор  $(S \to SSS, s_0, 3)$ , а также, возвращаясь по петлям 8 и 9, добавляем дескрипторы  $(S \to S \cdot SS, s_2, 3), (S \to S \cdot S, s_2, 3)$ .
- 14. Мы достигли финального дескриптора  $(S \to SSS, s_0, 3)$ , синтаксический разбор успешен.

Внимательный читатель мог заметить, что если бы в этом примере шаг 4 был выполнен перед шагом 2, разбор довольно быстро бы завершился неудачей. Отсюда вытекает следующее наблюдение: если в какой-то момент из существующего узла появилось новое ребро, необходимо пересчитать все входящие в него пути.

Для построения SPPF требуется внести лишь несколько небольших добавлений:

- 1. В дескриптор необходимо добавить узел SPPF w, который будет представлять уже разобранный префикс.
- 2. Необходимо поддерживать множество P из элементов вида (u, z), где u это узел GSS, а z соответствующий ему узел SPPF, для того, чтобы переиспользовать результаты разбора, ассоциированные с узлами GSS.
- 3. При обработке терминала t на позиции i ищется узел вида (t, i, i+1), либо создается, если такого еще нет.
- 4. При обработке нетерминала с помощью P ищется или при необходимости создается промежуточный узел вида (X,l,r), где X соответствующий слот грамматики, а l и r узлы SPPF, отвечающие за разбор левой и правой частей слота соответственно.

Конкретные шаги построения SPPF будут зависеть от выбранного для него формата. Описание эффективного бинаризованного SPPF и детали его построения при выполнении GLL представлены в работе [2].

GLL довольно естественно обобщается на граф [29]: позициями входа теперь будем считать не индексы линейного слова, а вершины графа. В самом же алгоритме требуется внести лишь два небольших дополнения:

1. Теперь при обработке терминала "следующих" символов может быть несколько — рассматриваем каждый из них отдельно, сдвигаясь по соответствующему ребру.

2. При обработке нетерминала аналогично правила управляющей таблицы применяются для каждого из "следующих" символов в графе. Соответственно новых дескрипторов будет сгенерировано больше, но все они по-прежнему независимы и просто добавляются в рабочее множество R.

Подробное описание алгоритма и псевдокод представлены в работе [29].

Напоследок сделаем небольшое замечание об эффективной реализации: в качестве рабочего множества R можно использовать несколько различных структур данных и, как правило, выбирают очередь. Однако иногда (в особенности для графов) лучше использовать стек дескрипторов, так как в этом случае выше локальность данных — мы кладём пачку дескрипторов, соответствующих исходящим рёбрам. И если граф представлен списком смежности, то исходящие будут храниться рядом и их лучше обработать сразу.

#### 9.3 Вопросы и задачи

- 1. Проведите алгоритм GLL для грамматики  $S \to aSbS \mid \varepsilon$ . Правда ли, что эта грамматика принадлежит классу LL(1)? Пронаблюдайте, как использование GSS вырождается в работу с обычным стеком.
- 2. Доразберите все не рассмотренные в примере 9.2.1 дескрипторы, постройте полный GSS.

## Глава 10

# Комбинаторы для КС апросов

#### 10.1 Парсер комбинаторы

Что это, с чем едят, плюсы, минусы. Про семантику, безопасность, левую рекурсию и т.д. Набор примитивных парсеров и функций, которые умеют из существующих арсеров строить более сложные (собственно, комбинаторы парсеров).

Разобрать символ, разобрать последовательность, разобрать альтернативу. впринципе, этого достаточно, но это не очень удобно.

Проблемы с левой рекурсией. Существуют решения. Одно из них — Meerkat. Подробно про него?

#### 10.2 Комбинаторы для КС запросов

Вообще говоря, идея использовать комбинаторы для навигации по графам достаточно очевидно и не нова. немного про Trails [40].

Комбинаторы для запросов к графам на основе Meerkat [78]

Обобщённые запросы, типобезопасность и всё такое. Примеры запросов.

#### 10.3 Вопросы и задачи

- 1. Реализовать библиотеку парсер комбинаторов.
- 2. Что-нибудь полезное с ними сделать.

### Глава 11

# Производные для КС запросов

В данной главе мы рассмотрим производные Бжозовского и их возможное применение.

#### 11.1 Производные

Впервые производные формальных языков были определены в 1964 году учёным Янушем Бжозовским (в честь него они и были названы). Он определил это понятие для регулярных языков, предложил алгоритм для вычисления производной обобщенного регулярного выражения, также Бжозовский занимался исследованием свойств производных [18].

Изначально всё начиналось с производных регулярных языков, и в главе мы в основном будем говорить именно о них.

Рассмотрим формальное определение производной произвольного языка:

**Определение 11.1.1.** Производной языка  $\mathcal{L}$  по символу a называется язык  $\mathcal{L}' = \partial_a(\mathcal{L}) = \{w \mid aw \in \mathcal{L}\}$ , где:

- $\mathcal{L} \subseteq \{w \mid w \in \Sigma^*\}$  произвольный язык над алфавитом  $\Sigma$
- $a \in \Sigma$  символ, по которому берётся производная

То есть фактически производная языка — это суффиксы слов, начинающихся на символ, по которому язык дифференцируется.

**Пример 11.1.1** (Производные языка). Рассмотрим язык  $\mathcal{L} = \{pen, plain, day, pray\}$  и несколько языков, порождённых от него с помощью дифференцирования:

1. 
$$\mathcal{L}' = \partial_p(\mathcal{L}) = \{en, lain, ray\}$$

2. 
$$\mathcal{L}'' = \partial_e(\mathcal{L}') = \{n\}$$

3. 
$$\mathcal{L}''' = \partial_n(\mathcal{L}'') = \{\varepsilon\}$$

#### 11.2 Принадлежность языку

С помощью производных ествественным образом можно проверять принадлежность слова регулярному языку. Есть регулярное выражение R и язык, порожденный этим регулярным выражением L(R). Возьмём произвольное слово w и зададимся вопросом:  $w \in L(R)$ ?

Пусть  $w = a_0 a_1 ... a_{n-1}$ , а новый язык  $\mathcal{L}'$  получен последовательным дифференцирование исходного языка L(R) по каждому из символов слова w, то есть  $\mathcal{L}' = \partial_{a_{n-1}} (... \partial_{a_1} (\partial_{a_0} (L(R)))...)$ . В таком случае принадлежность w языку L(R) определяется наличием пустого слова в итоговом языке:  $\varepsilon \in \mathcal{L}' \Rightarrow w \in L(R)$ .

**Пример 11.2.1.** Дан язык  $\mathcal{L} = \{pen, plain, day, pray\}$ . Принадлежат ли данному языку слова pen, pet?

- $\partial_p(\mathcal{L}) = \{en, lain, ray\} \Rightarrow \partial_e(\partial_p(\mathcal{L})) = \{n\} \Rightarrow \partial_n(\partial_e(\partial_p(\mathcal{L}))) = \{\varepsilon\}$ . А значит,  $pen \in \mathcal{L}$
- $\partial_p(\mathcal{L}) = \{en, lain, ray\} \Rightarrow \partial_e(\partial_p(\mathcal{L})) = \{n\} \Rightarrow \partial_t(\partial_e(\partial_p(\mathcal{L}))) = \emptyset$ . Значит,  $pet \notin \mathcal{L}$

Описанный выше механизм является основной идеей всех алгоритмом, которые стоятся на производных.

#### 11.3 Построение производных

Концептуально понятно, как выглядят производные, но хотелось бы уметь считать их алгоритмически, причём сохраняя конструктивное представление языка. Например, для КС грамматики, вычисляя её производную, строится другая КС грамматика.

Рассмотрим алгоритм вычисления производной для регулярных языков, которые представлены как регулярные выражения. Пусть  $r_1$  и  $r_2$  — два регулярных выражения, a — произвольный терминальный символ. Определим

вспомогательную функцию N — Nullable, которая проверяет язык на содержание в нём пустого слова  $\varepsilon$ :

$$N(\varepsilon) = true$$

$$N(a) = false$$

$$N(r_1 \cdot r_2) = N(r_1) \wedge N(r_2)$$

$$N(r_1 \mid r_2) = N(r_1) \vee N(r_2)$$

$$N(r^*) = true$$

Теперь мы готовы перейти непосредственно к вычислению производной по символу *a*:

$$\begin{split} \partial_a(\emptyset) &= \emptyset \\ \partial_a(\varepsilon) &= \emptyset \\ \partial_a(b) &= \begin{cases} \emptyset, & \text{if } a \neq b \\ \varepsilon, & \text{otherwise} \end{cases} \\ \partial_a(r_1 \cdot r_2) &= \begin{cases} \partial_a(r_1) \cdot r_2 \mid \partial_a(r_2) & \text{if } N(r_1) = \text{true} \\ \partial_a(r_1) \cdot r_2, & \text{otherwise} \end{cases} \\ \partial_a(r_1 \mid r_2) &= \partial_a(r_1) \mid \partial_a(r_2) \\ \partial_a(r^*) &= \partial_a(r) \cdot r^* \end{split}$$

Все правила, за исключением, может быть, последнего, достаточно тривиальны. Последнее доказывается по индукции, но особо любопытные могут руками вычислить для первой пары слагаемых и рассмотреть закономерность.

Приводить подобный алгоритм для KC языков мы не будем, но важно понимать, что он есть, и идея не сильно отличается от алгоритма для регулярных языков.

#### 11.4 Задача достижимости

Используя производные, можно решать задачу достижимости. Даны регулярный запрос и граф, для простоты зафиксируем стартовую вершину. Для решения задачи достижимости при помощи производных рекурсивно выполняем следующее:

- 1. При переходе по ребру дифференцируем запрос по метке на нём
- 2. Передаём эту производную вдоль ребра в следующую вершину
- 3. В этой следующей вершине производная запоминается, если ранее не встречалось регулярное выражение, которое порождается тот же язык (таким образом формируется набор регулярных выражений, порождающих языки, которые уже передовались на вершину). В противном случае терминируемся.


После того, как вышеописанный алгоритм завершился для всех вершин, проходим по ним и ищем в их наборах Nullable регулярные выражения, которые и сигнализируют о том, что путь из стартовой веришны в данную вершину существует.

Некоторые замечания:

- Если алгоритм запускается не на одной вершине, а сразу на нескольких, передаются вдоль рёбер не просто производные, а пары: (стартовая вершина, производная).
- Что мы в общем случае делаем с циклами, чтобы задача считалась алгоритмически? Разбиваем граф на наибольшие по включению компоненты сильной связности с связями между ними, стягиваем компоненты. Тогда граф превращается в дек, в котором проблем с нетерминируемостью нет, а с компонентами сильной связности разбираемся отдельно. Для этого достаточно рассмотреть одну такую компоненту: если есть цикл, то по нему можно ходить, только если в запросе есть применение звезды Клини, и, как нам уже известно, производная запроса данной операции конечная конструкция. В итоге мы сможем, переходя по вершинами, прийти к моменту, когда внутри компоненты в наборах производных вершин новых элементов не будет прибавляться, а значит, мы можем закончить алгоритм.

Рассмотрим решение задачи достижимости с помощью производных на конкретном примере:

**Пример 11.4.1.** Даны регулярный запрос  $R = a^* \mid a^* \cdot b$  и граф  $\mathcal{G}$ :



Стартовая веришина — вершина графа  $\mathcal{G}$  с индексом 0. Хотим проверить существование путей из вершины 0 до других вершин графа по R. Заведем 4 множества, в которых будем хранить регулярные выражения, передаваемые в конкретную вершину:  $M_0$  — для вершины с индексом 0,  $M_1$  — для вершины с индексом 1 и так далее.

- 1. Начинаем идти вдоль ребра с меткой a из вершины 0 в 1. Дифференцируем наш запрос по данной метке:  $\partial_a(R) = \partial_a(a^* \mid a^* \cdot b) = \partial_a(a^*) \mid \partial_a(a^* \cdot b) = \partial_a(a) \cdot a^* \mid \partial_a(a^*) \cdot b \mid \partial_a(b) = a^* \mid a^* \cdot b = R$ . Запоминаем эту производную в  $M_1$ :  $M_1 = \{R\}$
- 2. Аналогично идём из вершины 1 в вершину 2 по a. В итоге в  $M_2$  также будет находиться R.
- 3. В вершине 2 параллельно идём по метке a в 0 и по метке b в вершину с индексом 3.
  - (а) В первом потоке при переходе по a мы дифференцируем R по а, получаем также R, кладем его в  $M_0$ . Пытаясь продолжить эти вычисления в данном потоке, мы обнаружим, что при переходе по a из вершины 0 в вершину 1 наша производная будет снова R, но в множестве  $M_1$  R уже находится, а значит, данная ветка вычислений терминируется.
  - (b) При переходе по b диффиринцируем переданную производную R:  $\partial_b(R) = \partial_b(a^* \mid a^* \cdot b) = \partial_b(a^*) \mid \partial_b(a^* \cdot b) = \partial_b(a) \cdot a^* \mid \partial_b(a^*) \cdot b \mid \partial_b(b) = \partial_b(b) = \varepsilon$ . Запоминаем производную в  $M_3$ :  $M_3 = \{\varepsilon\}$ . Дифференцируем её по b при переходе из 3 в 2. Кладём в  $M_2$   $\partial_b(\varepsilon) = \emptyset$ . Таким образом,  $M_2 = \{R, \emptyset\}$ . На данном этапе можно терминирироваться, т.к. для достижимости нам интересны регулярные выражения, порождающий  $\varepsilon$ , но дифференцируя  $\emptyset$  по каким-либо меткам, мы

снова получаем  $\emptyset$ . При "честном"вычислении, в нашем случае пустое множество будет добавлено во все множества  $M_i$ , и уже после этого вычисление завершится.

4. Теперь у нас есть сформированные множества производных для всех вершин и мы можем говорить о достижимости до данных вершин из стартовой. Рассмотрим  $M_0$ ,  $M_0 = \{R\}$ . Содержит ли  $R \varepsilon$ ? Посчитаем для этого нашу функцию Nullable:  $N(R) = N(a^* \mid a^* \cdot b) = N(a^*) \mid N(a^* \cdot b) = true \mid N(a^* \cdot b) = true$ . Из чего следует, что существует путь из вершины 0 в вершину 0. Аналогичным способом заключаем, что веришны 2 и 3 достижимы из вершины 0 (т.к. в их множества также содержится R). Рассмотрим  $M_3 = \{\varepsilon\}$ .  $N(\varepsilon) = true$ , значит, вершина 3 тоже достижима из 0. Алгоритм завершён.

Таким образом, выполнив указанный выше алгоритм для данного примера, мы определили, что из стартовой вершины с индексом 0 достижимы все вершины графа  $\mathcal{G}$ .

#### 11.5 Парсинг на производных

Статьи [46, 1, 47, 3] Реализации. Ha Scala <sup>1</sup>, на Racket <sup>2</sup>.

#### 11.6 Адоптация для КС запросов

Для регулярных запросов над графами [49]. Хорошо работают в распределённых системах, в которых реализовван параллелизм уровня вершин. Например Google Pregel.

#### 11.7 Вопросы и задачи

- 1. Предъявить несколько выводов для одной цепочки.
- 2. Построить выводы
- 3. Построить деревья вывода !!! Перенести из раздела про SPPF

https://github.com/djspiewak/parseback

<sup>&</sup>lt;sup>2</sup>https://bitbucket.org/ucombinator/derp-3/src/86bca8a720231e010a3ad6aefd1aa1c0f35cbf6b/src/derp.rkt?at=master&fileviewer=file-view-default

## Глава 12

# От CFPQ к вычислению Datalog-запросов

Рассмотрим грамматику  $S \to aSb \mid SS \mid \varepsilon$ , заданную через набор предикатов:

- a(i,w) Предикат, соответствующий терминалу. Обращается в True, если на i-том месте в строке w стоит символ a
- S(i, j, w) Предикат, соответствующий нетерминалу. Обращается в True, если выполняется одно из условий:
  - 1. i == j  $(\varepsilon)$
  - 2.  $\exists k : i \leq k \leq j \& S(i, k-1, w) \& S(k, j, w)$  (SS)
  - 3. a(i, w) & S(i + 1, j 1, w) & b(j 1, w) (aSb)

Таким образом S(0, |w|, w) покажет, выводится ли строка w из данной грамматики, а  $S(\_, \_, w)$  даст нам список всех цепочек внутри w, выводящихся из S.

#### 12.0.1 Datalog

Datalog [28]<sup>1</sup> — декларативный логический язык программирования. Используется для написания запросов к дедуктивным базам данных<sup>2</sup>.

Пример 12.0.1. Пример программы на даталоге.

<sup>1</sup>https://www.computer.org/csdl/journal/tk/1989/01/k0146/13rRUx0xPIQ

<sup>&</sup>lt;sup>2</sup>https://en.wikipedia.org/wiki/Deductive\_database

- 1. Набор фактов (часто факты находятся в базе данных):
  - a(0).
  - b(1).
  - a(2).
  - b(3).
  - $\bullet$  s(I,I).
- 2. Набор правил:
  - $s(I, J) := s(I, K 1), s(K, J), (I \le K \le J)$
  - s(I, J) := a(I), s(I + 1, J 1), b(J)
- 3. Запросы:
  - ? s(I, J)


Таким образом мы описали на даталоге строку через набор фактов, грамматику, указанную выше, через набор фактов и правил и сделали запрос на все цепочки, выводящиеся из S.

**NB!** Обратите внимание [28], что строки, начинающиеся с большой буквы, в даталоге считаются переменными. Также важно, что все переменные неявно квантифицированны.

#### 12.0.2 Datalog для работы с графами

На даталоге также можно задавать графы и писать к ним запросы.

Пример 12.0.2. Пример описания графа на даталоге.



- a(0,1).
- a(1,2).
- a(2,0).
- b(2,3).
- b(3,2).

Теперь зададим рассмотренную выше грамматику для работы с графом.

$$s(I,I)$$
.

$$s(I, J) := s(I, K - 1), s(K, J).$$

$$s(I, J) := a(I, L), S(L, M), b(M, J).$$

Тогда запрос ?-s(I,J) выдаст нам все такие пути в графе, что последовательность составляющих их вершин в порядке прохождения выводится их грамматики.

#### 12.0.3 Алгоритм Эрли

Для распознавания контекстно-свободных грамматик может использоваться алгоритм Эрли [70] <sup>3</sup>. Рассмотрим грамматику G = (N, T, P, S), слово  $a_1...a_n$ , и правило  $A \to \alpha\beta$ . Будем считать, что утверждение  $[A \to \alpha \bullet \beta](i,j), j \in [1..n]$  является истиной, если верно, что:

- $\alpha \xrightarrow{*} a_{i+1}...a_j$  (Последовательность выводится из  $\alpha$ )
- $S \xrightarrow{*} a_1...a_i A_{\gamma}$

Рассмотрим правила вывода для подобных утверждений:

- 1.  $\frac{S \to \alpha \in P}{[S \to \bullet \alpha](0,0)}$  Инициализация (Init)
- 2.  $\frac{[A\to\alpha\bullet a_{j+1}\beta](i,j)}{[A\to\alpha a_{j+1}\bullet\beta](i,j+1)}$  Сканирование (Scan)
- 3.  $\frac{[A \to \alpha \cdot B\beta](i,j)}{[B \to \bullet \gamma](j,j)}$  Предсказание (Predict)

https://en.wikipedia.org/wiki/Earley

4. 
$$\frac{[A \to \alpha \cdot B](i,j)}{[A \to \alpha B \bullet \beta](i,k)}$$
 Завершение (Complete)

Идея алгоритма Эрли заключается в том, чтобы, начиная с инициализации, используя правила, вывести утверждение, содержащие данную строку слева от точки, и ничего справа, или попробовать все возможные выводы и признать, что строка не выводима.

Сложность алгоритма Эрли составляет  $O(|P|^2n^3)$ 

**Пример 12.0.3.** Пример начала одной из веток дерева вывода для алгоритма Эрли для рассматриваемой грамматики

Сложность можно понизить, изменив правила "Предсказание" и "Завершение" таким образом:

$$\bullet \ \frac{[A \to \alpha \cdot B\beta](i,j) \quad B \to \gamma \in P}{[B \to \bullet\gamma](j,j)} \Rightarrow \frac{[A \to \alpha \cdot B\beta](i,j)}{?B(j)}; \quad \frac{?B(j) \quad B \to \gamma \in P}{[B \to \cdot\gamma](j,j)}$$

$$\bullet \ \frac{[A \to \alpha \cdot B](i,j) \quad [B \to \gamma \bullet](j,k)}{[A \to \alpha B \bullet \beta](i,k)} \Rightarrow \frac{[B \to \gamma \bullet](j,k)}{B(j,k)}; \quad \frac{[A \to \alpha \cdot B \beta](i,j) \quad B(j,k)}{[A \to \alpha B \cdot \beta](i,k)}$$

Так, разложив каждое правило на два, мы избавляемся от необходимости перевычислять дерево разбора каждого нетерминала после того, как однократно вычислим, что он выводим (мемоизируем его). Получаем сложность O(|P|).

Описанный подход мемоизации [8] части используется для оптимизации программ на даталоге. Можно либо видоизменять правила, задающие грамматику в тексте программы, либо модифицировать компилятор, чтобы он пытался сделать это автоматически.

# 12.1 Вопросы и задачи

- 1. Написать синтаксический анализатор раз.
- 2. Написать синтаксический анализатор два.
- 3. Побаловаться с неоднозначными грамматиками
- 4. Побаловаться с конъюнктивными грамматиками.
- Графы?

# Литература

- [1] M. D. Adams, C. Hollenbeck, and M. Might. On the complexity and performance of parsing with derivatives. In *Proceedings of the 37th ACM SIGPLAN Conference on Programming Language Design and Implementation*, PLDI '16, pages 224–236, New York, NY, USA, 2016. ACM.
- [2] A. Afroozeh and A. Izmaylova. Faster, practical gll parsing. In B. Franke, editor, *Compiler Construction*, pages 89–108, Berlin, Heidelberg, 2015. Springer Berlin Heidelberg.
- [3] L. Andersen. Parsing with derivatives.
- [4] J. W. Anderson, P. Tataru, J. Staines, J. Hein, and R. Lyngsø. Evolving stochastic context–free grammars for RNA secondary structure prediction. *BMC Bioinformatics*, 13(1):78, 2012.
- [5] R. Axelsson and M. Lange. Formal language constrained reachability and model checking propositional dynamic logics. In *International Workshop on Reachability Problems*, pages 45–57. Springer, 2011.
- [6] R. Azimov and S. Grigorev. Context-free path querying by matrix multiplication. In Proceedings of the 1st ACM SIGMOD Joint International Workshop on Graph Data Management Experiences & Systems (GRADES) and Network Data Analytics (NDA), GRADES-NDA '18, pages 5:1–5:10, New York, NY, USA, 2018. ACM.
- [7] R. Azimov and S. Grigorev. Path querying using conjunctive grammars. Proceedings of the Institute for System Programming of the RAS, 30:149–166, 01 2018.
- [8] F. Bancilhon, D. Maier, Y. Sagiv, and J. D. Ullman. Magic sets and other strange ways to implement logic programs (extended abstract). In *Proceedings of the Fifth ACM SIGACT-SIGMOD Symposium on Principles of Database Systems*, PODS '86, pages 1–15, New York, NY, USA, 1986. ACM.

[9] C. Barrett, K. Bisset, M. Holzer, G. Konjevod, M. Marathe, and D. Wagner. Label constrained shortest path algorithms: An experimental evaluation using transportation networks. *March*, 9:2007, 2007.

- [10] C. Barrett, R. Jacob, and M. Marathe. Formal-language-constrained path problems. SIAM Journal on Computing, 30(3):809-837, 2000.
- [11] O. Bastani, S. Anand, and A. Aiken. Specification inference using context-free language reachability. In ACM SIGPLAN Notices, volume 50, pages 553–566. ACM, 2015.
- [12] S. Billot and B. Lang. The structure of shared forests in ambiguous parsing. In *Proceedings of the 27th Annual Meeting on Association for Computational Linguistics*, ACL '89, pages 143–151, Stroudsburg, PA, USA, 1989. Association for Computational Linguistics.
- [13] D. A. Bini, M. Capovani, F. Romani, and G. Lotti.  $o(n^{2.7799})$  complexity for approximate matrix multiplication. *Information Processing Letters*, 8(5):234–235, 1979.
- [14] P. G. Bradford. Quickest path distances on context-free labeled graphs. In Appear in 6-th WSEAS Conference on Computational Intelligence, Man-Machine Systems and Cybernetics. Citeseer, 2007.
- [15] P. G. Bradford. Language constrained graph problems: A microcosm of engineering research and development. In *Proceedings of the 2Nd WSEAS International Conference on Computer Engineering and Applications*, CEA'08, pages 71–76, Stevens Point, Wisconsin, USA, 2008. World Scientific and Engineering Academy and Society (WSEAS).
- [16] P. G. Bradford. Efficient exact paths for dyck and semi-dyck labeled path reachability (extended abstract). In 2017 IEEE 8th Annual Ubiquitous Computing, Electronics and Mobile Communication Conference (UEMCON), pages 247–253, Oct 2017.
- [17] P. G. Bradford and V. Choppella. Fast point-to-point dyck constrained shortest paths on a dag. In 2016 IEEE 7th Annual Ubiquitous Computing, Electronics & Mobile Communication Conference (UEMCON), pages 1–7. IEEE, 2016.
- [18] J. A. Brzozowski. Derivatives of regular expressions. Journal of the ACM, 11 (4):481—-494, 1964.

[19] T. M. Chan. All-pairs shortest paths with real weights in  $o(n^3/\log n)$  time. Algorithmica, 50(2):236-243, Feb 2008.

- [20] T. M. Chan. More algorithms for all-pairs shortest paths in weighted graphs. SIAM Journal on Computing, 39(5):2075–2089, 2010.
- [21] D. Coppersmith and S. Winograd. On the asymptotic complexity of matrix multiplication. SIAM Journal on Computing, 11(3):472–492, 1982.
- [22] D. Coppersmith and S. Winograd. Matrix multiplication via arithmetic progressions. *Journal of symbolic computation*, 9(3):251–280, 1990.
- [23] W. Dobosiewicz. A more efficient algorithm for the min-plus multiplication. International journal of computer mathematics, 32(1-2):49-60, 1990.
- [24] W. Dyrka, M. Pyzik, F. Coste, and H. Talibart. Estimating probabilistic context-free grammars for proteins using contact map constraints. *PeerJ*, 7:e6559, Mar. 2019.
- [25] N. El abbadi. An efficient storage format for large sparse matrices based on quadtree. *International Journal of Computer Applications*, 105:25–30, 11 2014.
- [26] R. W. Floyd. Algorithm 97: shortest path. Communications of the ACM, 5(6):345, 1962.
- [27] M. L. Fredman. New bounds on the complexity of the shortest path problem. SIAM Journal on Computing, 5(1):83–89, 1976.
- [28] G. Gottlob, S. Ceri, and L. Tanca. What you always wanted to know about datalog (and never dared to ask). *IEEE Transactions on Knowledge & Data Engineering*, 1(01):146–166, jan 1989.
- [29] S. Grigorev and A. Ragozina. Context-free path querying with structural representation of result. In *Proceedings of the 13th Central & Eastern European Software Engineering Conference in Russia*, CEE-SECR '17, pages 10:1–10:7, New York, NY, USA, 2017. ACM.
- [30] Y. Han. Improved algorithm for all pairs shortest paths. *Information Processing Letters*, 91(5):245–250, 2004.
- [31] J. Hellings. Conjunctive context-free path queries. In *Proceedings of ICDT'14*, pages 119–130, 2014.

[32] J. Hellings. Path results for context-free grammar queries on graphs. ArXiv, abs/1502.02242, 2015.

- [33] J. Hellings. Querying for paths in graphs using context-free path queries, 2015.
- [34] K. Hemerik. Towards a taxonomy for ecfg and rrpg parsing. Proceedings of the 3rd International Conference on Language and Automata Theory and Applications, pages 410–421, 2009.
- [35] M. Holzer, M. Kutrib, and U. Leiter. Nodes connected by path languages. In G. Mauri and A. Leporati, editors, *Developments in Language Theory*, pages 276–287, Berlin, Heidelberg, 2011. Springer Berlin Heidelberg.
- [36] J. E. Hopcroft and J. D. Ullman. *Introduction to Automata Theory, Languages, and Computation*. Addison-Wesley Publishing Company, 1979.
- [37] A. K. Joshi and Y. Schabes. *Tree-Adjoining Grammars*, pages 69–123. Springer Berlin Heidelberg, Berlin, Heidelberg, 1997.
- [38] J. Kasai, B. Frank, T. McCoy, O. Rambow, and A. Nasr. TAG parsing with neural networks and vector representations of supertags. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 1712–1722, Copenhagen, Denmark, Sept. 2017. Association for Computational Linguistics.
- [39] J. Kasai, R. Frank, P. Xu, W. Merrill, and O. Rambow. End-to-end graph-based TAG parsing with neural networks. In Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers), pages 1181–1194, New Orleans, Louisiana, June 2018. Association for Computational Linguistics.
- [40] D. Kröni and R. Schweizer. Parsing graphs: Applying parser combinators to graph traversals. In *Proceedings of the 4th Workshop on Scala*, SCALA '13, pages 7:1–7:4, New York, NY, USA, 2013. ACM.
- [41] J. Kuijpers, G. Fletcher, N. Yakovets, and T. Lindaaker. An experimental study of context-free path query evaluation methods. In *Proceedings of the 31st International Conference on Scientific and Statistical Database Management*, SSDBM '19, pages 121–132, New York, NY, USA, 2019. ACM.
- [42] O. Kupferman and G. Vardi. Eulerian paths with regular constraints. In 41st International Symposium on Mathematical Foundations of Computer Science (MFCS 2016). Schloss Dagstuhl-Leibniz-Zentrum fuer Informatik, 2016.

[43] M. J. Kusner, B. Paige, and J. M. Hernández-Lobato. Grammar variational autoencoder. In *Proceedings of the 34th International Conference on Machine Learning - Volume 70*, ICML'17, page 1945–1954. JMLR.org, 2017.

- [44] L. Lee. Fast context-free grammar parsing requires fast boolean matrix multiplication. J. ACM, 49(1):1–15, Jan. 2002.
- [45] C. M. Medeiros, M. A. Musicante, and U. S. Costa. Ll-based query answering over rdf databases. *Journal of Computer Languages*, 51:75 87, 2019.
- [46] M. Might and D. Darais. Yacc is dead. CoRR, abs/1010.5023, 2010.
- [47] M. Might, D. Darais, and D. Spiewak. Parsing with derivatives: A functional pearl. SIGPLAN Not., 46(9):189–195, Sept. 2011.
- [48] N. Mishin, I. Sokolov, E. Spirin, V. Kutuev, E. Nemchinov, S. Gorbatyuk, and S. Grigorev. Evaluation of the context-free path querying algorithm based on matrix multiplication. In *Proceedings of the 2Nd Joint International Workshop on Graph Data Management Experiences & Systems (GRADES) and Network Data Analytics (NDA)*, GRADES-NDA'19, pages 12:1–12:5, New York, NY, USA, 2019. ACM.
- [49] M. Nolé and C. Sartiani. Regular path queries on massive graphs. In Proceedings of the 28th International Conference on Scientific and Statistical Database Management, SSDBM '16, pages 13:1–13:12, New York, NY, USA, 2016. ACM.
- [50] A. Okhotin. Conjunctive grammars. Journal of Automata, Languages and Combinatorics, 6(4):519–535, 2001.
- [51] A. Okhotin. Boolean grammars. In Proceedings of the 7th International Conference on Developments in Language Theory, DLT'03, pages 398–410, Berlin, Heidelberg, 2003. Springer-Verlag.
- [52] A. Okhotin. On the closure properties of linear conjunctive languages. *Theor. Comput. Sci.*, 299(1-3):663–685, 2003.
- [53] A. Okhotin. Conjunctive and boolean grammars: The true general case of the context-free grammars. Computer Science Review, 9:27–59, 8 2013.
- [54] A. Okhotin. Parsing by matrix multiplication generalized to boolean grammars. *Theor. Comput. Sci.*, 516:101–120, Jan. 2014.
- [55] A. S. Okhotin. Conjunctive grammars and systems of language equations. *Programming and Computer Software*, 28(5):243–249, Sep 2002.

[56] V. Y. Pan. Strassen's algorithm is not optimal trilinear technique of aggregating, uniting and canceling for constructing fast algorithms for matrix operations. In 19th Annual Symposium on Foundations of Computer Science (sfcs 1978), pages 166–176. IEEE, 1978.

- [57] P. Pratikakis, J. S. Foster, and M. Hicks. Existential label flow inference via cfl reachability. In SAS, volume 6, pages 88–106. Springer, 2006.
- [58] J. Rehof and M. Fähndrich. Type-base flow analysis: From polymorphic subtyping to cfl-reachability. SIGPLAN Not., 36(3):54-66, Jan. 2001.
- [59] J. G. Rekers. Parser generation for interactive environments. PhD thesis, Universiteit van Amsterdam, 1992.
- [60] T. Reps. Program analysis via graph reachability. In Proceedings of the 1997 International Symposium on Logic Programming, ILPS '97, pages 5–19, Cambridge, MA, USA, 1997. MIT Press.
- [61] T. Reps, S. Horwitz, M. Sagiv, and G. Rosay. Speeding up slicing. In Proceedings of the 2nd ACM SIGSOFT Symposium on Foundations of Software Engineering, SIGSOFT '94, pages 11–20, New York, NY, USA, 1994. Association for Computing Machinery.
- [62] B. Roy. Transitivité et connexité. Comptes Rendus Hebdomadaires Des Seances De L Academie Des Sciences, 249(2):216-218, 1959.
- [63] A. Schönhage. Partial and total matrix multiplication. SIAM Journal on Computing, 10(3):434-455, 1981.
- [64] E. Scott and A. Johnstone. Right nulled glr parsers. ACM Trans. Program. Lang. Syst., 28(4):577–618, July 2006.
- [65] E. Scott and A. Johnstone. Gll parsing. *Electron. Notes Theor. Comput. Sci.*, 253(7):177–189, Sept. 2010.
- [66] E. Scott, A. Johnstone, and R. Economopoulos. Brnglr: A cubic tomita-style glr parsing algorithm. *Acta Inf.*, 44(6):427–461, Sept. 2007.
- [67] H. Seki, T. Matsumura, M. Fujii, and T. Kasami. On multiple context-free grammars. *Theoretical Computer Science*, 88(2):191 229, 1991.
- [68] P. Sevon and L. Eronen. Subgraph queries by context-free grammars. *Journal of Integrative Bioinformatics*, 5, 06 2008.

[69] V. Strassen. Gaussian elimination is not optimal. *Numerische mathematik*, 13(4):354–356, 1969.

- [70] Sylvain Salvati. Multiple context-free grammars.
- [71] T. Takaoka. A new upper bound on the complexity of the all pairs shortest path problem. *Information Processing Letters*, 43(4):195–199, 1992.
- [72] T. Takaoka. A faster algorithm for the all-pairs shortest path problem and its application. In *Computing and Combinatorics*, volume 3106, pages 278–289, 2004.
- [73] T. Takaoka. An  $o(n^3 \log \log n / \log n)$  time algorithm for the all-pairs shortest path problem. Information Processing Letters, 96:155–161, 2005.
- [74] M. Tomita. An efficient augmented-context-free parsing algorithm. Computational Linguistics, 13:31–46, 1987.
- [75] M. Tomita. Graph-structured stack and natural language parsing. In 26th Annual Meeting of the Association for Computational Linguistics, pages 249– 257, Buffalo, New York, USA, June 1988. Association for Computational Linguistics.
- [76] L. G. Valiant. General context-free recognition in less than cubic time. *J. Comput. Syst. Sci.*, 10(2):308–315, Apr. 1975.
- [77] E. Verbitskaia, S. Grigorev, and D. Avdyukhin. Relaxed parsing of regular approximations of string-embedded languages. In M. Mazzara and A. Voronkov, editors, *Perspectives of System Informatics*, pages 291–302, Cham, 2016. Springer International Publishing.
- [78] E. Verbitskaia, I. Kirillov, I. Nozkin, and S. Grigorev. Parser combinators for context-free path querying. In *Proceedings of the 9th ACM SIGPLAN International Symposium on Scala*, Scala 2018, pages 13–23, New York, NY, USA, 2018. ACM.
- [79] C. B. Ward and N. M. Wiegand. Complexity results on labeled shortest path problems from wireless routing metrics. *Comput. Netw.*, 54(2):208–217, Feb. 2010.
- [80] C. B. Ward, N. M. Wiegand, and P. G. Bradford. A distributed contextfree language constrained shortest path algorithm. In 2008 37th International Conference on Parallel Processing, pages 373–380. IEEE, 2008.
- [81] S. Warshall. A theorem on boolean matrices. 1962.

[82] N. Wirth. What can we do about the unnecessary diversity of notation for syntactic definitions? Communications of the ACM, 20(11):822-823, 1977.

- [83] D. Yan, G. Xu, and A. Rountev. Demand-driven context-sensitive alias analysis for java. In *Proceedings of the 2011 International Symposium on Software Testing and Analysis*, ISSTA '11, pages 155–165, New York, NY, USA, 2011. Association for Computing Machinery.
- [84] M. Yannakakis. Graph-theoretic methods in database theory. In Proceedings of the ninth ACM SIGACT-SIGMOD-SIGART symposium on Principles of database systems, pages 230–242. ACM, 1990.
- [85] Q. Zhang, X. Xiao, C. Zhang, H. Yuan, and Z. Su. Efficient subcubic alias analysis for c. SIGPLAN Not., 49(10):829-845, Oct. 2014.
- [86] X. Zhang, Z. Feng, X. Wang, G. Rao, and W. Wu. Context-free path queries on rdf graphs. In P. Groth, E. Simperl, A. Gray, M. Sabou, M. Krötzsch, F. Lecue, F. Flöck, and Y. Gil, editors, *The Semantic Web - ISWC 2016*, pages 632–648, Cham, 2016. Springer International Publishing.
- [87] X. Zheng and R. Rugina. Demand-driven alias analysis for c. In Proceedings of the 35th Annual ACM SIGPLAN-SIGACT Symposium on Principles of Programming Languages, POPL '08, pages 197–208, New York, NY, USA, 2008. ACM.
- [88] R. Zier-Vogel and M. Domaratzki. Rna pseudoknot prediction through stochastic conjunctive grammars. *Computability in Europe 2013. Informal Proceedings*, pages 80–89, 2013.
- [89] U. Zwick. A slightly improved sub-cubic algorithm for the all pairs shortest paths problem with real edge lengths. In *International Symposium on Algorithms and Computation*, pages 921–932. Springer, 2004.