Приложения теории формальных языков и синтаксического анализа

Семён Григорьев

2 сентября 2019 г.

Содержание

1	Вве	едение	4											
2	Обі	цие сведения теории графов	4											
	2.1	Транзитивне замыкание графа	4											
	2.2	Задачи поиска путей	4											
3 Общие сведения теории формальных языков														
	3.1	Контекстно-свободные грамматики и языки	5											
	3.2	Дерево вывода	5											
	3.3	Нормальная форма Хомского	6											
	3.4	Алгоритм СҮК	6											
4	1 Постановка задачи о поиске путей с ограничениями в терминах формальных языков													
5	Ор	азрешимости задачи поиска путей с ограничениями в терминах языков	6											
6	Алі	горитм на матричных опреациях	7											
	6.1	Алгоритм для графов на основе СҮК	7											
	6.2	Алгоритм на основе матриц	7											
	6.3	Конъюнктивные и булевы граммтики	7											
		6.3.1 Определения	7											
		6.3.2 Для графов	7											
	6.4	Особенности реализации матричного алгоритма	7											
	6.5	Обзор	7											
	6.6	Вопросы и задачи	7											
7	чер	рез тензорное произведение	8											
	7.1	Рекурсивные автоматы и сети	8											
	7.2	Тензорное произведение	9											
	7.3	Алгоритм	11											
	7.4	Примеры	12											
	7.5	Замечания о реализации	32											
	7.6	Вопросы и задачи	32											
8	Сж	атое представление леса разбора	32											
	8.1	Лес разбора как представление контекстно-свободной грамматики	32											
	8.2	Вопросы и задачи	32											

9	Алгоритм на основе восходящего анализа	33
	9.1 Восходящий синтаксический анализ	. 33
	9.2 Вопросы и задачи	. 33
10	Алгоритм на основе нисходящего анализа	33
	10.1 Нисходящий синтаксический анализ	. 34
11	От CFPQ к вычислению Datalog-запросов	3 4
	11.1 Datalog	. 34
	11.2 KC-запрос как запрос на Datalog	. 34
	11.3 Обобщение GLL для вычисления Datalog-запросов	. 34

1 Введение

Одна из классических задач, связанных с анализом графов — это поиск путей в графе. Возможны различные формулировки этой задачи. В некоторых случайх необходимо выяснить, существует ли путь с определёнными свойствами между двумя выбранными вершинами. В других же ситуациях необходимо найти все пути в графе, удовлетворяющие некоторым свойствам.

Так или иначе, на практике часто требуется указать, что интересующие нас пути должны обладать каким-либо специальными свойствами. Иными словами, наложить на пути некоторые ограничения. Например, указать, что искомый путь должен быть простым, кратчайшим, гамильтоновым и так далее.

Один из способов задавать ограничения на пути в графе основан на использовании формальных языков. Базоваое определение языка говорит нам, что язык — это множество слов над некоторым алфавитом. Если рассмотреть граф, рёбра которого помечены символами из алфавита, то путь в графе будет задавать слово: достаточно соединить последовательно символы, лежащие на рёбрах пути. Множество же таких путей будет задавать множество слов или язык. Таким образом, если мы хотим найти некоторое множество путей в графе, то в качестве ограничения можно описать язык, который должно задачать это множество. Иными словами, задача поиска путей может быть сформулирована следующим образом: необходимо найти такие пути в графе, что слова, получаемые конкатенацей меток их рёбер, принадлежат заданному языку. Такой класс задач будем называть задачами поиска путей с ограничениям в теринах формальных языков.

Рассмотрим различные варианты постановки задачи.

Различные алгоритмы решения.

2 Общие сведения теории графов

основные определения: рёбра, вершины, графы ориентированные, неориентированные, помеченные.

Специальные понятия, необходимые для иложения конкретного материала, будут даны в соответсвующих главах.

Матрицы смежности

2.1 Транзитивне замыкание графа

Флойд-Уоршал, матрицы.

Рассуждения про субкубичность. Про то, что булево полукольцо.

2.2 Задачи поиска путей

Достижимость, все пути, один путь.

Про кратчайшие, простые и прочее.

Про классические задачи и классическое сведение к матричным операциям.

Тра-та-та.

3 Общие сведения теории формальных языков

В данной главе мы рассмотрим основные понятия из теории формальных языков, которые пригодятся нам в дальнейшем изложении.

Определение 3.1. *Алфавит* — это конечное множество. Элементы этого множества будем называть *символами*.

Традиционное обозначение для алфавита — Σ . Также мы будем использовать различные прописные буквы латинского алфавита.

Будем считать, что над алфавитом Σ всегда определена операция конкатенации (\cdot) : $\Sigma^* \times \Sigma^* \to \Sigma^*$. При записи выражений символ точки (обозначение операции конкатенации) часто будем опускать: $a \cdot b = ab$.

Определение 3.2. C_{n060} над алфавитом Σ — это конечная конкатенация символов алфавита Σ : $\omega = a_0 \cdot a_1 \cdot \ldots \cdot a_m$, где ω — слово, а для любого i $a_i \in \Sigma$.

Определение 3.3. Cлово над алфавитом Σ — это результат конечной конкатенации символов алфавита Σ : $\omega = a_0 \cdot a_1 \cdot \ldots \cdot a_m$, где ω — слово, а для любого i $a_i \in \Sigma$. Будем называть m+1 длиной слова и обозначать как $|\omega|$.

Определение 3.4. *Язык* над алфавитом Σ — это множество слов над алфавитом Σ .

Заметим, что язык не обязан быть конечным множеством, в то время как алфавит обязан быть конечным и изучаем мы конечные слова.

Определение 3.5. Способы задания языков

- Перечислить для онечных
- Генератор
- Распознователь

3.1 Контекстно-свободные грамматики и языки

Определение 3.6. Контекстно-свободная грамматика

Определение 3.7. Вывод слова в граммтике

Определение 3.8. Левосторонний вывод

Аналогично можно определить правосторонний вывод.

Неоднозначные граммтики.

Существенно неоднозначные языки

3.2 Дерево вывода

Дерево вывода цепочки в граммтике

- Корневое. Корень помечен стартовым нетерминалом.
- Упорядоченное
- Соотношение узлов и правил
- Крона цепочка

3.3 Нормальная форма Хомского

Данный алгоритм накладывает ограничение на форму грамматики: грамматика должна быть в "ослабленной" нормальной форме Хомского.

Определение НФХ.

Любую КС граммтику можно преобразовать в НФХ.

3.4 Алгоритм СҮК

Построение и заполнение таблицы.

4 Постановка задачи о поиске путей с ограничениями в терминах формальных языков

Пусть $\mathcal{G} = \langle V, E, L \rangle$ — конечный ориентрованный граф с метками на рёбрах, где V — конечное множество вершин, E — конечное множество рёбер, L — конечное множество или алфавит меток. Рёбра будем представлять в виде упорядоченных троек из $V \times L \times V$. Путём π в графе \mathcal{G} будем называть последовательность рёбер такую, что для любых двух последовательных рёбер $e_1 = (u_1, l_1, v_1)$ и $e_2 = (u_2, l_2, v_2)$ в этой последовательности, конечная вершина первого ребра является начальной вершиной второго, то есть $v_1 = u_2$. Будем обобзначать путь из вершины v_0 в вершину v_n как $v_0 \pi v_n = e_0, e_1, \ldots, e_{n-1} = (v_0, l_0, v_1), (v_1, l_1, v_2), \ldots, (v_{n-1}, l_n, v_n)$.

Функция $\omega(\pi) = \omega((v_0, l_0, v_1), (v_1, l_1, v_2), \dots, (v_{n-1}, l_n, v_n)) = l_0 \cdot l_1 \cdot \dots \cdot l_n$ строит слово по пути посредством конкатенации меток рёбер вдоль этого пути. Очевидно, для пустого пути данная функция будет возвращать пустое слово, а для пути длины n > 0 — непустое слово длины n.

Путь $G = \langle \Sigma, N, P \rangle$ — контекстно-свободная граммтика. Будем считать, что $L \subseteq \Sigma$. Мы не фиксируем стартовый нетерминал в определении граммтики, поэтому, чтобы описать язык, задаваемый ей, нам необходимо отдельно зафиксировать стартовый нетерминал. Таким образом, будем говорить, что $L(G, N_i) = \{w | N_i \overset{*}{\underset{G}{\Rightarrow}} w\}$ — это язык задаваемый граммтикой G со стартовым нетерминалом N_i .

Задача достижимости:

Задача поиска путей:

5 О разрешимости задачи поиска путей с ограничениями в терминах языков

Сведение к задаче о пересечениии с регулярным.

Замкнутость регулярных.

Проверка пустоты.

Замкнутость контекстно-свободных. Проверка пустоты.

Про другие классы языков: конъюнктивные, булевы, многокомпонентные.

6 Алгоритм на матричных опреациях

6.1 Алгоритм для графов на основе СҮК

Обобщение. Смотрим на транзитивное замыкание.

6.2 Алгоритм на основе матриц

Ссылка на Валианта [?].

Оригинальные матрицы (Рустам) [1]

Кратчайшие.

Одно дерево?

6.3 Конъюнктивные и булевы граммтики

6.3.1 Определения

Охотин [?].

6.3.2 Для графов

Классическая семантика— работает для конъюнктивных для любых графов. Для Булевых и конъюнктивных только для графов без циклов.

Альтернативная семантика (DataLog). Трактуем конъюнкцию как в даталоге. Тогда всё хорошо. Это похоже на даталог через линейную алгебру [?]

6.4 Особенности реализации матричного алгоритма

Кое-что про наши реализации [6]

Разреженные матрицы, плотные матрицы, GraphBLAS¹, GPGPU, CUTLASS².

Расположенеи в памяти: хорошо, когда всё влезло на одну карту.

Распределённые решения. Через GraphBLAS

6.5 Обзор

Китайцы [?], Брэдфорд [?], Ли [?], Хеллингс [?], OpenCypher [4].

Рассуждения про ассимптотику.

Субкубический для частного случая (Брэдфорд) [2].

6.6 Вопросы и задачи

1. !!!

 $¹_{[!]!}$

²Репозиторий библиотеки CUTLASS: https://github.com/NVIDIA/cutlass

7 Через тензорное произведение

Предыдущий подход позволяет выразить задачу поиска путей с ограничениями в терминах ыормальных языков через набор матричных операций. Это позволяет использовать высокопроизводительные библиотеки и массовопараллельные архитектуры и вообще круто. Однако, такой подход требует, чтобы грамматика находилась в ослабленной нормальной форме Хомского, что приводит к её разростанию. Можно ли как-то избежать этого?

В данном разделе мы попробуем предложить альтернативное сведение задачи поиска путей к матричным опреациям. В результате мы сможем избежать преобразования граммтики в ОНФХ, однако, матрицы, с которыми нам предётся работать, будут существенно бо́льшего размера.

В основе подхода лежит использование рекурсивных сетей или рекурсивных автоматов в качестве представления контекстно-свободных грамматик.

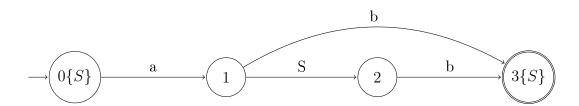
7.1 Рекурсивные автоматы и сети

Рекурсивный автомат или сеть — это представление контекстно-свободных грамматик, обобщающее конечные автоматы. В нашей работе мы будем придерживаться термина **рекурсивный автомат**. Классическое определение рекурсивного автомата выглядит следующим образом.

Определение 7.1. Рекурсивный автомат — это кортеж вида (N, Σ, S, D) , где

- *N* нетерминальный алфавит;
- Σ терминальный алфавит;
- S стартовый нетерминал;
- D конечный автомат над $N \cup \Sigma$ в котором стартовые и финальные состояния помечены подмножествами N.

Построим рекурсивный автомат для грамматики!!!!



Используем стандартные обозначения для стартовых и финальных состояний. Дополнительно в стартовых и финальных состояниях укажем нетерминалы, для которых эти состояния стартовые/финальные.

В некоторых случаях рекурствный автомат можно рассматривать как конечный автомат над смешанным алфавитом. Именно такой взгляд мы будем использовать при изложении алгоритма.

7.2 Тензорное произведение

Тензорное произведение матриц или произведение Кронекера — это бинарная опирация, обозначаемая ⊗ и определяемая следующим образом.

Определение 7.2. Пусть даны две матрицы: A размера $m \times n$ и B размера $p \times q$. Произведение Кронекера или тензорное произведение матриц A и B — это блочная матрица C размера $mp \times nq$, вычисляемая следующим образом:

$$C = A \otimes B = \begin{pmatrix} A_{0,0}B & \cdots & A_{0,n-1}B \\ \vdots & \ddots & \vdots \\ A_{m-1,0}B & \cdots & A_{m-1,n-1}B \end{pmatrix}$$

Пример 7.1.

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \otimes \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} = \begin{pmatrix} 1 & 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{pmatrix} \begin{pmatrix} 7 & 8 & 10 & 12 & 14 & 16 \\ 9 & 10 & 11 & 12 & 18 & 20 & 22 & 24 \\ 13 & 14 & 15 & 16 & 26 & 28 & 30 & 32 \\ 15 & 18 & 21 & 24 & 20 & 24 & 28 & 32 \\ 27 & 30 & 33 & 36 & 36 & 40 & 44 & 48 \\ 39 & 42 & 45 & 48 & 52 & 56 & 60 & 64 \end{pmatrix}$$
 (1)

Заметим, что для определения тензорного произведения матриц достаточно определить опреацию умножения на элементах исходных матриц. Также отметим, что произведение Кронекера не является коммутативной. При этом всегда существуют такиедве матрицы перестоновок P и Q, что $A \otimes B = P(B \otimes A)Q$. Это свойство потребуется нам в дальнейшем.

Теперь перейдём к графам. Сперва дадим классическое определение тензорного произведения двух неориентированных графов.

Определение 7.3. Пусть даны два графа: $\mathcal{G}_1 = \langle V_1, E_1 \rangle$ и $\mathcal{G}_2 = \langle V_2, E_2 \rangle$. Тензорным произведением этих графов будем называть граф $\mathcal{G}_3 = \langle V_3, E_3 \rangle$, где $V_3 = V_1 \times V_2$, $E_3 = \{((v_1, v_2), (u_1, u_2)) \mid (v_1, u_1) \in E_1$ и $(v_2, u_2) \in E_2\}$.

Иными словами, тензорным произведением двух графов является граф, такой что:

- 1. множество вершин это прямое произведение множемтв вершин исходных графов;
- 2. ребро между вершинами $v = (v_1, v_2)$ и $u = (u_1, u_2)$ существует тогда и только тогда, когда существуют рёбра между парами вершин v_1 , u_1 и v_2 , u_2 в соответсвующих графах.

Для того, чтобы построить тензорное произведение ориентированных графов, необходимо в предыдущем определении, в условии существования реба в результирующем графе, дополнительно потребовать, чтобы направления рёбер совпадали. Данное требование получается естесвенным образом, если считать, что пары вершин, задающие ребро упорядочены, поэтому формальное определение отличаться не будет.

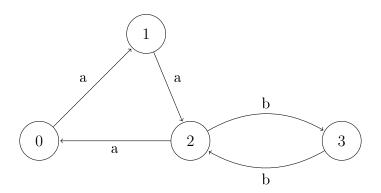
Осталось добавить метки к рёбрам. Это приведёт к логичному усилению требованя к существованию ребра: метки рёбер в исходных графах должны совпадать. Таким образом, мы получаем следующее определение тензорного произведения ориентированных графов с метками на рёбрах.

Определение 7.4. Пусть даны два ориентированных графа с метками на рёбрах: $\mathcal{G}_1 = \langle V_1, E_1, L_1 \rangle$ и $\mathcal{G}_2 = \langle V_2, E_2, L_2 \rangle$. Тензорным произведением этих графов будем называть граф $\mathcal{G}_3 = \langle V_3, E_3, L_3 \rangle$, где $V_3 = V_1 \times V_2$, $E_3 = \{((v_1, v_2), l, (u_1, u_2)) \mid (v_1, l, u_1) \in E_1$ и $(v_2, l, u_2) \in E_2\}$, $L_3 = L_1 \cap L_2$.

Нетрудно заметить, что матрица смежности графа \mathcal{G}_3 равна тенорному произведению матриц смежностей исходных графов \mathcal{G}_1 и \mathcal{G}_2 .

Рассмотрим пример. В качестве одного из графов возьмём рекурсивный автомат, построенный ранее!!!. Его матрица смежности выглядит следующим образом.

$$M_1 = \begin{pmatrix} . & [a] & . & . \\ . & . & [S] & [b] \\ . & . & . & [b] \\ . & . & . & . \end{pmatrix}$$



Второй граф представлен на изображении 7.2. Его матрица смежности имеет следующий вид.

$$M_2 = \begin{pmatrix} \cdot & [a] & \cdot & \cdot \\ \cdot & \cdot & [a] & \cdot \\ [a] & \cdot & \cdot & [b] \\ \cdot & \cdot & [b] & \cdot \end{pmatrix}$$

Теперь вычислим $M_1 \otimes M_2$.

Побалуемся с некоммутативностью и перестановками.

7.3 Алгоритм

Идея алгоритма основана на обобщении пересечения двух конечных автоматов до пересечения рекурсивного автомата, построенного по грамматике, со входным графом.

Пересечение двух конечных автоматов — тензорное произведение соответствующих графов. Пересечение языкрв коммутативно, тензорное произведение нет, но это не страшно.

Несколько наблюдений Путь из нетерминалов и терминалов. При этом должны быть пути из терминалов. Иначе не задать язык. Будем насыщать граф рёбрами, помеченными нетерминалами.

По грамматике строим автомат. г 13

В цикле: пересекли через тензорное произведение, замкнули через обычное матричное произведение, чтобы найти пути из начальной в конечную в граммтике, поставили в соответствующие ячейки нетерминалы, добавили соответствующие рёбра в исходный граф.

Можно вычислять только разницу. Для этого, правда, потребуется держать ещё одну матрицу. И надо проверять, что вычислительно дешевле: поддерживать разницу и потом каждый раз поэлементно складывать две матрицы или каждый раз вычислять полностью произведение.

Всего несколько матриц. Разреженные. Необходимо отметить, что для реальных графов и запросов результат тензорного произведения будет очень разрежен. На готовых либах должно быть быстро.

Listing 1 Поиск путей через тензорное произведение

```
1: function ContextFreePathQueryIngTP(G, \mathcal{G})
 2:
         N \leftarrow рекурсивный автомат для G
         M_1 \leftarrow матрица смежности N
 3:
         M_2 \leftarrow матрица смежности \mathcal{G}
 4:
        T \leftarrow the matrix n \times n in which each element is \varnothing
 5:
         for all (i, x, j) \in E do
                                                                                               ▶ Matrix initialization
 6:
 7:
             T_{i,j} \leftarrow T_{i,j} \cup \{A \mid (A \rightarrow x) \in P\}
         while matrix T is changing do
 8:
 9:
             M_3 \leftarrow M_1 \otimes M_2
                                                                                                M_3 \leftarrow transitiveClosure(M_3)
10:
             for do
11:
                 for do
12:
13:
                     if then
                          Nt \leftarrow M_3[i,j] \cup \{\}
14:
                          m \leftarrow M_3[i,j] \cup \{\}
15:
                          n \leftarrow M_3[i,j] \cup \{\}
16:
                          M_2[n,m] \leftarrow M_2[n,m] \cup \{Nt\}
17:
18:
        return T
```

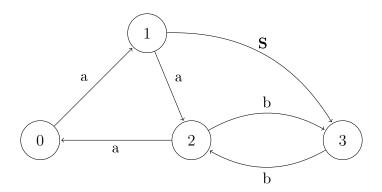
7.4 Примеры

Рассмотрим подробно ряд примеров работы описанного алгоритма. Будем для каждой итерации внешнего цикла выписывать результаты основных операций: тензорного произведения, транзитивного замыкания, обновления матрицы смежности входного грвфа. Новые, по сравнению с пердыдущим состоянием, элементы матриц будем выделять жирным.

Пример 7.2. Теоретический худший случай. Такой же как и для матричного.

Итерация 1 (конец). Начало в разделе!!!, где мы вычислили тензорное произведение матриц смежности. Теепрь нам осталось только вычислить транзитивное замыкание полученной матрицы.

Мы видим, что в результате транзитивного замыкания появилось новое ребро с меткой ab из вершины (0,1) в вершину (3,3). Так как вершина 0 является стартовой в рекурсивном автоматие, а 3 является финальной, то слово вдоль пути из вершины 1 в вершину 3 во входном графе выводимо из нетерминала S. Это означает, что в графе должно быть добавлено ребро из 0 в 3 с меткой S, после чего граф будет выглядеть следующим образом:



Матрица смежности обновлённого графа:

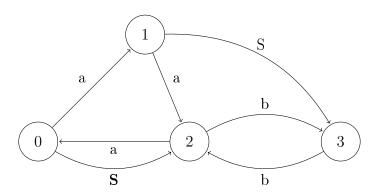
$$M_2 = \begin{pmatrix} \cdot & [a] & \cdot & \cdot \\ \cdot & \cdot & [a] & [\mathbf{S}] \\ [a] & \cdot & \cdot & [b] \\ \cdot & \cdot & [b] & \cdot \end{pmatrix}$$

Итерация закончена. Возвращаемся к началу цикла и вновь вычисляем тензорное произведение.

Итерация 2. Вычисляем тензорное произведение матриц смежности.

Вычисляем транзитивное замыкание полученной матрицы:

В транзитивном замыкании появилось три новых ребра, лжнако только одно из них соединяет вершины, соответствующие сартовому и конечному состоянию входного рекурсивного автомата. Только это ребро должно быть соответствующим образом добавлено во входной граф. В итоге, обновлённый граф:



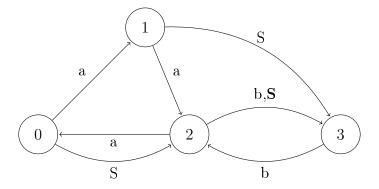
И его матрица смежности:

$$M_2 = \begin{pmatrix} . & [a] & [S] & . \\ . & . & [a] & [S] \\ [a] & . & . & [b] \\ . & . & [b] & . \end{pmatrix}$$

Итерация 3. Снова начинаем с тензорного произведения.

Затем вычисляем транзитивное замыкание:

И наконец обновляем граф:



Матрица смежности обновлённого графа:

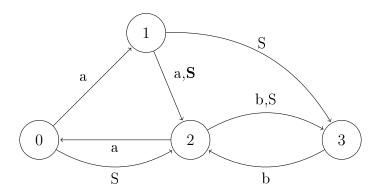
$$M_2 = \begin{pmatrix} \cdot & [a] & [S] & \cdot \\ \cdot & \cdot & [a] & [S] \\ [a] & \cdot & \cdot & [b, \mathbf{S}] \\ \cdot & \cdot & [b] & \cdot \end{pmatrix}$$

Уже можно заметить закономерность: на каждой итерации мы добавляем ровно одно новое ребро во входной граф. То есть находим ровно одну новую пару вешин, между которыми существует интересующий нас путь. Попробуйте спрогонозировать, сколько итераций нам ещё осталось сделать.

Итерауия 4. Продолжаем. Вычисляем тензорное произведение.

Затем транзитивное замыкание:

И снова обновляем граф, так как в транзитивном замыкании оявился один (и снова ровно один) новый элемент, соответствующий принимающему пути в автомате.



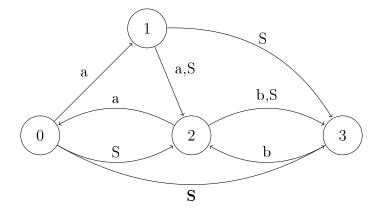
Матрица смежности обновлённого графа:

$$M_2 = \begin{pmatrix} . & [a] & [S] & . \\ . & . & [a, \mathbf{S}] & [S] \\ [a] & . & . & [b, S] \\ . & . & [b] & . \end{pmatrix}$$

Итерация 5. Приступаем к выполнению следующей итерации основного цикла. Вычисляем тензорное произведение.

Затем вычисляем транзитивное замыкание:

Обновляем граф:



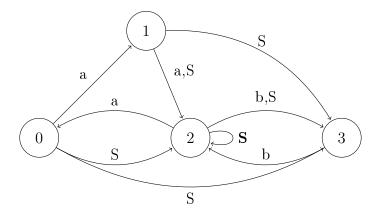
Матрица смежности обновлённого графа:

$$M_2 = \begin{pmatrix} . & [a] & [S] & [\mathbf{S}] \\ . & . & [a, S] & [S] \\ [a] & . & . & [b, S] \\ . & . & [b] & . \end{pmatrix}$$

Итерация 6. И наконец последняя содержательная итерация основного цикла.

Транзитивное замыкание:

Обновлённый граф:



И матрица смежности:

$$M_2 = \begin{pmatrix} . & [a] & [S] & [S] \\ . & . & [a, S] & [S] \\ [a] & . & [\mathbf{S}] & [b, S] \\ . & . & [b] & . \end{pmatrix}$$

Следующая итерация не приведёт к изменению графа. Читатель может убедиться в этом самостоятельно. Соответственно алгоритм можно завершать. Нам потребовалось семь итераций (шесть содержательных и одна проверочная).

Матрица смежности получилась такая же, как и раньше, рответ правильный. Мы видим, что количество итераций внешнего цикла такое же как и у алгоритма !!!. И ещё что-то видим и можем понять.

Пример 7.3. В данном примере мы увидим, как структура грамматики и, соответственно, рекурсивного автомата, влияет на процесс вычислений.

Интуитивно понятно, что чем меньше состояний в рекурсивной сети, тем лучше. То есть желательно получить как можно более компактное описание контекстно-свободного языка.

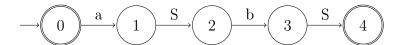
Для примера возьмём в качестве KC языка язык Дика на одном типе скобок и опишем его двумя различными грамматиками. Первая граммтика классическая:

$$G_1 = \langle \{a, b\}, \{S\}, \{S \rightarrow a \ S \ b \ S \mid \varepsilon \} \rangle$$

Во второй грамматике мы будем использовать конструкции регулярных выражений в правой части правил. То есть вторая грамматика находитмся в EBNF [?].

$$G_2 = \langle \{a, b\}, \{S\}, \{S \to (a \ S \ b)^*\} \rangle$$

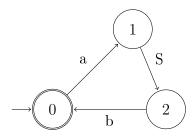
Построим рекурсивные автоматы N_1 и N_2 и их матрицы смежности для этих грамматик. Рекурсивный автомат N_1 для грамматики G_1 :



Матрица смежности N_1 :

$$M_1^1 = \begin{pmatrix} \cdot & [a] & \cdot & \cdot & \cdot \\ \cdot & \cdot & [S] & \cdot & \cdot \\ \cdot & \cdot & \cdot & [b] & \cdot \\ \cdot & \cdot & \cdot & \cdot & [S] \\ \cdot & \cdot & \cdot & \cdot & \cdot \end{pmatrix}$$

Рекурсивный автомат N_2 для грамматики G_2 :



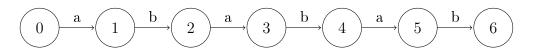
Матрица смежности N_2 :

$$M_1^2 = \begin{pmatrix} \cdot & [a] & \cdot \\ \cdot & \cdot & [S] \\ [b] & \cdot & \cdot \end{pmatrix}$$

Первое, очевидное, наблюдение — количество состояний в N_2 меньше, чем в N_1 . Это значит, что матрицы будут меньше, считать быстрее.

Для того, чтобы проще было сделать второе, сперва выполним пошагово алгоритм для двух заданных рекурсивных сетей.

Вход возьмём линейный:



Сразу дополним матрицу смежности нетерминалами, выводящими пустую строку, и получим следующую матрицу:

$$M_{2} = \begin{pmatrix} [S] & [a] & . & . & . & . & . \\ . & [S] & [b] & . & . & . & . \\ . & . & [S] & [a] & . & . & . \\ . & . & . & [S] & [b] & . & . \\ . & . & . & . & [S] & [a] & . \\ . & . & . & . & . & [S] & [b] \\ . & . & . & . & . & . & . & [S] \end{pmatrix}$$

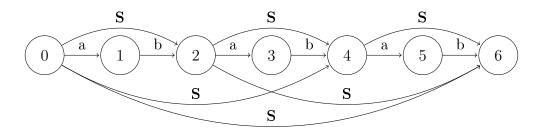
Сперва запустим алгоритм на входе и N_2 . Первый шаг первой итерации — вычисление тензорного произведения $M_1^2\otimes M_2$.

Опустим промежуточные шаги вычисления транзитивного замыкания M_3 и сразу пред-

ставим конечный результат:

В результате вычисления транзитивного замыкания появилось большое количество новых рёбер, однако нас будут интересновать только те, информация о которых храниться в левом верхнем блоке. Остальные рёбра не соответствуют принимающим путям в рекурсивном автомате (убедитесь в этом самостоятельно).

После добавления соответствующих рёбер, мы получим следующий граф:



Его матрица смежности:

$$M_{2} = \begin{pmatrix} [S] & [a] & [S] & . & [S] & . & [S] \\ . & [S] & [b] & . & . & . & . \\ . & . & [S] & [a] & [S] & . & [S] \\ . & . & . & [S] & [b] & . & . \\ . & . & . & . & . & [S] & [a] & [S] \\ . & . & . & . & . & . & . & [S] \end{pmatrix}$$

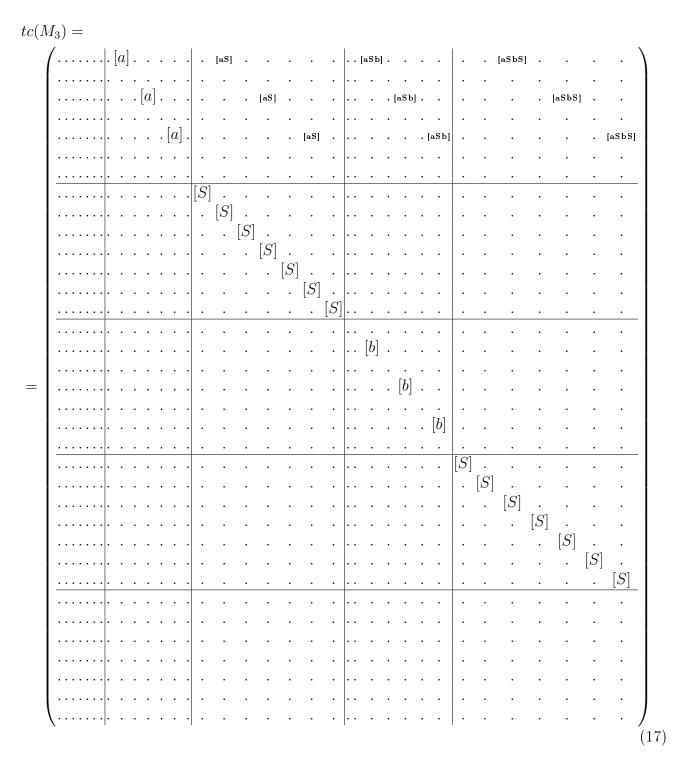
Таким образом видно, что для выбранных входных данных алгоритму достаточно двух итераций основного цикла: первая содержательная, вторая, как обычно, проверочная. Читателю предлагается самостоятельно выяснить, сколько умножений матриц потребуется, стобы вычислить транзитивное замыкание на первой итерации.

Теперь запустим алгоритм на второй грамматике и том же входе.

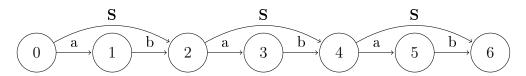
M_3	$=M_1^1\otimes M_2=$	$\begin{pmatrix} \cdot & [a] \\ \cdot & \cdot \\ \cdot & \cdot \\ \cdot & \cdot \\ \cdot & \cdot \end{pmatrix}$. [S] [· · · · · · · · · · · · · · · · · · ·	[S]	$\otimes \begin{pmatrix} [S] \\ \cdot \\ \cdot \\ \cdot \\ \cdot \\ \cdot \\ \cdot \end{pmatrix}$	[S] [a] [S] [S]	. [b] [S]	. [a] [S]	[b] [S]	[<i>a</i>] [<i>a</i>]	$\begin{bmatrix} \cdot \\ \cdot \\ \cdot \\ \cdot \\ \end{bmatrix}$ $\begin{bmatrix} b \end{bmatrix}$ $\begin{bmatrix} S \end{bmatrix}$		=						
	$/\ldots a $		 \
		. [a]																		
			. [a]																	.
								•												
				[S]				•										•		
					[S]			•												
						[S] .	•	•												
						. [S	"] .													.
							[S]											•		.
	<u> </u>				•			•	[S]									•	•	·
																				.
							•	•			[b]									
							•	•												.
=							•	•				. [b]						•	•	
							•	•										•		.
					٠		•	•					. [b]					•		.
					•		•	•	•		•				•	•		•	•	<u> </u>
					٠		•	•						S				•		.
					•		•	•			•				[S]			•	•	
			• •				•	•	•		•				•	[S]		•	•	
			• •		٠		•	•	٠	• •	٠				•	٠	[S]		•	.
			• •		٠		•	•	٠	• •	٠				•	٠	•	[S]		.
					•		•	•	٠	• •	•				•	٠	•	٠	[S]	
					•		•	•	•		•		• •		•	•	•	•	<u>·</u>	S
			• •	$\cdot \cdot $	٠		•	•	•	• •	•				•	•	•	•	•	.
			• •		•		•	•	•		•				•	•	•	•	•	.
	• • • • • • • •		• •		•		•	•	•	• •	•				•	•	•	•	•	.
			• •		•		•	•	•	• •	•				•	٠	•	•	•	.
	• • • • • • • •		• •		•		•	•	٠		٠				•	٠	•	•	•	.
			• •		•		•	•	•		•				•	•	•	•	•	.]
	$/\cdots\cdots $		• •	. .	•		•	•	•		•			•	•	•	•	•	•	(10)
																				(16)

Уже сейчас можно заметить, что размер матриц, с которыми нам придётся работать, существенно увеличелся, по сравнению с предыдущим вариантом. Это, конечно, закономерно, ведь в рекурсивном автомате для предыдущего варианта меньше состояний, а значит и матрица смежности имеет меньший размер.

Транзитивное замыкание.



Обновлённый граф



Его матрица смежности:

$$M_{2} = \begin{pmatrix} [S] & [a] & [\mathbf{S}] & . & . & . & . \\ . & [S] & [b] & . & . & . & . \\ . & . & [S] & [a] & [\mathbf{S}] & . & . \\ . & . & . & [S] & [b] & . & . \\ . & . & . & . & [S] & [a] & [\mathbf{S}] \\ . & . & . & . & . & . & [S] & [b] \\ . & . & . & . & . & . & . & . & [S] \end{pmatrix}$$

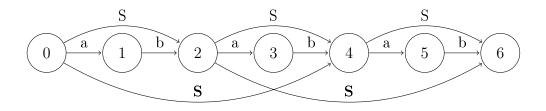
Потребуется ещё одна итерация.

$$M_{3} = M_{1}^{1} \otimes M_{2} = \begin{pmatrix} \cdot & [a] & \cdot & \cdot & \cdot \\ \cdot & [S] & [b] & [b] & \cdot & \cdot \\ \cdot & \cdot & [S] & [a] & [S] & \cdot & \cdot \\ \cdot & \cdot & [S] & [a] & [S] & \cdot & \cdot \\ \cdot & \cdot & [S] & [a] & [S] & \cdot & \cdot \\ \cdot & \cdot & [S] & [b] & \cdot & \cdot & \cdot \\ \cdot & \cdot & [S] & [b] & \cdot & \cdot & \cdot \\ \cdot & \cdot & \vdots & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots \\ \cdot & \cdot & \cdot & \vdots & \vdots \\ \cdot & \cdot &$$

Транзитивное замыкание.

 $tc(M_3) =$ (19)

Обновлённый граф. На этом шаге мы смогли "склеить" из подстрок, воводимых из S, более длинные пути. Однако, согласно правилам грамматики, мы согли "скленить" только две подстроки в единое целое.



Матрица смежности обновлённого графа:

$$M_{2} = \begin{pmatrix} [S] & [a] & [S] & . & [\mathbf{S}] & . \\ . & [S] & [b] & . & . & . \\ . & . & [S] & [a] & [S] & . & [\mathbf{S}] \\ . & . & . & [S] & [b] & . & . \\ . & . & . & . & . & [S] & [a] & [S] \\ . & . & . & . & . & . & . & [S] \end{pmatrix}$$

И, наконец, последняя содержательная итерация.

Транзитивное замыкание.

/																									
- ([′]	. [a]						[aS]		[aS]		[aS]			[aSb]] - [[aSb]	. [aSb]			[aSbS]		[aSbS]	•	[aSbS]
			[a	ι].				•		[aS]		[aS]	•			•	· [aSb]	 . [aSb]					· [aSbS]		· [aSbS]
								•				•													
				•	[a]			•				[aS]					•	. [aSb]		•	•			•	[aSbS]
ı				•	•		•	•	•	•	•	•	•		•	•	•			•	•	٠	•	•	•
	• • • • • • • • • • • • • • • • • • • •			•	•	\cdot	· [0]	•	[0]	•	[0]	•	•		•	•	•			•	•	•	•	•	•
				•	•			[c]	[5]	•	[S]	•	•		•	٠	•			•	•	٠	•	•	•
				•	•				[S]	•	[S]	•	[<i>S</i>]		•	•	•			•	•	•	•	•	•
				•						[S]		•	[ا		•	•	•			•	•	•	•	•	•
				•	•	•	•	•			[S]	•	[S]		•	•	•			•	•	•	•		
												[S]	ر∼]						.						
													[S]						١.						·
															[b]										
:								•				•					[b]			•					
							•	•			•	•					•			•					•
ı				•	٠		•	•			•	•	•			•	•	. [b]		•			•	•	•
	• • • • • • • • • • • • • • • • • • • •			•	•	•	•	•	•	•	•	•	•		•	•	•			•		•		•	·
				•	•	•	•	•	•	•	•	•	•		•	•	•		S	[<i>[</i>]	[S]	٠	[S]	•	•
				•	•		•	•	•	•	•	•	•		•	•	•			[S]	[<i>C</i>]	٠	[<i>C</i>]	•	[<i>C</i>]
				•	•	•	•	•	•	•	•	•	•		•	•	•	• •		•	[S]	S[S]	[S]	•	[S]
				•	•	•	•	•	•	•	•	•	•		•	•	•	• •		•	•	[]	[S]	•	[S]
				•	•	•	•	•	•	•	•	•	•		•	•	•			•	•	•		[S]	
																			:						[S]
										•					•										
												•													
																									•
																									•
																			.						
								•									•								
/	\·····						•	•			•	•							.				•		. ,

В конечном итоге мы получаем такой же результат как и при первом запуске. Однако нам потребовалось выполнить существенно больше итераций внешнего цикла, а именно четыре (три содержательных и одна проверочная). При этом, в ходе работы нам пришлось оперировать сущесвенно бо́льшими матрицами: 35×35 против 21×21

Таким образом — минимизация рекурсивного автомата как конечного автомата над смешанным алфавитом может быть полезна.

7.5 Замечания о реализации

Блочная структура матриц даёт хорошую основу для распределённого умнодения при построении транзитивного замыкания.

Кодирование данных в ячейках.

Транзитивное замыкание.

7.6 Вопросы и задачи

- 1. Оценить пространсвенную сложность алгоритма.
- 2. Оценить временную сложность алгоритма.
- 3. Найти библиотеку для тензорного произведения. Реализовать алгоритм. Можно предпологать, что запросы содержат ограниченное число терминалов и нетерминалов. Провести замеры. Сравнить с матричным.
- 4. Реализовать распределённое решение. См. блочную структуру

8 Сжатое представление леса разбора

Матричный алгоритм даёт нам ответ на вопрос о достижимости, но не предоставляет самих путей. Что делать, если мы хотим построить все пути, удовлетворяющие ограичениям?

Проблема в том, что множество путей может быть бесконечным. Можем ли мы предложить конечную структуру, однозначно описывающую такое множество? Вспомним, что пересечение контекстно-свободного языка с регулярным — это контекстно-свободный язык. Мы знаем, что конекстно-свободный язык можно описать коньекстно-своюодной граммтикой, которая конечна. Это и есть решение нашего вопроса. Осталось толко научиться строить такую грамматику.

8.1 Лес разбора как представление контекстно-свободной грамматики

Добавление информации в классическое дерево разбора. Координаты и промежуточные узлы.

8.2 Вопросы и задачи

- 1. Постройте дерево вывода цепочки w=aababb в грамматике $G=\langle \{a,b\}, \{S\}, \{S\to\varepsilon\mid a\ S\ b\ S\}, S\rangle.$
- 2. Постройте все левосторонние выводы цепочки w=ababab в грамматике $G=\langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \mid S \mid b \mid S \mid S\}, S \rangle$.
- 3. Постройте все правосторонние выводы цепочки w=ababab в грамматике $G=\langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \mid S \mid b \mid S \mid S\}, S \rangle$.

- 4. Постройте все деревья вывода цепочки w = ababab в грамматике $G = \langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \mid S \mid b \mid S \mid S\}, S \rangle$, соответствующие левосторонним выводам.
- 5. Постройте все деревья вывода цепочки w = ababab в грамматике $G = \langle \{a,b\}, \{S\}, \{S \to \varepsilon \mid a \mid S \mid b \mid S \mid S\}, S \rangle$, соответствующие правосторонним выводам.
- 6. Как связаны между собой леса, полученные в предыдущих двух задачах (4 и 5)? Какие выводы можно сделать из такой связи?
- 7. Постройте сжатое представление леса разбора, полученного в задаче 4.
- 8. Постройте сжатое представление леса разбора, полученного в задаче 5.
- 9. Предъявите контекстно-свободную граммтику существенно неоднозначного языка. Возьмите цепочку длины болше пяти, при надлежащую этому языку, и постройте все деревья вывода этой цепочки в предъявленной граммтике.
- 10. Постройте сжатое представление леса, полученного в задаче 9.

9 Алгоритм на основе восходящего анализа

Наша реализация [?]

9.1 Восходящий синтаксический анализ

Основы LR-анализа.

Таблицы, конфликты.

Пример автомата и таблиц.

9.2 Вопросы и задачи

- 1. Постройте автомат для грамматики
- 2. Постройте таблицу для автомата из задачи
- 3. В том числе дать неоднозначную грамматику
- 4. Запустить, постоить деревья, стеки и т.д.

10 Алгоритм на основе нисходящего анализа

Комбинаторы [7] GLL [3]

Другие реализации [5]

10.1 Нисходящий синтаксический анализ

11 От CFPQ к вычислению Datalog-запросов

11.1 Datalog

Конечные Эрбрановы модели. Наименьшая неподвижная точка. C := d

11.2 KC-запрос как запрос на Datalog

Покажем, что для данного графа и КС-запроса можно построить эквивалентный запрос на Datalog.

Пусть дан граф Граф преобразуется в набор фактов (базу данных).

Пусть есть граммтика $G: S \to a \ b \ | \ a \ S \ b$. Она может быть преобразована в запрос следующего вида. $s(X,Y) := a(X,Z), b(Z,Y). \ s(X,Y) := a(X,Z), s(Z,W)b(W,Y). \ ? := s(X,Y)$

Наблюдения: появились пременные, есть порядок у конъюнктов, который задаёт порядок связывания.

11.3 Обобщение GLL для вычисления Datalog-запросов

Дескриптор — состояние процесса: состояние автомата, результат проделанной работы, подстановка. Задача — найти подстановки. На каждом шаге есть набор подстановок.

Список литературы

- [1] R. Azimov and S. Grigorev. Context-free path querying by matrix multiplication. In Proceedings of the 1st ACM SIGMOD Joint International Workshop on Graph Data Management Experiences & Systems (GRADES) and Network Data Analytics (NDA), GRADES-NDA '18, pages 5:1–5:10, New York, NY, USA, 2018. ACM.
- [2] P. G. Bradford. Efficient exact paths for dyck and semi-dyck labeled path reachability (extended abstract). In 2017 IEEE 8th Annual Ubiquitous Computing, Electronics and Mobile Communication Conference (UEMCON), pages 247–253, Oct 2017.
- [3] S. Grigorev and A. Ragozina. Context-free path querying with structural representation of result. In *Proceedings of the 13th Central & Eastern European Software Engineering Conference in Russia*, CEE-SECR '17, pages 10:1–10:7, New York, NY, USA, 2017. ACM.
- [4] J. Kuijpers, G. Fletcher, N. Yakovets, and T. Lindaaker. An experimental study of context-free path query evaluation methods. In *Proceedings of the 31st International Conference on Scientific and Statistical Database Management*, SSDBM '19, pages 121–132, New York, NY, USA, 2019. ACM.
- [5] C. M. Medeiros, M. A. Musicante, and U. S. Costa. Ll-based query answering over rdf databases. *Journal of Computer Languages*, 51:75 87, 2019.

- [6] N. Mishin, I. Sokolov, E. Spirin, V. Kutuev, E. Nemchinov, S. Gorbatyuk, and S. Grigorev. Evaluation of the context-free path querying algorithm based on matrix multiplication. In Proceedings of the 2Nd Joint International Workshop on Graph Data Management Experiences & Systems (GRADES) and Network Data Analytics (NDA), GRADES-NDA'19, pages 12:1–12:5, New York, NY, USA, 2019. ACM.
- [7] E. Verbitskaia, I. Kirillov, I. Nozkin, and S. Grigorev. Parser combinators for context-free path querying. In *Proceedings of the 9th ACM SIGPLAN International Symposium on Scala*, Scala 2018, pages 13–23, New York, NY, USA, 2018. ACM.